

Методы машинного обучения. Активное обучение (Active Learning)

Воронцов Константин Вячеславович

www.MachineLearning.ru/wiki?title=User:Vokov

вопросы к лектору: k.vorontsov@iai.msu.ru

материалы курса:

github.com/MSU-ML-COURSE/ML-COURSE-25-26

орг.вопросы по курсу: ml.cmc@mail.ru

ВМК МГУ • 21 апреля 2026

1 Стратегии активного обучения

- Постановка задачи активного обучения
- Отбор объектов из выборки
- Синтез объектов (планирование экспериментов)

2 Активное обучение с изучающими действиями


- Компромисс «изучение–применение»
- Алгоритм ε -active
- Экспоненциальный градиент

3 Активное обучение в краудсорсинге

- Задача краудсорсинга
- Согласование оценок аннотаторов
- Работа с аннотаторами

Постановка задачи активного обучения

Задача: обучение модели $a: X \rightarrow Y$ по выборке (x_i, y_i) ,
когда получение ответов учителя $y_i = y(x_i)$ стоит дорого.



Постановка задачи активного обучения

Дано: $X^\ell = (x_i, y_i)_{i=1}^\ell$ — выборка размеченных объектов
 $U = (u_i)_{i=1}^K$ — пул неразмеченных объектов

Найти: $a(x, w)$ — модель с инкрементным обучением
 $\phi(u)$ — модель перспективности разметки $u \in U$
 $(u_i, y_i^*)_{i=1}^k, k \leq K$ — размеченная выборка

Критерий: достичь как можно лучшего качества модели a , разметив как можно меньше объектов из U

обучить модель a по начальной выборке $(x_i, y_i)_{i=1}^\ell$;

пока есть неразмеченные объекты и модель не обучилась

$u_i = \arg \max_{u \in U} \phi(u)$ — наиболее перспективный объект;

$y_i^* = y(u_i)$ — запросить ответ учителя (оракула);

дообучить модель $a(x, w)$ ещё на одном примере (u_i, y_i^*) ;

Почему активное обучение быстрее пассивного


Пример 1. Синтетические данные: $\ell = 30$, $\ell + k = 400$;

(а) два гауссовских класса;


логистическая регрессия по 30 объектам:

(b) случайным;


(c) отобранным по максимуму неуверенности классификации.



(a)



(b)



(c)

Обучение по смещённой неслучайной выборке требует меньше данных для построения алгоритма сопоставимого качества.


Почему активное обучение быстрее пассивного

Пример 2. Одномерная задача с пороговым классификатором:

$$x_i \sim \text{uniform}[-1, +1], \quad y_i = [x_i > 0], \quad a(x, \theta) = [x > \theta].$$


Оценим число шагов для определения θ с точностью $\frac{1}{k}$.

- Наивная стратегия: выбирать $u_i \sim \text{uniform}(U)$;
— число шагов $O(k)$.
- Бинарный поиск: выбирать u_i , ближайший к середине зазора между классами $\frac{1}{2} \left(\max_{y_j=0} (x_j) + \min_{y_j=1} (x_j) \right)$;
— число шагов $O(\log k)$.



Оценивание качества активного обучения

Кривая обучения (learning curve) — зависимость точности классификации на тесте от числа размеченных объектов k .



Идея: строить кривые обучения отдельно по классам, чтобы размечать объекты, вероятнее лежащие в проблемных классах

Burr Settles. Active Learning Literature Survey. 2010.

Стратегии активного обучения

- **Отбор объектов из выборки (pool-based sampling):**
какой следующий u_i выбрать из пула $U = \{u_i\}_{i=1}^K$
- **Синтез объектов (query synthesis):**
на каждом шаге синтезировать оптимальный объект u_i
- **Отбор объектов из потока (selective sampling):**
для каждого приходящего u_i решать, стоит ли узнавать y_i^*

Методы, чувствительные к стоимости (cost-sensitive):

$$\sum_{i=1}^{\ell} \mathcal{L}(x_i, y_i; \theta) + \sum_{u_i \in U_k} (C_i + \mathcal{L}(u_i, y_i^*; \theta)) \rightarrow \min_{\theta, U_k},$$

$\mathcal{L}(x, y; \theta)$ — функция *стоимости* потерь для модели $a(x, \theta)$,

C_i — *стоимость* получения разметки $y_i^* = y(u_i)$,

$U_k \subset U$ — подмножество из k размечаемых объектов

Примеры приложений активного обучения

- сбор ассессорских данных для информационного поиска, анализа текстов, сигналов, речи, изображений, видео
- в том числе на платформах краудсорсинга
- *планирование экспериментов* в естественных науках или на производстве (пример — комбинаторная химия)
- оптимизация трудно вычислимых функций (пример — оптимизация гиперпараметров, AutoML)

Применения в бизнесе:

- управление ценами и ассортиментом в торговых сетях
- выбор товара для проведения маркетинговой акции
- проактивное взаимодействие с клиентами
- выборочный контроль качества
- выявление аномалий в данных, случаев мошенничества

Сэмплирование по неопределённости (uncertainty sampling)

Идея: выбирать u_i с наибольшей неопределённостью $a(u_i)$.

Задача многоклассовой классификации:

$$a(u) = \arg \max_{y \in Y} P(y|u)$$

$p_m(u)$, $m=1 \dots |Y|$ — ранжированные по убыванию $P(y|u)$, $y \in Y$.

- Принцип *наименьшей достоверности* (least confidence):

$$u_i = \arg \min_{u \in U} p_1(u)$$

- Принцип *наименьшей разности* (minimum margin):

$$u_i = \arg \min_{u \in U} (p_1(u) - p_2(u))$$

- Принцип *максимума энтропии* (maximum entropy):

$$u_i = \arg \min_{u \in U} \sum_m p_m(u) \ln p_m(u)$$


Сэмплирование по неуверенности (uncertainty sampling)

В случае двух классов эти три принципа эквивалентны.

В случае многих классов появляются различия.

Пример. Три класса, $p_1 + p_2 + p_3 = 1$.

Показаны линии уровня трёх критериев выбора объекта:



Сэмплирование по несогласию в комитете (query by committee)

Идея: выбирать u_i с наибольшей несогласованностью решений комитета моделей $a_t(u_i) = \arg \max_{y \in Y} P_t(y|u_i)$, $t = 1, \dots, T$.

- Принцип *максимума энтропии*:

выбираем u_i , на котором $a_t(u_i)$ максимально различны:

$$u_i = \arg \min_{u \in U} \sum_{y \in Y} \hat{p}(y|u) \ln \hat{p}(y|u),$$

где $\hat{p}(y|u) = \frac{1}{T} \sum_{t=1}^T [a_t(u) = y]$.

- Принцип *максимума средней KL-дивергенции*:

выбираем u_i , на котором $P_t(y|u_i)$ максимально различны:


$$u_i = \arg \max_{u \in U} \sum_{t=1}^T \text{KL}(P_t(y|u) \parallel \bar{P}(y|u)),$$

где $\bar{P}(y|u) = \frac{1}{T} \sum_{t=1}^T P_t(y|u)$ — консенсус комитета.

Сокращение пространства решений (version space reduction)

Идея: выбирать u_i , максимально сужая множество решений.

Пример. Пространства допустимых решений для линейных и пороговых классификаторов (двумерный случай):



Бустинг и бэггинг находят конечные подмножества решений. Поэтому сэмплирование по несогласию в комитете — это аппроксимация принципа сокращения пространства решений.

Ожидаемое изменение модели (expected model change)

Идея: выбрать u_i , который в методе стохастического градиента привёл бы к наибольшему изменению модели.

Параметрическая модель многоклассовой классификации:

$$a(u, \theta) = \arg \max_{y \in Y} P(y|u, \theta);$$

Для каждого $u \in U$ и $y \in Y$ оценим длину градиентного шага в пространстве параметров θ при дообучении модели на (u, y) ; пусть $\nabla_{\theta} \mathcal{L}(u, y; \theta)$ — вектор градиента функции потерь.

Принцип *максимума ожидаемой длины градиента*:

$$u_i = \arg \max_{u \in U} \sum_{y \in Y} P(y|u, \theta) \|\nabla_{\theta} \mathcal{L}(u, y; \theta)\|.$$

Ожидаемое сокращение ошибки (expected error reduction)

Идея: выбирать u_i , который после дообучения даст наиболее уверенную классификацию неразмеченной выборки $U \setminus u_i$.

Для каждого $u \in U$ и $y \in Y$ обучим модель классификации, добавив к размеченной обучающей выборке X^ℓ пример (u, y) :

$$a_{uy}(x) = \arg \max_{z \in Y} P_{uy}(z|x).$$

- Принцип *максимума уверенности на неразмеченных данных*:

$$u_i = \arg \max_{u \in U} \sum_{y \in Y} P(y|u) \sum_{u_j \in U \setminus u} P_{uy}(a_{uy}(u_j)|u_j).$$



- Принцип *минимума энтропии неразмеченных данных*:

$$u_i = \arg \max_{u \in U} \sum_{y \in Y} P(y|u) \sum_{u_j \in U \setminus u} \sum_{z \in Y} P_{uy}(z|u_j) \log P_{uy}(z|u_j).$$

Безградиентная оптимизация. Метод Нелдера–Мида

Идея: выбирать объекты u_i не из конечного пула, а из всего X , максимизируя $\max_{u \in X} \phi(u)$ любым безградиентным методом.

Метод Нелдера–Мида: перемещение и деформирование симплекса из $n + 1$ точек в пространстве X размерности n



J.A.Nelder, R.Mead. A simplex method for function minimization. 1965.

Метод Нелдера–Мида: «отражение–растяжение–сжатие»

повторять

сортировка $n + 1$ точек: $\phi(x_w) < \phi(x_o) < \dots < \phi(x_b)$;

центрoид грани x_c : по всем точкам кроме x_w ;

отражение: $x_r := x_c + \alpha(x_c - x_w)$;

если $\phi(x_b) < \phi(x_r)$ **то**

растяжение: $x_{exp} := x_c + \gamma(x_r - x_c)$;

$x_w := (\phi(x_r) < \phi(x_{exp})) ? x_{exp} : x_r$;

иначе если $\phi(x_w) < \phi(x_r) < \phi(x_b)$ **то** $x_w := x_r$;

иначе

сжатие: $x_{con} := x_c + \beta(x_w - x_c)$;


если $\phi(x_w) < \phi(x_{con})$ **то** $x_w := x_{con}$;

иначе

сжатие симплекса: $x_i := x_b + \sigma(x_i - x_b)$;

пока $\phi(x_w) \ll \phi(x_b)$;

Рекомендуемые параметры: $\alpha = 1$, $\beta = \frac{1}{2}$, $\gamma = 2$, $\sigma = \frac{1}{2}$



J.A.Nelder, R.Mead. A simplex method for function minimization. 1965.

Сокращение дисперсии (variance reduction)

Идея: выбирать $u \in X$, который даст наименьшую оценку дисперсии $E_x \sigma_{a(x)}^2$ после дообучения модели $a(x, \theta)$ на u .

Метод наименьших квадратов, линейная регрессия $a(x, \theta) = x^T \theta$:

$$S^2(\theta) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i, \theta) - y_i)^2 = \frac{1}{\ell} \|F\theta - y\|^2 \rightarrow \min_{\theta}$$

Из теории *оптимального планирования экспериментов* (OED, optimal experiment design):

$$\sigma_{a(x)}^2 \approx S^2 \left(\frac{\partial a(x)}{\partial \theta} \right)^T \left(\frac{\partial S^2}{\partial \theta^2} \right)^{-1} \left(\frac{\partial a(x)}{\partial \theta} \right) = S^2 x^T (F^T F)^{-1} x$$


Принцип *сокращения дисперсии* для линейной регрессии:

$$u = \arg \min_{u \in X} \sum_i x_i^T (F^T F + u^T u)^{-1} x_i$$

Взвешивание по плотности (density-weighted methods)

Идея: понижать вес нерепрезентативных объектов.

Пример. Объект A более пограничный, но менее репрезентативный, чем B.



Любой критерий выбора объектов, имеющий вид

$$u = \arg \max_{u \in U} \phi(u),$$

может быть уточнён локальной оценкой плотности:

$$u = \arg \max_{u \in U} \phi(u) \left(\sum_{u' \in U} \text{sim}(u, u') \right)^\beta,$$

$\text{sim}(u, u')$ — оценка близости u и u' (чем ближе, тем больше).

Необходимость изучающих действий в активном обучении

Недостатки стратегий активного обучения:

- остаются не обследованные области пространства X ,
- в результате снижается качество обучения,
- увеличивается время обучения.

Идея: применять изучающие (exploration) действия:

- брать случайный объект с вероятностью ϵ
- адаптировать параметр ϵ — уменьшать со временем, в зависимости от успешности изучающих действий
- можно использовать обучение с подкреплением (см. следующую лекцию)

Djallel Bouneffouf. Exponentiated gradient exploration for active learning. 2016.
Djallel Bouneffouf et al. Contextual bandit for active learning: active Thompson sampling. 2014.

Алгоритм ε -active

Алгоритм — обёртка над любой стратегией активного обучения

Вход: размеченная выборка $X^\ell = (x_i, y_i)_{i=1}^\ell$ и пул $U = (u_i)_{i=1}^K$;

Выход: модель a и размеченная выборка $(u_i, y_i^*)_{i=1}^k$;

обучить модель a по начальной выборке $(x_i, y_i)_{i=1}^\ell$;

пока есть неразмеченные объекты и модель не обучилась

выбрать $\begin{cases} u_i \text{ неразмеченный,} & \text{с вероятностью } \varepsilon; \\ u_i = \arg \max_{u \in U} \phi(u), & \text{с вероятностью } 1 - \varepsilon; \end{cases}$

узнать $y_i^* = y(u_i)$ для объекта u_i ;

дообучить модель a ещё на одном примере (u_i, y_i^*) ;

Проблема:

как подбирать вероятность ε исследовательских действий?

как её адаптировать (уменьшать) со временем?

Экспоненциальный градиент (Exponential Gradient)

$\varepsilon_1, \dots, \varepsilon_H$ — сетка значений параметра ε ;

$p_1, \dots, p_H$ — вероятности использовать значения $\varepsilon_1, \dots, \varepsilon_H$;

β, τ, κ — параметры метода.

Идея алгоритма EG-active: аналогично алгоритму AdaBoost, экспоненциально увеличивать p_h в случае успеха ε_h :

- экспоненциальное обновление весов w_h по значению критерия $\phi(u_i)$ на выбранном объекте u_i :

$$w_h := w_h \exp\left(\frac{\tau}{p_h}(\phi(u_i) + \beta)\right);$$

- перенормировка вероятностей:

$$p_h := (1 - \kappa) \frac{w_h}{\sum_j w_j} + \kappa \frac{1}{H}.$$

Алгоритм EG-active

Вход: $X^\ell = (x_i, y_i)_{i=1}^\ell$, $U = (u_i)_{i=1}^K$, параметры $\varepsilon_1, \dots, \varepsilon_H$, β , τ , κ ;

Выход: модель a и размеченная выборка $(u_i, y_i^*)_{i=1}^k$;

инициализация: $p_h := \frac{1}{H}$, $w_h := 1$;

обучить модель a по начальной выборке $(x_i, y_i)_{i=1}^\ell$;

пока есть неразмеченные объекты и модель не обучилась

выбрать h из дискретного распределения $(p_1, \dots, p_H)$;

выбрать $\begin{cases} u_i \text{ неразмеченный,} & \text{с вероятностью } \varepsilon_h; \\ u_i = \arg \max_{u \in U} \phi(u), & \text{с вероятностью } 1 - \varepsilon_h; \end{cases}$

узнать y_i^* для объекта u_i ;

дообучить модель a ещё на одном примере (u_i, y_i^*) ;


$w_h := w_h \exp\left(\frac{\tau}{p_h}(\phi(u_i) + \beta)\right)$;

$p_h := (1 - \kappa) \frac{w_h}{\sum_j w_j} + \kappa \frac{1}{H}$;

Активное обучение, когда аннотаторов много

y_{it} — ответы аннотаторов $t \in T$ на объекте u_i

Задача: сформировать согласованный ответ (консенсус) $\hat{y}_i$
и оценить надёжность каждого аннотатора $q_t = P[y_{it} = \hat{y}_i]$



Р.А.Гилязов, Д.Ю.Турдаков. Активное обучение и краудсорсинг: обзор методов оптимизации разметки данных. 2018.

Согласование оценок аннотаторов

$y_{it} \in Y$ — ответ аннотатора $t \in T$ на объекте u_i

$T_i \subseteq T$ — множество аннотаторов, разметивших объект u_i

Консенсус — взвешенное голосование аннотаторов:

$$\hat{y}_i = \arg \max_{y \in Y} \sum_{t \in T_i} w_t [y_{it} = y]$$

w_t — вес аннотатора при голосовании, например,

$w_t = 1$ при голосовании по большинству (majority voting, MV)

$w_t = \log \frac{q_t}{1-q_t}$ при предположении, что аннотаторы независимы

ЕМ-like алгоритм согласования аннотаций объекта u_i :

пока оценки не сойдутся

 оценить консенсус $\hat{y}_i$;

 надёжности $q_t := P[y_{it} = \hat{y}_i]$ и веса w_t аннотаторов;

если $q_t < \delta$ **то** исключить аннотатора из оценки;

Варианты моделирования надёжности аннотаторов

- По результатам выполнения тестовых заданий.
- Моделирование матрицы ошибок $|Y| \times |Y|$:

$$\pi_{yz}^t = P[\text{аннотатор } t \text{ ставит } z \text{ вместо } y], \quad y, z \in Y$$

- Моделирование трудности объектов:

$$q_t(u_i) = \sigma\left(\frac{\alpha_t}{\beta_i}\right) = \frac{1}{1 + \exp(-\frac{\alpha_t}{\beta_i})},$$

α_t — частотная оценка надёжности аннотатора t ;

β_i — оценка трудности объекта u_i (по большому $|T_i|$).

- Моделирование тематической компетентности аннотаторов:
 $p(\text{topic}|u_i)$ — тематическое векторное представление объекта u_i , например, если объект является текстом

Р.А.Гилязов, Д.Ю.Турдаков. Активное обучение и краудсорсинг: обзор методов оптимизации разметки данных. 2018.

Задача назначения заданий аннотаторам

Общая схема распределения заданий:

$$\begin{cases} u_i = \arg \max_{u \in U} \phi(u) & \text{— выбор неразмеченного объекта в AL} \\ t = \arg \max_{t \in T} q_t(u_i) & \text{— выбор наиболее уверенного аннотатора} \end{cases}$$

Обучение вероятностной модели уверенности аннотатора

$q_t(u_i, \theta_t) = \sigma(\theta_t^\top u_i)$ на размеченных им объектах U_t :

$$\sum_{u_i \in U_t} [y_{it} = \hat{y}_i] \ln q_t(u_i, \theta_t) + [y_{it} \neq \hat{y}_i] \ln(1 - q_t(u_i, \theta_t)) \rightarrow \max_{\theta_t}$$

Недостаток: одни аннотаторы будут выбираться слишком часто, другие не будут выбираться совсем

Сэмплирование аннотаторов: $t \sim q_t(u_i)p(t)$ с учётом априорной информации $p(t)$ о средней надёжности q_t , компетенции, доступности, загруженности, плане работ.

Пример. Разметка текстов в конкурсе ПРО//ЧТЕНИЕ

Задача: поиск смысловых ошибок в сочинениях ЕГЭ по русскому, литературе, обществознанию, истории, английскому

Алгоритм должен выделять
ошибки и давать их объяснения

Типов ошибок: 152

(р:70 л:16 о:23 и:20 а:23)

Подтипов ошибок: 236


(р:112 л:19 о:29 и:26 а:50)

Призовой фонд:

— 100М руб. русский язык

— 100М руб. английский язык

Период: дек 2019 – дек 2022



Технический регламент конкурса ПРО//ЧТЕНИЕ: <http://ai.upgreat.one>

Оценивание модели разметки по нескольким аннотаторам

$\text{Con}_k(a_i, y_{it})$ — меры согласованности разметок алгоритма a_i и экспертов y_{it} после оптимального сопоставления их фрагментов

$\text{Con}(a_i, y_{it})$ — средневзвешенная согласованность разметок

- *Средняя Точность Алгоритмической Разметки:*

$$\text{CTAP}(a) = \text{mean}_{x_i \in X^\ell} \text{mean}_{t \in T_i} \text{Con}(a_i, y_{it})$$

- *Средняя Точность Экспертных Разметок:*

$$\text{CTЭР} = \text{mean}_{x_i \in X^\ell} \text{mean}_{t, s \in T_i} \text{Con}(y_{it}, y_{is})$$

- *Относительная Точность Алгоритмической Разметки:*

$$\text{OTAP}(a) = \frac{\text{CTAP}(a)}{\text{CTЭР}}$$

Условие преодоления технологического барьера в конкурсе:

$\text{OTAP} \geq 1$ означает, что алгоритм работает не хуже экспертов

- Активное обучение используется для уменьшения обучающей выборки, когда размеченные данные дороги
- При малом объёме размеченных данных оно достигает того же качества, что пассивное при полной разметке
- Два основных типа активного обучения:
выбор объектов из пула и синтез новых объектов
- Введение изучающих действий в активном обучении позволяет быстрее обследовать пространство объектов
- Модели надёжности аннотаторов и трудности заданий позволяют лучше распределять задания в краудсорсинге
- Разметка каждого объекта несколькими аннотаторами позволяет оценить «естественный уровень шума» в задаче

Роберт (Манро) Монарх. Машинное обучение с участием человека. 2022

Burr Settles. Active learning literature survey. 2010

P.Kumar, A.Gupta. Active learning query strategies for classification, regression, and clustering: a survey. 2020

C.C.Aggarwal et al. Active learning: a survey. 2014

Pengzhen Ren et al. A survey of deep active learning. 2020