Методы машинного обучения. Обучение без учителя: кластеризация и частичное обучение

Воронцов Константин Вячеславович
www.MachineLearning.ru/wiki?title=User:Vokov
вопросы к лектору: k.vorontsov@iai.msu.ru

материалы курса:
github.com/MSU-ML-COURSE/ML-COURSE-25-26
орг.вопросы по курсу: ml.cmc@mail.ru

ВМК МГУ • 24 февраля 2026

Содержание

1. **Задачи кластеризации и частичного обучения**
   - Задача кластеризации
   - Задача частичного обучения
   - Критерии качества кластеризации
2. **Алгоритмы кластеризации**
   - Метод K-средних
   - Алгоритм DBSCAN
   - Иерархические методы
3. **Частичное обучение на основе классификации**
   - Обёртки над методами классификации
   - Трансдуктивный SVM
   - Регуляризация правдоподобия

Неформальная постановка задачи кластеризации

Дано:

X — пространство объектов;
$X^\ell = \{x_1, \ldots, x_\ell\}$ — обучающая выборка;
$\rho\colon X \times X \to [0, \infty)$ — функция расстояния между объектами.

Найти:

Y — множество кластеров,
$a\colon X \to Y$ — алгоритм кластеризации,
такие, что:
— каждый кластер состоит из близких объектов;
— объекты разных кластеров существенно различны.

Это задача *обучения без учителя* (unsupervised learning).

Критерий?

Некорректность постановки задачи кластеризации

Решение задачи кластеризации принципиально неоднозначно:

- точной постановки задачи кластеризации нет;
- существует много критериев качества кластеризации;
- существует много эвристических методов кластеризации;
- число кластеров $|Y|$, как правило, заранее не известно;
- результат кластеризации сильно зависит от метрики ρ, выбор которой также является эвристикой.

Пример: сколько здесь кластеров?

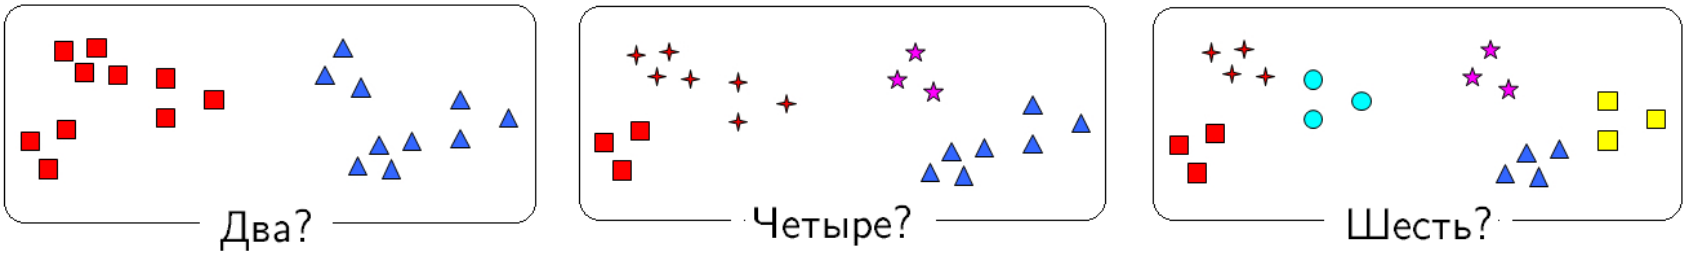

Цели кластеризации

- **Упростить дальнейшую обработку данных**,
  разбить выборку X^ℓ на подвыборки схожих объектов,
  далее работать с ними по принципу «разделяй и властвуй»
  (в задачах классификации, регрессии, прогнозирования)
- **Сократить объём хранимых данных**,
  оставив по одному представителю от каждого кластера,
  получить максимально представительную подвыборку
- **Выделить нетипичные объекты**,
  которые не подходят ни к одному из кластеров
  (выделение аномалий, одноклассовая классификация)
- **Построить иерархию множества объектов,**
  пример — классификация животных и растений К.Линнея
  (задачи таксономии, иерархической кластеризации)

Типы кластерных структур

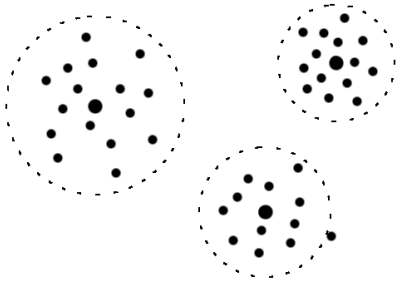

кластеры с центрами

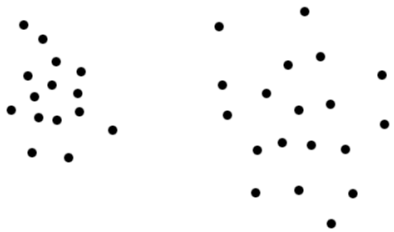

внутрикластерные расстояния меньше межкластерных

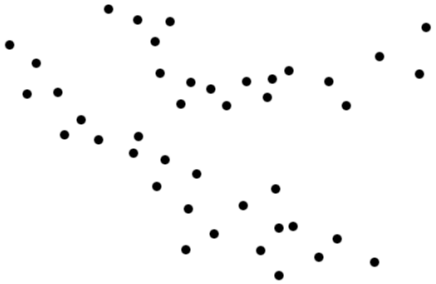

ленточные кластеры

Типы кластерных структур

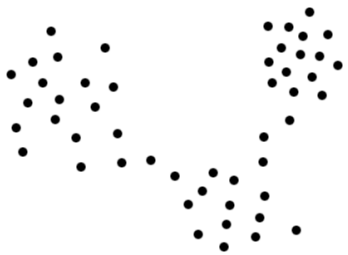

перемычки между кластерами

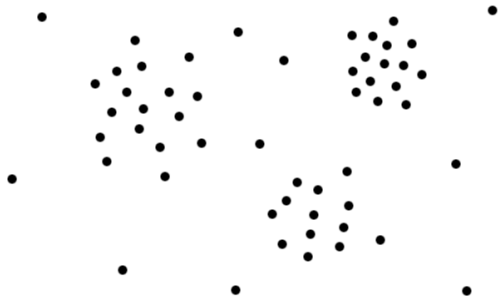

разреженный фон
из нетипичных объектов

перекрывающиеся кластеры

Типы кластерных структур

кластеры могут вообще отсутствовать

а это вообще не кластеры
и на практике такое не встречается

- Каждый метод кластеризации имеет свои ограничения и выделяет кластеры лишь некоторых типов.
- Понятие «тип кластерной структуры» зависит от метода и также не имеет формального определения.

Проблема чувствительности к выбору метрики

Результат зависит от нормировки признаков:

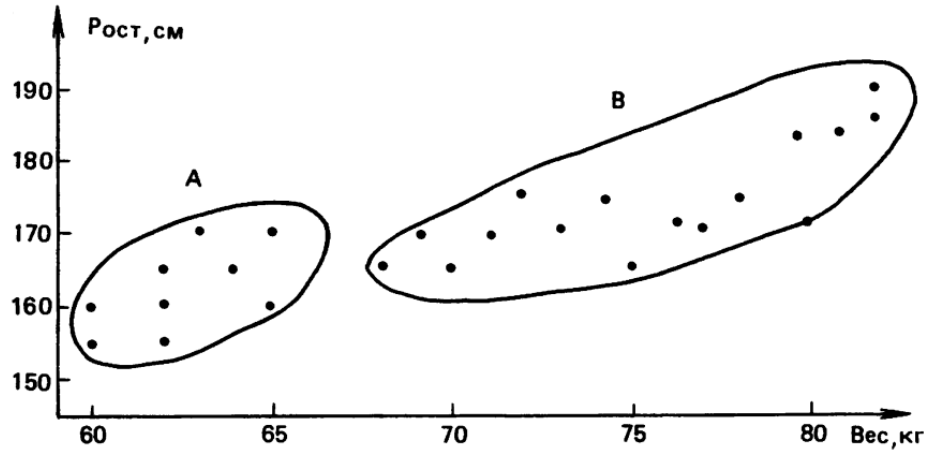

A — студентки,
B — студенты

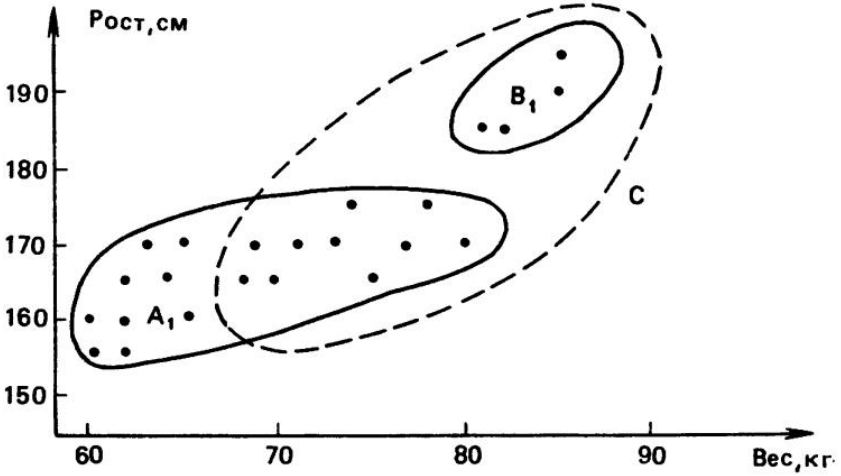

после перенормировки
(сжали ось «вес» вдвое)

Постановка задачи частичного обучения (SSL)

Дано:

множество объектов X, множество классов Y;

$X^k = \{x_1, \ldots, x_k\}$ — размеченные объекты (labeled data);
$\{y_1, \ldots, y_k\}$

$U = \{x_{k+1}, \ldots, x_\ell\}$ — неразмеченные объекты (unlabeled data).

Найти: (два варианта постановки задачи)

- алгоритм классификации $a\colon X \to Y$
  — задача *частичного обучения* (semi-supervised learning)
- метки $\{a_{k+1}, \ldots, a_\ell\}$ объектов $\{x_{k+1}, \ldots, x_\ell\}$
  — задача *трансдуктивного обучения* (transductive learning)

Типичные приложения:

классификация и каталогизация текстов, изображений, и т. п.

SSL не сводится к классификации

Пример 1. плотности классов, восстановленные:

по размеченным данным X^k

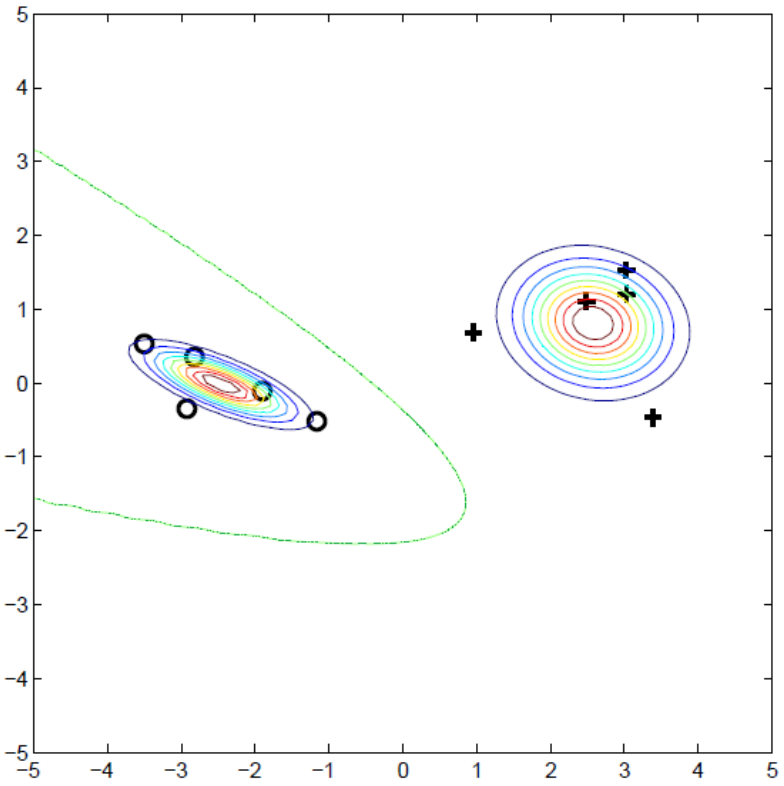

по полным данным X^ℓ

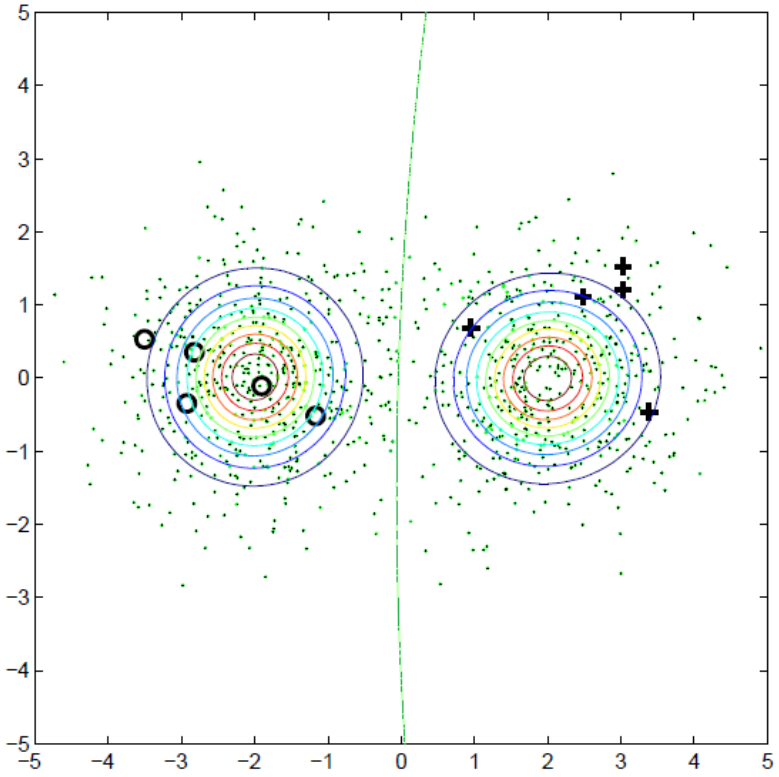

SSL не сводится к классификации

Пример 2. Методы классификации не учитывают кластерную структуру неразмеченных данных

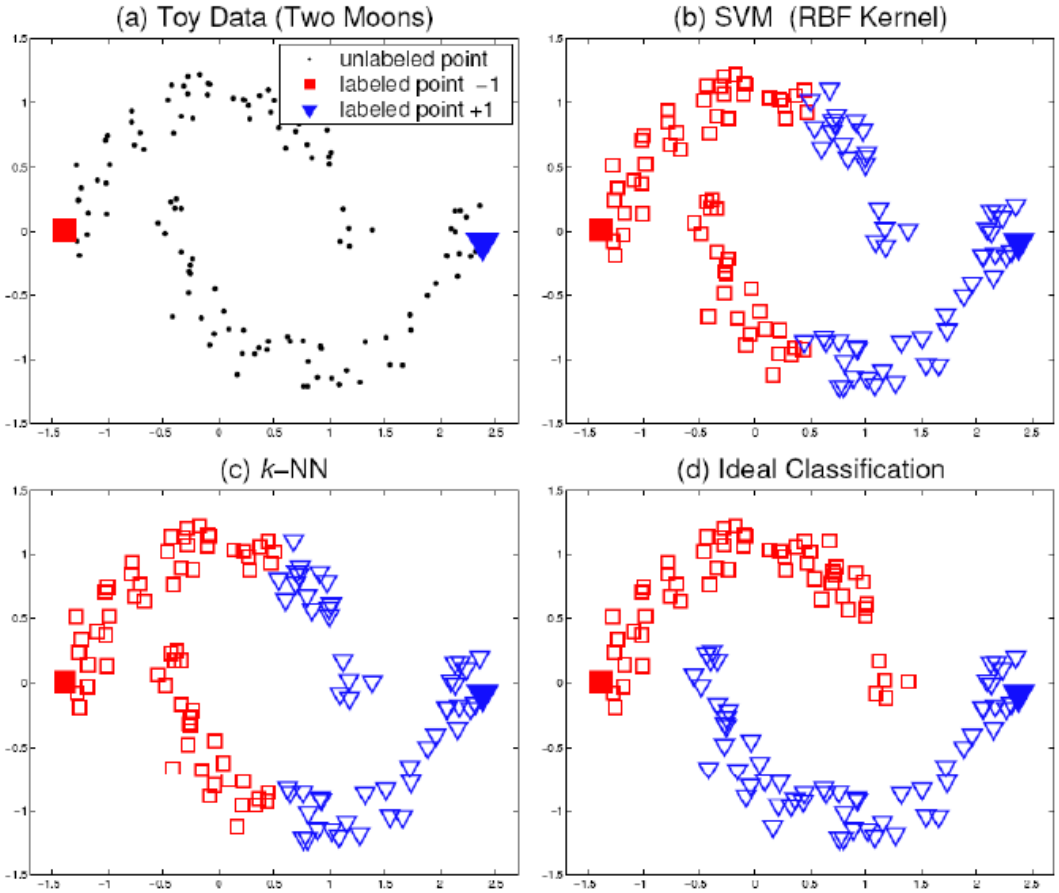

Однако и к кластеризации SSL также не сводится

Пример 3. Методы кластеризации не учитывают приоритетность разметки над кластерной структурой.

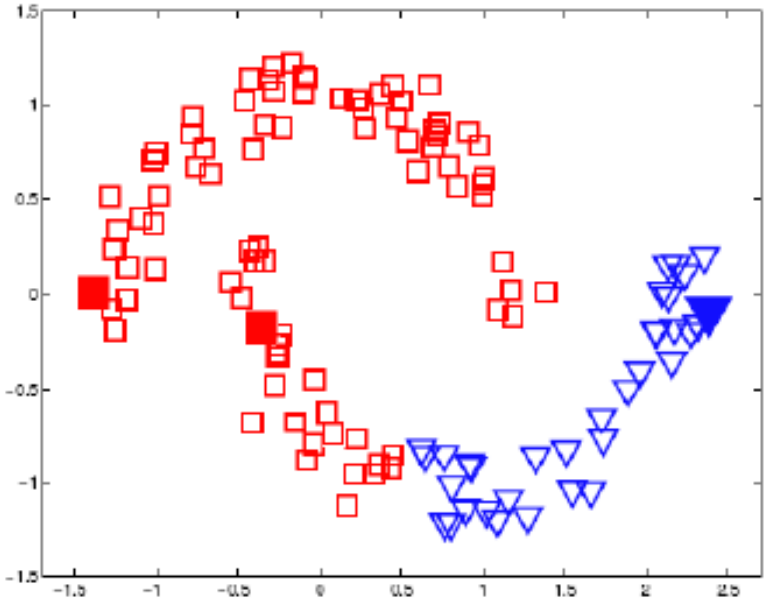

Качество кластеризации в метрическом пространстве

Пусть известны только попарные расстояния между объектами.
$a_i = a(x_i)$ — кластеризация объекта x_i

- Среднее внутрикластерное расстояние:

$$F_0 = \frac{\sum\limits_{i<j} [a_i = a_j]\, \rho(x_i, x_j)}{\sum\limits_{i<j} [a_i = a_j]} \to \min .$$

- Среднее межкластерное расстояние:

$$F_1 = \frac{\sum\limits_{i<j} [a_i \neq a_j]\, \rho(x_i, x_j)}{\sum\limits_{i<j} [a_i \neq a_j]} \to \max .$$

- Отношение пары функционалов: $F_0 / F_1 \to \min$.

Качество кластеризации в линейном векторном пространстве

Пусть объекты x_i задаются векторами $\big(f_1(x_i), \ldots, f_n(x_i)\big)$.

- Сумма средних внутрикластерных расстояний:

$$\Phi_0 = \sum_{a \in Y} \frac{1}{|X_a|} \sum_{x_i \in X_a} \rho(x_i, \mu_a) \to \min,$$

$X_a = \{x_i \in X^\ell \mid a_i = a\}$ — кластер a,
$\mu_a = \frac{1}{|X_a|} \sum\limits_{x_i \in X_a} x_i$ — центр масс кластера a.

- Сумма межкластерных расстояний:

$$\Phi_1 = \sum_{a,b \in Y} \rho(\mu_a, \mu_b) \to \max.$$

- Отношение пары функционалов: $\Phi_0 / \Phi_1 \to \min$.

Коэффициент силуэта (анализ ошибок кластеризации)

Распределение качества кластеризации по объектам/кластерам

- Среднее расстояние от объекта x_i до объектов x того же кластера X_{a_i}:

$$r_i = \frac{1}{|X_{a_i}| - 1} \sum_{x \in X_{a_i} \setminus x_i} \rho(x, x_i)$$

- Мин. ср.расстояние до чужого кластера:

$$R_i = \min_{a \in Y \setminus a_i} \frac{1}{|X_a|} \sum_{x \in X_a} \rho(x, x_i)$$

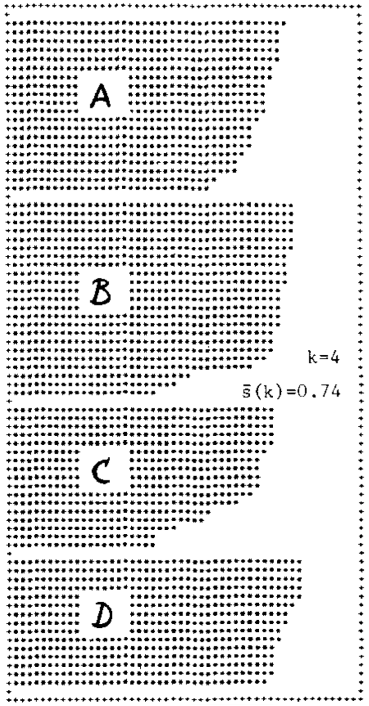

- Коэффициент силуэта объекта: $s(i) = \frac{R_i - r_i}{\max(R_i, r_i)} \in [-1, +1]$

Peter J. Rousseeuw. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. 1987.

Точность и полнота кластеризации в сравнении с эталоном

$y_i \in Y_0$ — эталонная классификация объектов, $i = 1, \ldots, \ell$
Проблема: мощности $|Y_0|$ и $|Y|$ могут не совпадать

$P_i = \{k \colon a_k = a_i\}$ — кластер объекта x_i
$Q_i = \{k \colon y_k = y_i\}$ — эталонный класс объекта x_i

BCubed-меры точности и полноты кластеризации:

$$\text{Precision} = \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{|P_i \cap Q_i|}{|P_i|} \text{ — средняя точность}$$

$$\text{Recall} = \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{|P_i \cap Q_i|}{|Q_i|} \text{ — средняя полнота}$$

$$F_1 = \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{2|P_i \cap Q_i|}{|P_i| + |Q_i|} \text{ — средняя } F_1\text{-мера}$$

E.Amigo, J.Gonzalo, J.Artiles, F.Verdejo. A comparison of extrinsic clustering evaluation metrics based on formal constraints. 2009.

Метод кластеризации K-средних (K-means): постановка задачи

Дано: $X^\ell = \{x_1, \ldots, x_\ell\}$ — обучающая выборка, $x_i \in \mathbb{R}^n$

Найти:

— центры кластеров — параметры $\mu_a \in \mathbb{R}^n$, $a = 1, \ldots, K$

— какому кластеру принадлежит каждый объект $a_i \in \{1, \ldots, K\}$

Критерий: минимум суммы внутрикластерных расстояний

$$\sum_{i=1}^{\ell} \|x_i - \mu_{a_i}\|^2 \to \min_{\{a_i\},\,\{\mu_a\}}$$

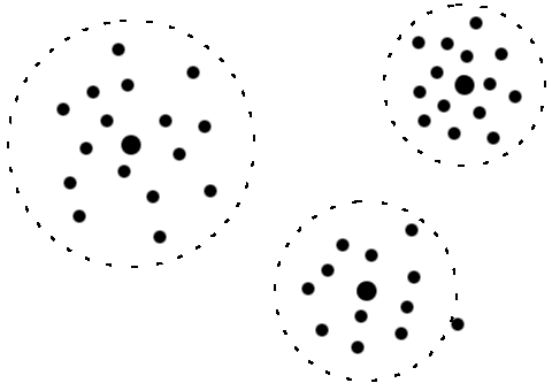

Метрика, как правило, евклидова (но может быть и другая):

$$\|x - \mu_a\|^2 = \sum_{d=1}^{n} \big(f_d(x) - \mu_{ad}\big)^2$$

Метод K-средних: алгоритм Ллойда

Минимизация суммы квадратов внутрикластерных расстояний:

$$\sum_{i=1}^{\ell} \|x_i - \mu_{a_i}\|^2 \to \min_{\{a_i\},\,\{\mu_a\}}, \quad \|x_i - \mu_a\|^2 = \sum_{j=1}^{n} \big(f_j(x_i) - \mu_{aj}\big)^2$$

Алгоритм Ллойда

вход: X^ℓ, $K = |Y|$; **выход:** центры кластеров μ_a, $a \in Y$;

$\mu_a :=$ начальное приближение центров, для всех $a \in Y$;

повторять

отнести каждый x_i к ближайшему центру:

$a_i := \arg\min\limits_{a \in Y} \|x_i - \mu_a\|, \quad i = 1, \ldots, \ell;$

вычислить новые положения центров:

$$\mu_a := \frac{\sum_{i=1}^{\ell} [a_i = a] x_i}{\sum_{i=1}^{\ell} [a_i = a]}, \quad a \in Y;$$

пока a_i не перестанут изменяться;

Метод K-средних для частичного обучения

Модификация алгоритма Ллойда

при наличии размеченных объектов $\{x_1, \ldots, x_k\}$

вход: X^ℓ, $K = |Y|$;
выход: центры кластеров μ_a, $a \in Y$;

$\mu_a :=$ начальное приближение центров, для всех $a \in Y$;
повторять
  отнести каждый $x_i \in U$ к ближайшему центру:
  $a_i := \arg\min\limits_{a \in Y} \|x_i - \mu_a\|, \quad i = k+1, \ldots, \ell$;
  вычислить новые положения центров:
  $$\mu_a := \frac{\sum_{i=1}^{\ell} [a_i = a] x_i}{\sum_{i=1}^{\ell} [a_i = a]}, \quad a \in Y;$$
пока a_i не перестанут изменяться;

Примеры неудачной кластеризации k-means

Причина — неудачное начальное приближение или форма кластеров, существенно отличная от сферической

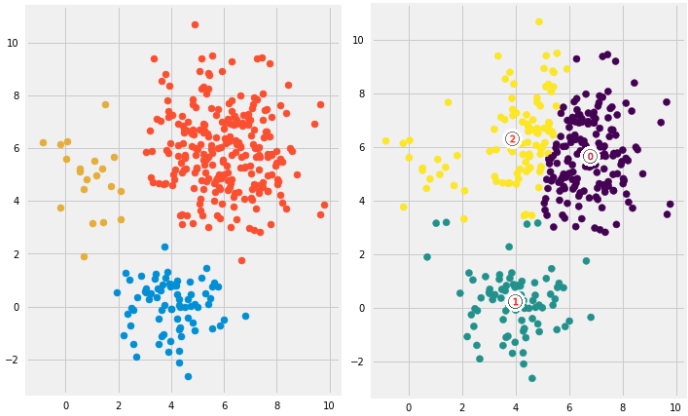

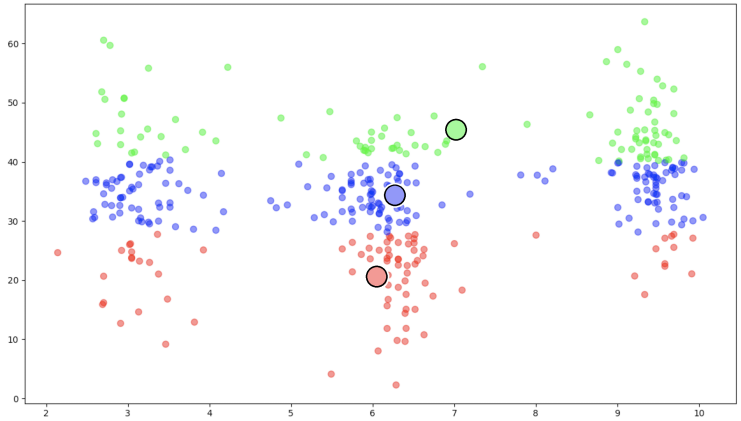

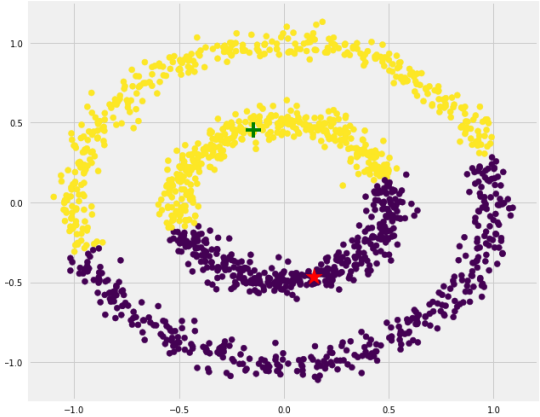

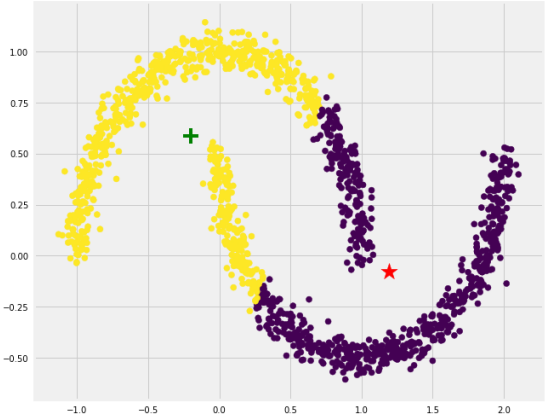

Алгоритм кластеризации DBSCAN

(Density-Based Spatial Clustering of Applications with Noise)

Объект $x \in U$, его ε-окрестность $U_\varepsilon(x) = \{u \in U \colon \rho(x,u) \leqslant \varepsilon\}$

Каждый объект может быть одного из трёх типов:

- корневой: имеющий плотную окрестность, $|U_\varepsilon(x)| \geqslant m$
- граничный: не корневой, но в окрестности корневого
- шумовой (выброс): не корневой и не граничный

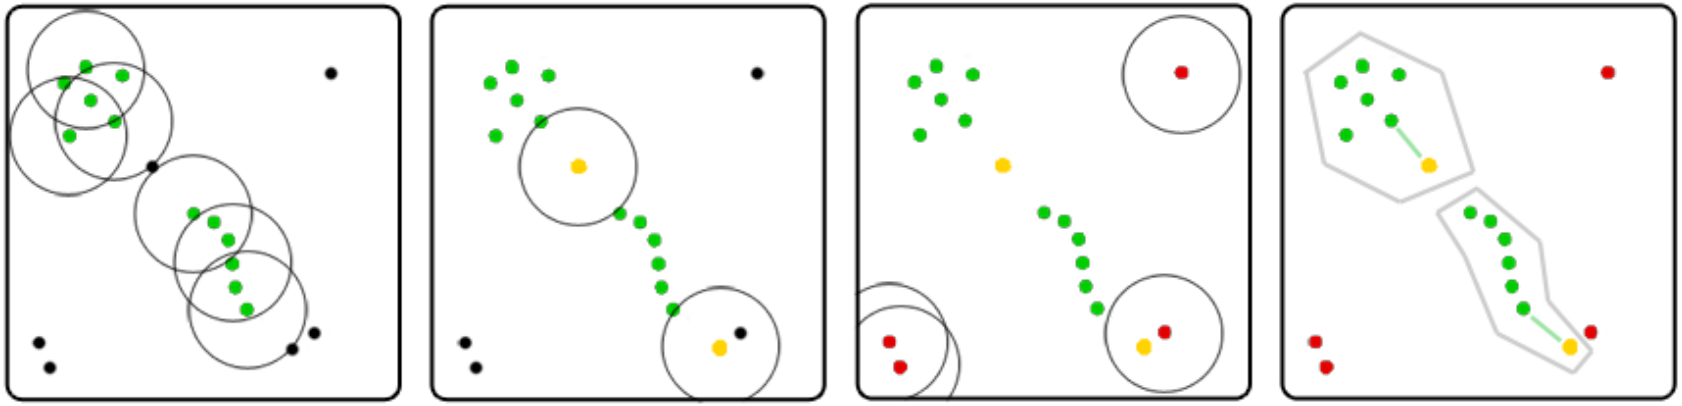

Ester, Kriegel, Sander, Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. KDD-1996.

Алгоритм кластеризации DBSCAN

вход: выборка $X^\ell = \{x_1, \ldots, x_\ell\}$; параметры ε и m;
выход: разбиение выборки на кластеры и шумовые выбросы;
$U := X^\ell$ — непомеченные; $a := 0$;
пока в выборке есть непомеченные точки, $U \neq \varnothing$:
  взять случайную точку $x \in U$;
  если $|U_\varepsilon(x)| < m$ **то**
    пометить x как, возможно, шумовой;
  иначе
    создать новый кластер: $K := U_\varepsilon(x)$; $a := a + 1$;
    для всех $x' \in K$, не помеченных или шумовых
      если $|U_\varepsilon(x')| \geqslant m$ **то** $K := K \cup U_\varepsilon(x')$;
      иначе пометить x' как граничный кластера K;
    $a_i := a$ для всех $x_i \in K$;
    $U := U \setminus K$;

Преимущества алгоритма DBSCAN

- быстрая кластеризация больших данных:
  $O(\ell^2)$ в худшем случае,
  $O(\ell \ln \ell)$ при эффективной реализации $U_\varepsilon(x)$;
- кластеры произвольной формы (долой центры!);
- деление объектов на корневые, граничные, шумовые.

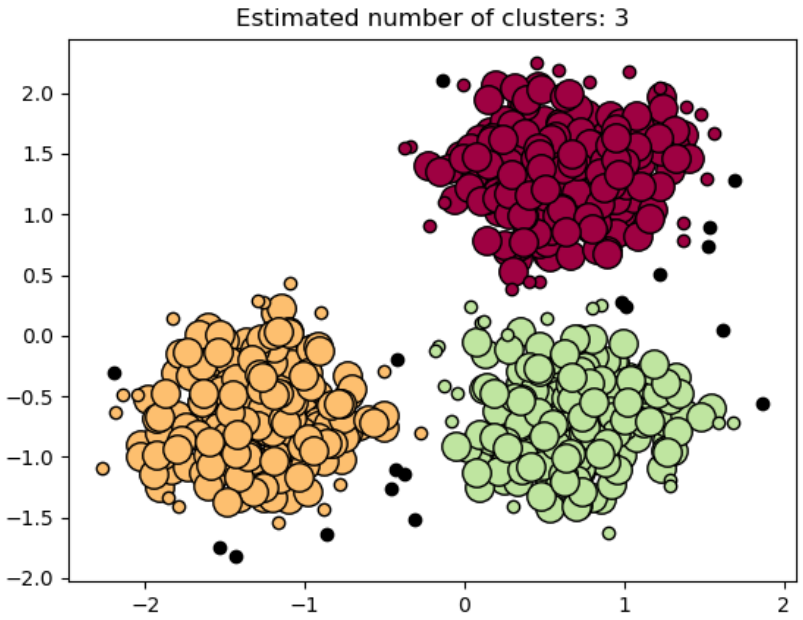

Агломеративная иерархическая кластеризация

Алгоритм иерархической кластеризации (Ланс, Уильямс, 1967): итеративный пересчёт расстояний R_{UV} между кластерами U, V.

$C_1 := \{\{x_1\}, \ldots, \{x_\ell\}\}$ — все кластеры 1-элементные;
$R_{\{x_i\}\{x_j\}} := \rho(x_i, x_j)$ — расстояния между ними;
для всех $t = 2, \ldots, \ell$ (t — номер итерации):
- найти в C_{t-1} пару кластеров (U, V) с минимальным R_{UV};
- слить их в один кластер:
- $W := U \cup V$;
- $C_t := C_{t-1} \cup \{W\} \setminus \{U, V\}$;
- **для всех** $S \in C_t$
  - вычислить R_{WS} по формуле Ланса-Уильямса:
  - $R_{WS} := \alpha_U R_{US} + \alpha_V R_{VS} + \beta R_{UV} + \gamma \left| R_{US} - R_{VS} \right|$;

Алгоритм Ланса-Уильямса для частичного обучения

Алгоритм иерархической кластеризации (Ланс, Уильямс, 1967): итеративный пересчёт расстояний R_{UV} между кластерами U, V.

$C_1 := \{\{x_1\}, \ldots, \{x_\ell\}\}$ — все кластеры 1-элементные;
$R_{\{x_i\}\{x_j\}} := \rho(x_i, x_j)$ — расстояния между ними;
для всех $t = 2, \ldots, \ell$ (t — номер итерации):
- найти в C_{t-1} пару кластеров (U, V) с минимальным R_{UV},
  при условии, что в $U \cup V$ нет объектов с разными метками;
- слить их в один кластер:
  $W := U \cup V$;
  $C_t := C_{t-1} \cup \{W\} \setminus \{U, V\}$;
  для всех $S \in C_t$
  - вычислить R_{WS} по формуле Ланса-Уильямса:
    $R_{WS} := \alpha_U R_{US} + \alpha_V R_{VS} + \beta R_{UV} + \gamma \left| R_{US} - R_{VS} \right|$;

Частные случаи формулы Ланса-Уильямса

1. Расстояние ближнего соседа:

$$R^{б}_{WS} = \min_{w \in W, s \in S} \rho(w, s);$$

$$\alpha_U = \alpha_V = \tfrac{1}{2}, \;\; \beta = 0, \;\; \gamma = -\tfrac{1}{2}.$$

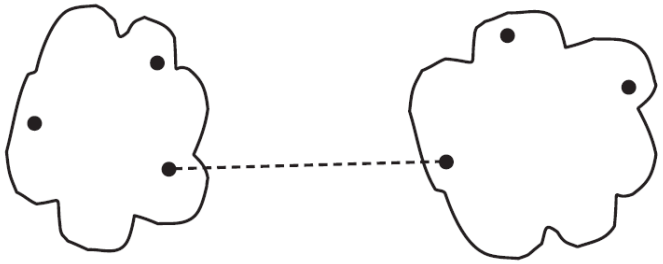

2. Расстояние дальнего соседа:

$$R^{д}_{WS} = \max_{w \in W, s \in S} \rho(w, s);$$

$$\alpha_U = \alpha_V = \tfrac{1}{2}, \;\; \beta = 0, \;\; \gamma = \tfrac{1}{2}.$$

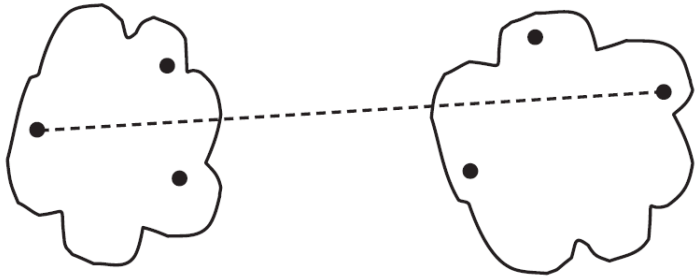

3. Групповое среднее расстояние:

$$R^{г}_{WS} = \frac{1}{|W||S|} \sum_{w \in W} \sum_{s \in S} \rho(w, s);$$

$$\alpha_U = \frac{|U|}{|W|}, \;\; \alpha_V = \frac{|V|}{|W|}, \;\; \beta = \gamma = 0.$$

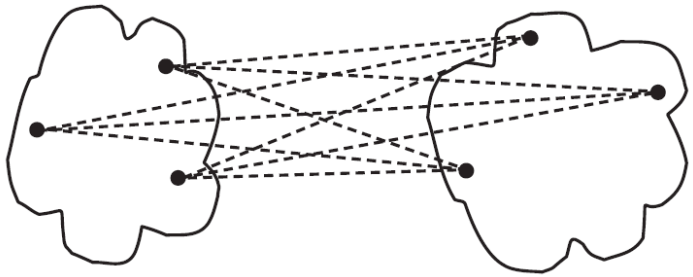

Частные случаи формулы Ланса-Уильямса

4. Расстояние между центрами:

$$R^{ц}_{WS} = \rho^2\Big(\sum_{w\in W}\frac{w}{|W|}, \sum_{s\in S}\frac{s}{|S|}\Big);$$

$$\alpha_U = \frac{|U|}{|W|}, \quad \alpha_V = \frac{|V|}{|W|},$$

$$\beta = -\alpha_U\alpha_V, \quad \gamma = 0.$$

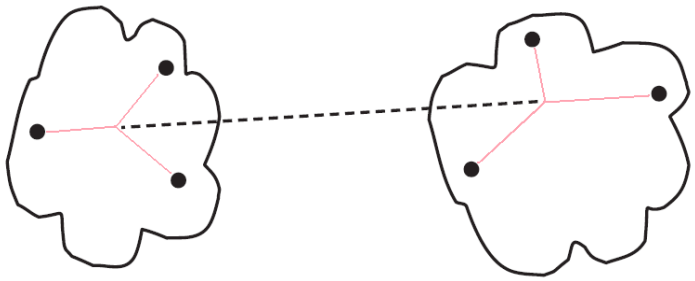

5. Расстояние Уорда:

$$R^{у}_{WS} = \frac{|S||W|}{|S|+|W|}\,\rho^2\Big(\sum_{w\in W}\frac{w}{|W|}, \sum_{s\in S}\frac{s}{|S|}\Big);$$

$$\alpha_U = \frac{|S|+|U|}{|S|+|W|}, \quad \alpha_V = \frac{|S|+|V|}{|S|+|W|}, \quad \beta = \frac{-|S|}{|S|+|W|}, \quad \gamma = 0.$$

Проблема выбора

Какая функция расстояния лучше?

Визуализация кластерной структуры

1. Расстояние ближнего соседа:

Диаграмма вложения

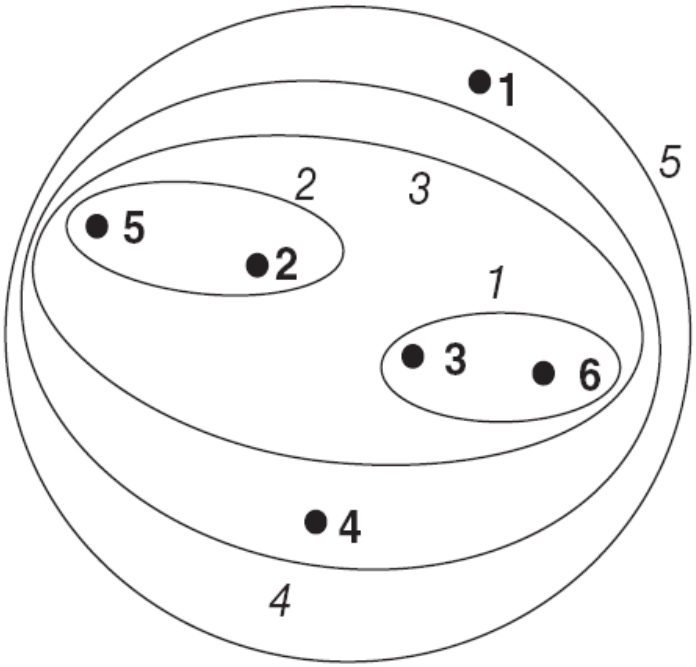

Дендрограмма

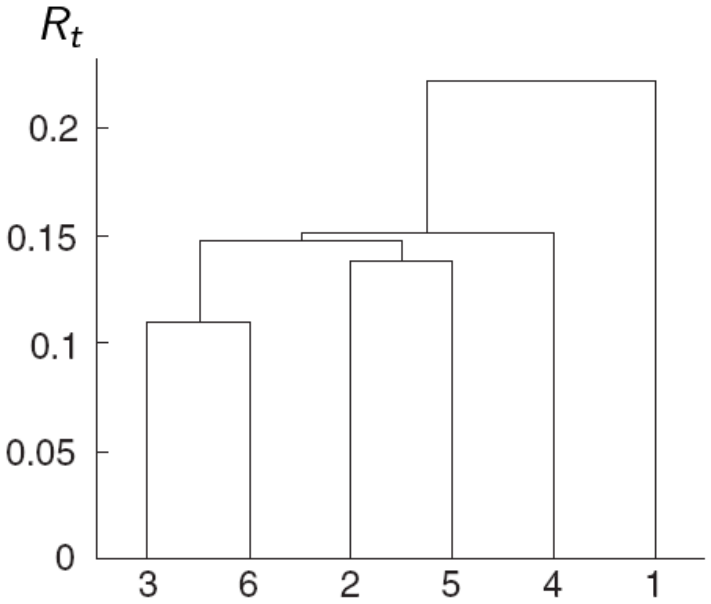

Визуализация кластерной структуры

2. Расстояние дальнего соседа:

Диаграмма вложения

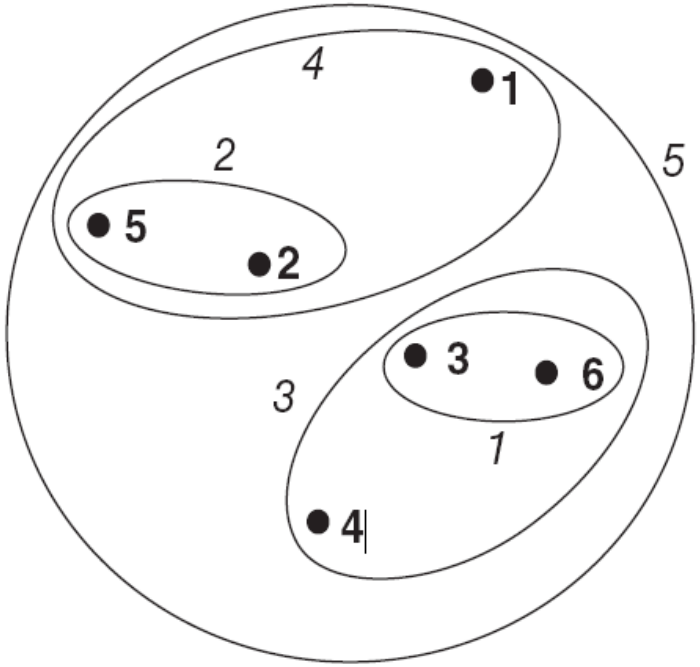

Дендрограмма

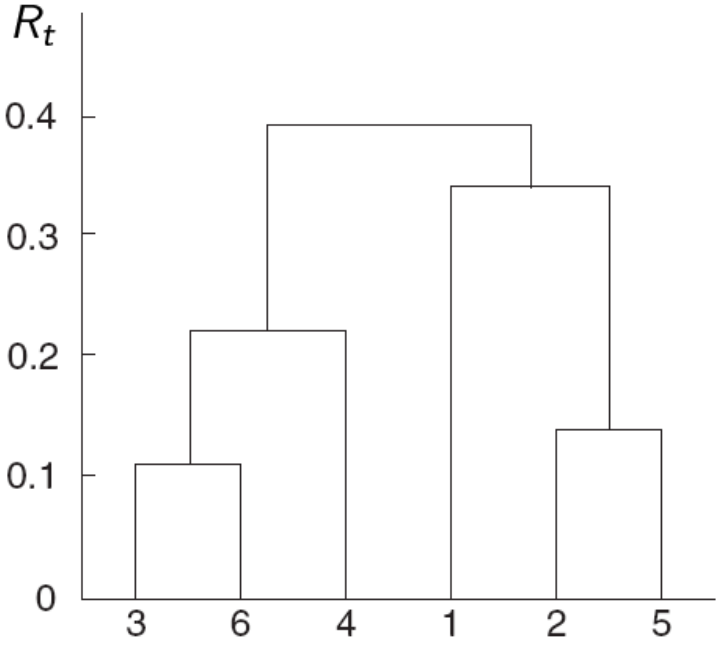

Визуализация кластерной структуры

3. Групповое среднее расстояние:

Диаграмма вложения

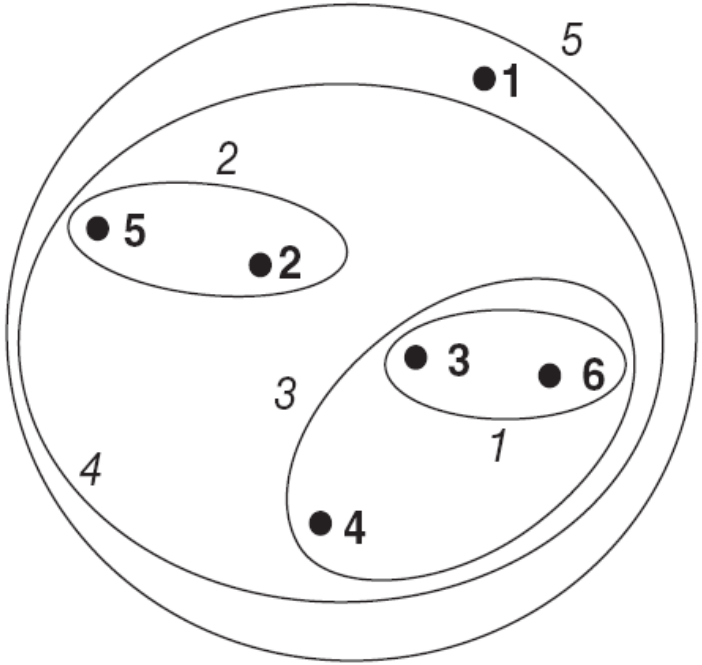

Дендрограмма

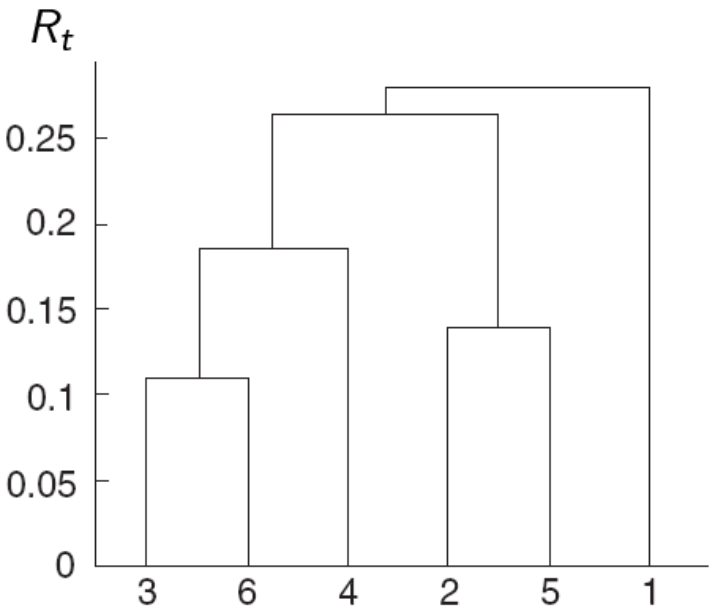

Визуализация кластерной структуры

5. Расстояние Уорда:

Диаграмма вложения

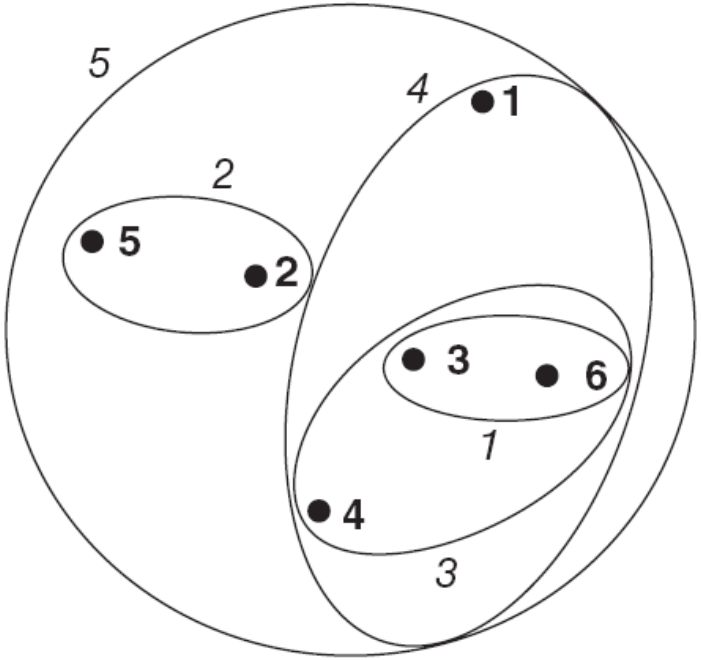

Дендрограмма

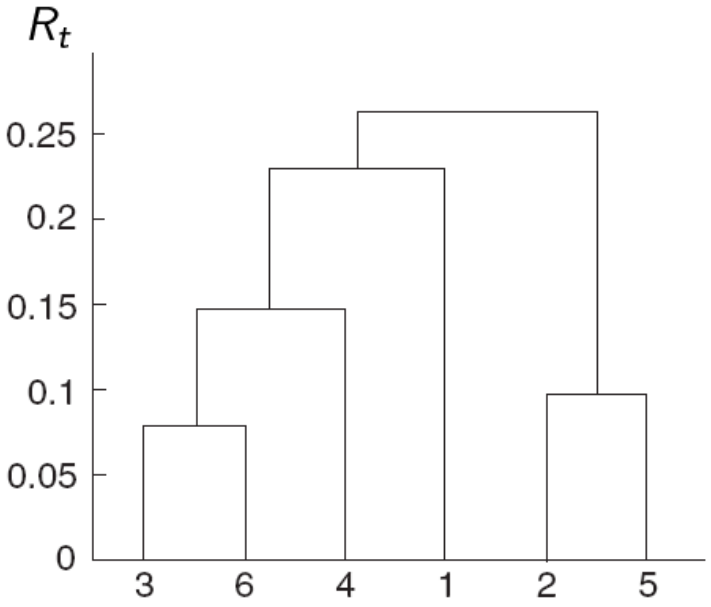

Дендрограмма — визуализация иерархической кластеризации

- Кластеры группируются вдоль горизонтальной оси
- По вертикальной оси откладываются расстояния R_t
- Расстояния возрастают, линии нигде не пересекаются
- Верхние уровни различимы лучше, чем нижние
- Уровень отсечения определяет число кластеров

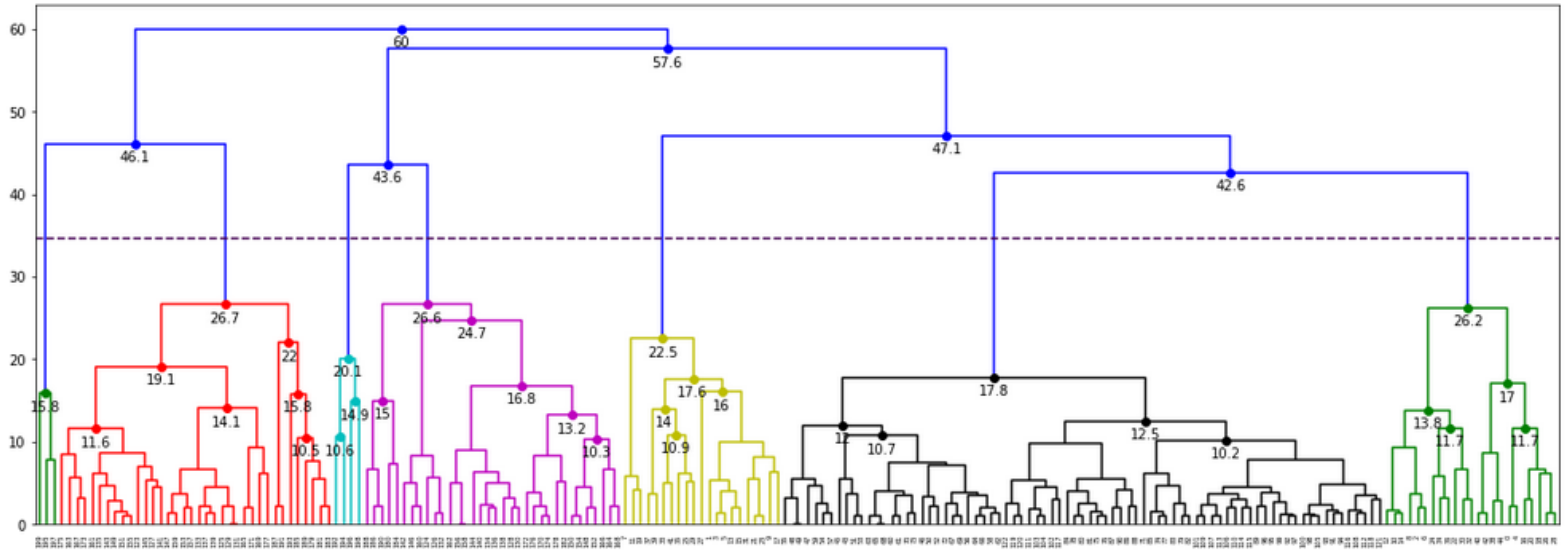

Основные свойства иерархической кластеризации

- *Монотонность*: дендрограмма не имеет самопересечений, при каждом слиянии расстояние между объединяемыми кластерами только увеличивается: $R_2 \leqslant R_3 \leqslant \ldots \leqslant R_\ell$.
- *Растягивающее расстояние*: разности $|R_{t+1} - R_t|$ растут
- *Сжимающее расстояние*: разности $|R_{t+1} - R_t|$ сокращаются

Теорема (Миллиган, 1979)

Кластеризация монотонна, если выполняются условия

$$\alpha_U \geqslant 0, \quad \alpha_V \geqslant 0, \quad \alpha_U + \alpha_V + \beta \geqslant 1, \quad \min\{\alpha_U, \alpha_V\} + \gamma \geqslant 0.$$

$R^{\text{ц}}$ не монотонно; $R^{\text{б}}$, $R^{\text{д}}$, $R^{\text{г}}$, $R^{\text{у}}$ — монотонны.

$R^{\text{б}}$ — сжимающее; $R^{\text{д}}$, $R^{\text{у}}$ — растягивающие;

Рекомендации и выводы

- рекомендуется пользоваться расстоянием Уорда $R^{\text{У}}$;
- обычно строят несколько вариантов и выбирают лучший визуально по дендрограмме;
- определение числа кластеров — по максимуму $|R_{t+1} - R_t|$, тогда результирующее множество кластеров $:= C_t$.

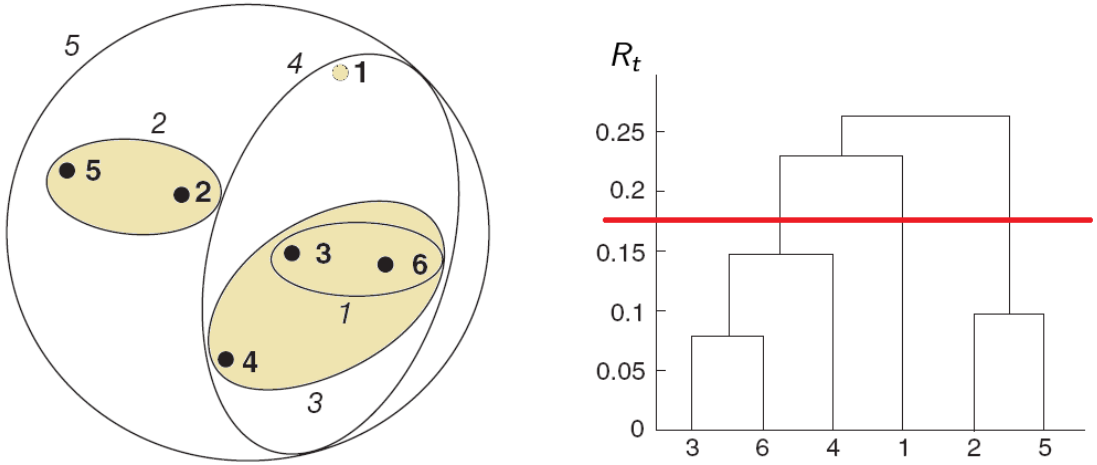

Метод частичного обучения self-training (1965-1970)

Пусть $\mu\colon X^k \to a$ — метод обучения классификации;
классификаторы имеют вид $a(x) = \arg\max\limits_{y \in Y} \Gamma_y(x)$;

Псевдоотступ — степень уверенности классификации $a_i = a(x_i)$:

$$M_i(a) = \Gamma_{a_i}(x_i) - \max_{y \in Y \setminus a_i} \Gamma_y(x_i).$$

Алгоритм self-training — обёртка (wrapper) над методом μ:

$Z := X^k$;
пока $|Z| < \ell$
  $a := \mu(Z)$;
  $\Delta := \{x_i \in U \setminus Z \mid M_i(a) \geqslant M_0\}$;
  $a_i := a(x_i)$ для всех $x_i \in \Delta$;
  $Z := Z \cup \Delta$;

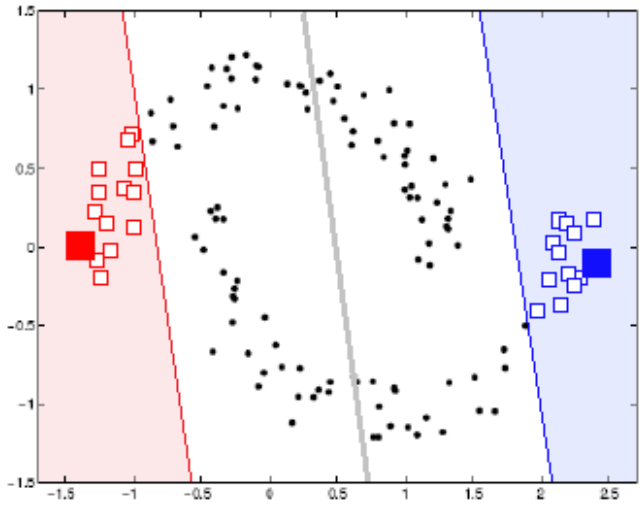

M_0 можно определять, например, из условия $|\Delta| = 0.05\,|U|$

Метод частичного обучения co-training (Blum, Mitchell, 1998)

Пусть $\mu_1 \colon X^k \to a_1$, $\mu_2 \colon X^k \to a_2$ — два существенно различных метода обучения, использующих
— либо разные наборы признаков;
— либо разные парадигмы обучения (inductive bias);
— либо разные источники данных $X_1^{k_1}$, $X_2^{k_2}$.

$Z_1 := X_1^{k_1}$; $Z_2 := X_2^{k_2}$;
пока $|Z_1 \cup Z_2| < \ell$

$a_1 := \mu_1(Z_1)$; $\Delta_1 := \{x_i \in U \backslash Z_1 \backslash Z_2 \mid M_i(a_1) \geqslant M_{01}\}$;
$a_i := a_1(x_i)$ для всех $x_i \in \Delta_1$;
$Z_2 := Z_2 \cup \Delta_1$;

$a_2 := \mu_2(Z_2)$; $\Delta_2 := \{x_i \in U \backslash Z_1 \backslash Z_2 \mid M_i(a_2) \geqslant M_{02}\}$;
$a_i := a_2(x_i)$ для всех $x_i \in \Delta_2$;
$Z_1 := Z_1 \cup \Delta_2$;

Метод частичного обучения co-learning (deSa, 1993)

Пусть $\mu_t \colon X^k \to a_t$ — разные методы обучения, $t = 1, \ldots, T$.

Алгоритм co-learning — это self-training для композиции — простого голосования базовых алгоритмов $a_1, \ldots, a_T$:

$$a(x) = \arg\max_{y \in Y} \Gamma_y(x), \quad \Gamma_y(x_i) = \sum_{t=1}^{T} \bigl[a_t(x_i) = y\bigr].$$

тогда $M_i(a)$ — степень уверенности классификации $a(x_i)$.

$Z := X^k$;
пока $|Z| < \ell$
  $a := \mu(Z)$;
  $\Delta := \bigl\{x_i \in U \backslash Z \mid M_i(a) \geqslant M_0\bigr\}$;
  $a_i := a(x_i)$ для всех $x_i \in \Delta$;
  $Z := Z \cup \Delta$;

Общий оптимизационный подход к задачам SSL

Дано:

$X^k = \begin{matrix}\{x_1, \ldots, x_k\} \\ \{y_1, \ldots, y_k\}\end{matrix}$ — размеченные объекты (labeled data);

$U = \{x_{k+1}, \ldots, x_\ell\}$ — неразмеченные объекты (unlabeled data).

Найти: модель классификации $a(x, w)$

Критерий одновременной классификации и кластеризации:

$$Q(w) = \underbrace{\sum_{i=1}^{k} \mathscr{L}(a(x_i, w), y_i)}_{\text{классификация}} + \lambda \underbrace{\sum_{i=1}^{\ell} \mathscr{L}_U(a(x_i, w))}_{\text{кластеризация}} \to \min_w$$

$\mathscr{L}(a, y)$ — функция потерь классификации,
$\mathscr{L}_U(a)$ — функция потерь для неразмеченных данных

Суть SSL — это общая параметризация w в двух критериях

Напоминание: SVM для двухклассовой классификации

Линейный классификатор на два класса $Y = \{-1, 1\}$:

$$a(x) = \operatorname{sign}\big(\langle w, x\rangle - w_0\big), \quad w, x \in \mathbb{R}^n, \; w_0 \in \mathbb{R}.$$

Отступ объекта x_i:

$$M_i(w, w_0) = \big(\langle w, x_i\rangle - w_0\big) y_i.$$

Задача обучения весов w, w_0 по размеченной выборке:

$$Q(w, w_0) = \sum_{i=1}^{k} \big(1 - M_i(w, w_0)\big)_+ + \frac{1}{2C}\|w\|^2 \;\to\; \min_{w, w_0}.$$

Функция $\mathscr{L}(M) = (1 - M)_+$ штрафует за уменьшение отступа.

Идея!
Функция $\mathscr{L}_U(M) = \big(1 - |M|\big)_+$ штрафует за попадание объекта внутрь разделяющей полосы.

Функция потерь для трансдуктивного SVM

Функция потерь $\mathscr{L}(M) = \big(1 - |M|\big)_+$ штрафует за попадание объекта внутрь разделяющей полосы.

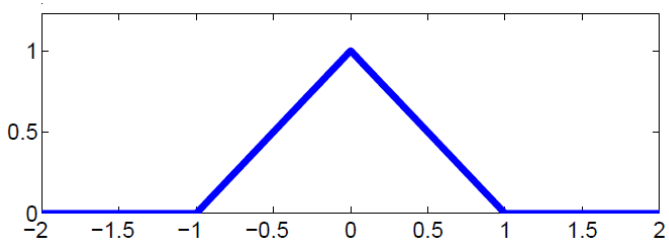

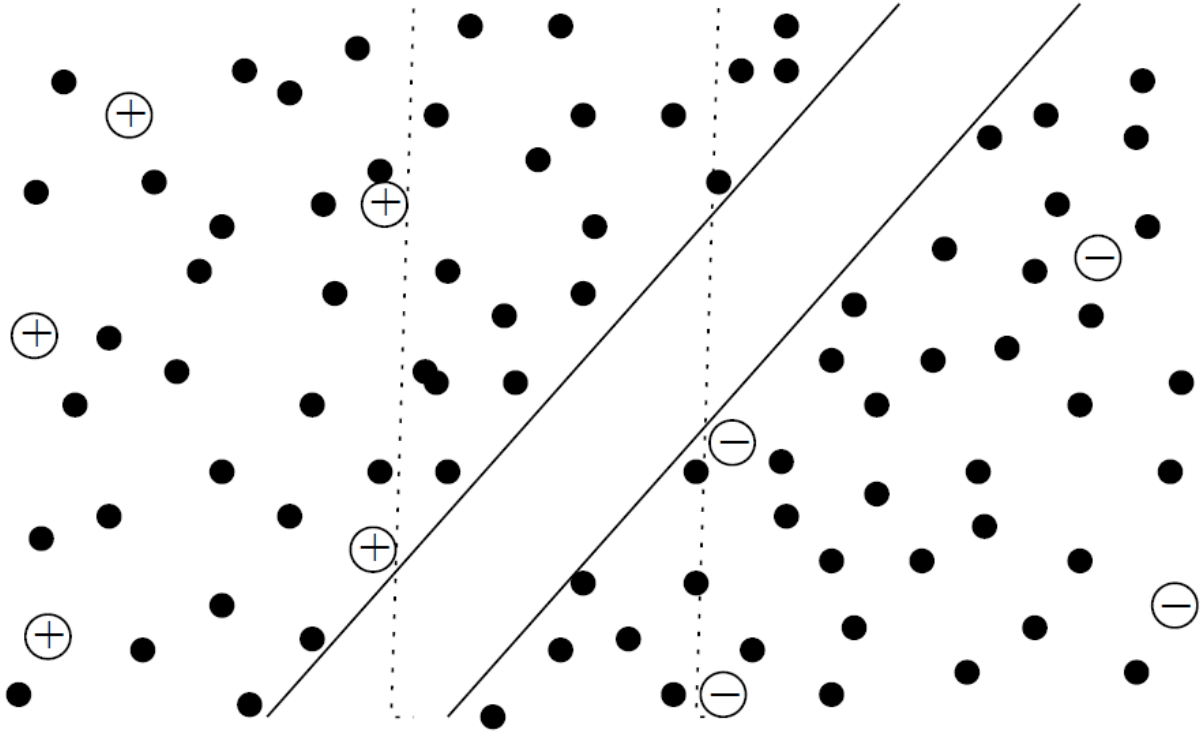

Метод частичного обучения Transductive SVM

Обучение весов w, w_0 по частично размеченной выборке:

$$Q(w, w_0) = \sum_{i=1}^{k} \big(1 - M_i(w, w_0)\big)_+ + \frac{1}{2C}\|w\|^2 +$$

$$+\gamma \sum_{i=k+1}^{\ell} \big(1 - |M_i(w, w_0)|\big)_+ \to \min_{w, w_0}.$$

Достоинства и недостатки TSVM:

- ⊕ как и в обычном SVM, можно использовать ядра;
- ⊕ имеются эффективные реализации для больших данных;
- ⊖ задача невыпуклая, методы оптимизации сложнее;
- ⊖ решение неустойчиво, если нет области разреженности;
- ⊖ требуется настройка двух параметров C, γ;

Sindhwani, Keerthi. Large scale semisupervised linear SVMs. SIGIR 2006.

Напоминание: многоклассовая логистическая регрессия

Линейный классификатор по конечному множеству классов $|Y|$:

$$a(x) = \arg\max_{y \in Y} \langle w_y, x \rangle, \quad x, w_y \in \mathbb{R}^n.$$

Вероятность того, что объект x относится к классу y:

$$P(y|x, w) = \frac{\exp\langle w_y, x \rangle}{\sum\limits_{c \in Y} \exp\langle w_c, x \rangle} = \underset{y \in Y}{\mathrm{SoftMax}} \langle w_y, x \rangle$$

Задача максимизации регуляризованного правдоподобия:

$$Q(w) = \sum_{i=1}^{k} \log P(y_i|x_i, w) - \frac{1}{2C} \sum_{y \in Y} \|w_y\|^2 \;\to\; \max_w$$

Оптимизация $Q(w)$ — методом стохастического градиента, по $n|Y|$-мерному вектору параметров $w = (w_y \colon y \in Y)$.

Согласование модели на размеченных и неразмеченных данных

Теперь учтём неразмеченные данные $U = \{x_{k+1}, \ldots, x_\ell\}$.
Пусть $b_j(x)$ — бинарные признаки, $j = 1, \ldots, m$.

Оценим вероятности $\mathrm{P}(y|b_j(x) = 1)$ двумя способами:

1) эмпирическая оценка по размеченным данным X^k:

$$\hat{p}_j(y) = \frac{\sum_{i=1}^k b_j(x_i)\,[y_i = y]}{\sum_{i=1}^k b_j(x_i)};$$

2) оценка по неразмеченным данным U и вероятностной модели:

$$p_j(y|w) = \frac{\sum_{i=k+1}^\ell b_j(x_i) P(y|x_i, w)}{\sum_{i=k+1}^\ell b_j(x_i)}.$$

Максимизируем правдоподобие вероятностной модели $p_j(y|w)$, приближающей эмпирическое распределение $\hat{p}_j(y)$.

Построение регуляризатора (XR, eXpectation Regularization)

Логарифм правдоподобия модели классов по j-му признаку:

$$Q_j(w) = \sum_{y \in Y} \hat{p}_j(y) \log p_j(y|w) \;\to\; \max_w .$$

Регуляризация критерия $Q(w)$ суммой log-правдоподобий $Q_j(w)$ с коэффициентом регуляризации γ:

$$Q(w) + \gamma \sum_{j=1}^{m} Q_j(w) = \sum_{i=1}^{k} \log P(y_i|x_i, w) - \frac{1}{2C} \sum_{y \in Y} \|w_y\|^2 +$$

$$+ \gamma \sum_{j=1}^{m} \sum_{y \in Y} \hat{p}_j(y) \log\Bigl(\sum_{i=k+1}^{\ell} b_j(x_i) P(y|x_i, w) \Bigr) \;\to\; \max_w .$$

Mann, McCallum. Simple, robust, scalable semi-supervised learning via expectation regularization. ICML 2007.

Особенности метода XR (eXpectation Regularization)

1. XR — это SSL, но это вообще не кластеризация!
2. Оптимизация методом стохастического градиента
3. Возможные варианты задания переменных b_j:
   - $b_j(x) \equiv 1$, тогда $\mathrm{P}(y|b_j(x)=1)$ — априорная вероятность класса y (label regularization)
     — подходит для задач с несбалансированными классами
   - $b_j(x) = \big[$термин j содержится в тексте $x\big]$
     — подходит для задач классификации текстов
4. Метод слабо чувствителен к выбору C и γ,
5. устойчив к погрешностям оценивания $\hat{p}_j(y)$,
6. не требует большого числа размеченных объектов k,
7. хорошо подходит для категоризации текстов.

Mann, McCallum. Simple, robust, scalable semi-supervised learning via expectation regularization. ICML 2007.

Резюме в конце лекции

- Кластеризация — это обучение без учителя, некорректно поставленная задача, существует много оптимизационных и эвристических алгоритмов кластеризации
- DBSCAN — популярный быстрый алгоритм кластеризации
- Задача SSL занимает промежуточное положение между классификацией и кластеризацией, но не сводится к ним
- Методы кластеризации легко адаптируются к SSL путём введения ограничений (constrained clustering)
- Адаптация методов классификации чаще реализуется через оптимизацию взвешенной суммы двух критериев
- SSL — не обязательно кластеризация (пример — XR); суть SSL именно в общей параметризации двух критериев, различных на размеченных и неразмеченных данных