Методы машинного обучения. Методы отбора признаков

Воронцов Константин Вячеславович
www.MachineLearning.ru/wiki?title=User:Vokov
вопросы к лектору: k.vorontsov@iai.msu.ru

материалы курса:
github.com/MSU-ML-COURSE/ML-COURSE-24-25
орг.вопросы по курсу: ml.cmc@mail.ru

ВМК МГУ • 10 февраля 2026

Содержание

1. **Задача отбора признаков**
   - Задачи и методы отбора признаков
   - Фильтры и встроенные методы
   - Методы-обёртки и внешние критерии
2. **Комбинаторный отбор признаков**
   - Полный перебор
   - Жадные и полужадные алгоритмы
   - Поиск в глубину и в ширину
3. **Эволюционные алгоритмы**
   - Эволюционные алгоритмы отбора признаков
   - Случайный поиск с адаптацией
   - Символьная регрессия

Напоминание. Задачи оценивания и выбора моделей

Дано:
$X^\ell = (x_1, \ldots, x_\ell)$ — обучающая выборка
$A_t = \{a\colon X \times W_t \to Y\}$ — параметрические модели, $t \in T$
W_t — пространство параметров модели A_t
$\mu_t\colon X^\ell \to W_t$ — методы обучения, $t \in T$

Найти: метод μ_t с наилучшей *обобщающей способностью*.

Частные случаи:

- выбор лучшей модели A_t (model selection);
- выбор метода обучения μ_t для заданной модели A (в частности, оптимизация *гиперпараметров*);
- отбор признаков (feature selection): метод обучения μ_J использует только признаки $J \subseteq F = \{f_1, \ldots, f_n\}$
- перебор формул как суперпозиций элементарных функций (symbolic regression, genetic programming)

Почему полезен отбор признаков (feature selection)

$X^\ell = (x_i, y_i)_{i=1}^\ell$ — обучающая выборка, $y_i = y(x_i)$;
$f_j(x)$, $j = 1, \ldots, n$ — признаки объекта x

Почему полезно отбирать признаки:

- признак может быть неинформативным:
  $f_j(x)$ не содержит информации об $y(x)$
- признак может быть зависимым:
  информация о $f_j(x)$ содержится в других признаках
- признак может быть настолько зашумлённым, что его использование повышает риск ошибок и переобучения
- минимизация числа используемых признаков может
  — понижать размерность пространства параметров модели,
  — уменьшать переобучение,
  — экономить ресурсы времени и памяти

Обзор подходов к отбору признаков

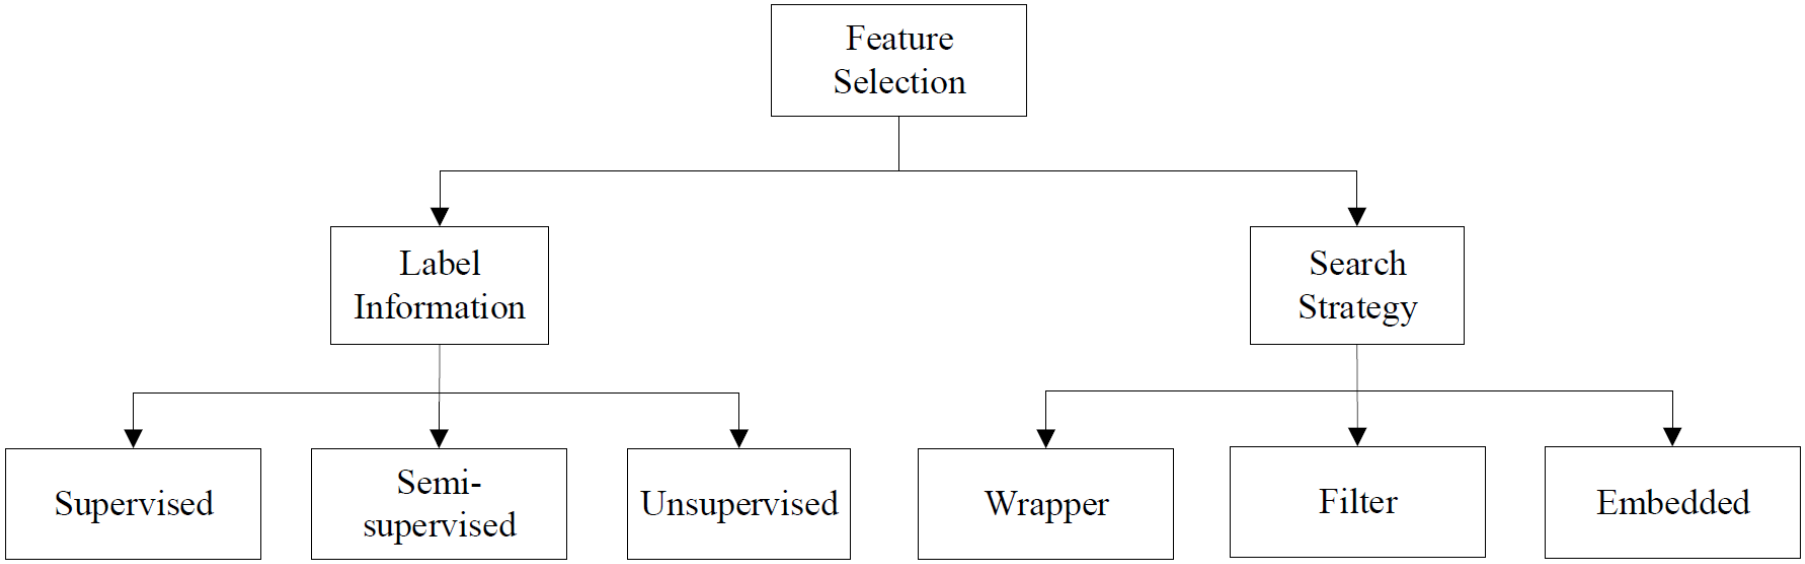

- с учителем — с использованием ответов $\{y_i\}$
- без учителя — например, по корреляциям признаков
- обёртки — с использованием готовых методов обучения
- фильтры — оценивание признаков по отдельности
- встроенные методы, в линейных моделях LASSO, ElasticNet

Jundong Li et al. Feature selection: a data perspective. 2016

Фильтрация признаков с учителем и без учителя

Отбор признаков с учителем:

- вычисление полезности признаков: MI или корреляции (y, f_j)
- ранжирование признаков по их полезности
- отбор top-k полезных признаков по выбранному критерию
- **плюс:** очень быстро
- **минус:** не учитываются зависимости между признаками

Отбор признаков без учителя:

- вычисление парных корреляций признаков (f_j, f_s)
- выделение кластеров или связных подграфов
- выбор представителей от каждого кластера (метод корреляционных плеяд П.В.Терентьева, 1928, 1959)
- **минус:** учитываются только парные зависимости

Сколько информации об y содержится в f_j

$f_j\colon X \to V_j$ — дискретный признак, V_j — конечное множество
$p(v)$ — выборочная частотная оценка вероятности $P\big(f_j(x) = v\big)$

Энтропия, мера неопределённости значений y:

$$H(y) = -\sum_{y \in Y} p(y) \log p(y)$$

Условная энтропия, неопределённость y при известном f_j:

$$H(y|f_j) = -\sum_{v \in V_j} p(v) \sum_{y \in Y} p(y|v) \log p(y|v)$$

Взаимная информация (mutual information, information gain):

$$I(y, f_j) = H(y) - H(y|f_j) = \sum_{v \in V_j} \sum_{y \in Y} p(y, v) \log \frac{p(y, v)}{p(y)p(v)}$$

$I(y, f_j) = 0 \quad \Leftrightarrow \quad$ переменные y и f_j независимы

Напоминание. Встроенный отбор признаков в линейных моделях

Негладкие регуляризаторы с параметром селективности μ:

$$\sum_{i=1}^{\ell} \mathscr{L}\big(\langle x_i, w\rangle, y_i\big) + \tau \sum_{j=1}^{n} R_\mu(w_j) \;\to\; \min_w .$$

LASSO (L_1): $R_\mu(w) = \mu|w|$

Elastic Net: $R_\mu(w) = \mu|w| + w^2$

Support Features Machine (SFM):

$$R_\mu(w) = \begin{cases} 2\mu|w|, & |w| \leqslant \mu; \\ \mu^2 + w^2, & |w| \geqslant \mu; \end{cases}$$

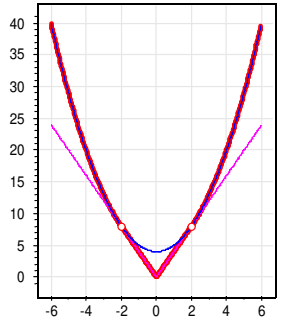

Relevance Features Machine (RFM):

$$R_\mu(w) = \ln\big(\mu w^2 + 1\big)$$

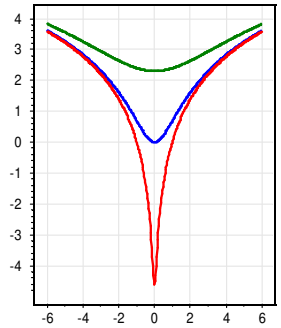

Напоминание. Внутренние и внешние критерии

$\mathscr{L}(w, x)$ — функция потерь модели $a(w, x)$ на объекте x

$Q(w, X^\ell) = \frac{1}{\ell}\sum\limits_{i=1}^{\ell} \mathscr{L}(w, x_i)$ — *функционал качества* $a(w, x)$ на X^ℓ

$Q\big(\mu(X^\ell), X^\ell\big)$ — *внутренний критерий*, оптимизируемый по обучающей выборке, убывает с ростом сложности модели (числа обучаемых параметров), смещенная оценка $\mathsf{E}_{X^\ell, x}\mathscr{L}\big(\mu(X^\ell), x\big)$

$Q\big(\mu(X^\ell), X^k\big)$ — *внешний критерий*, имеет минимум по сложности модели, несмещённая оценка $\mathsf{E}_{X^\ell, x}\mathscr{L}\big(\mu(X^\ell), x\big)$

Недостаток оценки hold-out: она зависит от разбиения $X^\ell \sqcup X^k$

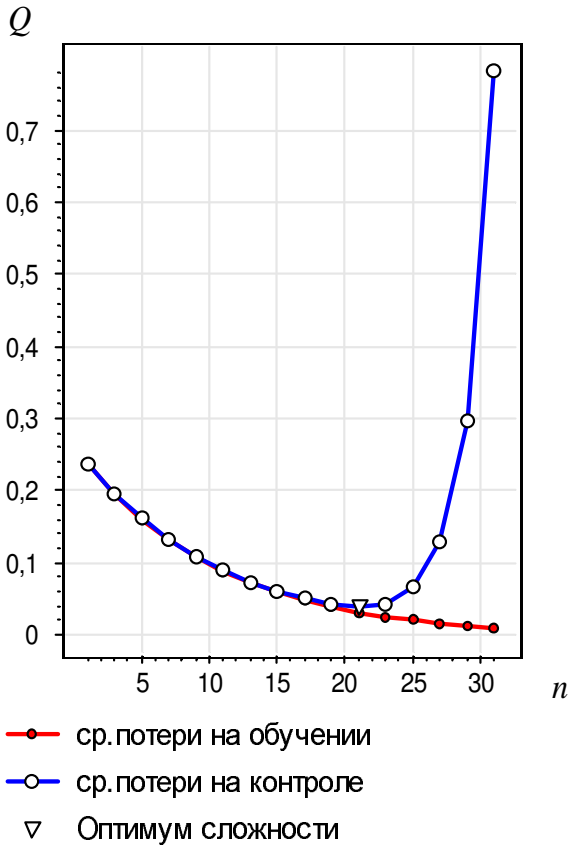

Напоминание. Кросс-проверка (cross-validation, CV)

Усреднение по множеству разбиений $X^L = X_s^\ell \sqcup X_s^k$, $s \in S$:

$$\mathrm{CV}(\mu, X^L) = \frac{1}{|S|} \sum_{s \in S} Q\big(\mu(X_s^\ell), X_s^k\big)$$

- $|S| = 1$ — единственное (случайное) разбиение: *hold-out*
- S — множество случайных разбиений: *метод Монте-Карло*
- $S = \big\{(X^L \setminus \{x_i\}) \sqcup \{x_i\}\big\}_{i=1..L}$, каждый объект становится контролем один раз, *скользящий контроль* (*leave one out*)
- $S = \big\{(X^L \setminus B_s) \sqcup B_s\big\}_{s=1..q}$, где $B_1 \sqcup \dots \sqcup B_q = X^L$ — разбиение *на q блоков* равной± 1 длины (q-fold CV), каждый объект участвует в контроле один раз
- $S = \big\{(X^L \setminus B_s^r) \sqcup B_s^r\big\}_{s=1..q}^{r=1..t}$, где $B_1^r \sqcup \dots \sqcup B_q^r = X^L$ — t разбиений *на q блоков* равной± 1 длины ($t \times q$-fold CV), каждый объект участвует в контроле ровно t раз
- S — все $C_{\ell+k}^k$ разбиений: *complete cross-validation*, CCV

Внешние критерии. Непротиворечивость моделей

Идея: Если модель верна, то алгоритмы, настроенные по разным частям данных, не должны противоречить друг другу.

1. По одному случайному разбиению $X^L = X^\ell \sqcup X^k$, $\ell = k$:

$$Q_1(\mu, X^L) = \frac{1}{L} \sum_{i=1}^{L} \left| \mu(X^\ell)(x_i) - \mu(X^k)(x_i) \right|$$

2. Аналог $\mathrm{CV}_{t\times 2}$: по $|S|$ разбиениям $X^L = X^\ell_s \sqcup X^k_s$, $s \in S$:

$$Q_S(\mu, X^L) = \frac{1}{|S|} \sum_{s\in S} \frac{1}{L} \sum_{i=1}^{L} \left| \mu(X^\ell_s)(x_i) - \mu(X^k_s)(x_i) \right|$$

Преимущество: подходит также для обучения без учителя.

Недостатки:

— объём обучения сокращается в 2 раза;

— трудоёмкость возрастает в $2|S|$ раз.

Внешние критерии. Аналитические оценки и их обращение

Основная идея аналитического подхода:

1. Получить верхнюю оценку вероятности переобучения, справедливую для любой выборки $X^L = X^\ell \sqcup X^k$, для широкого класса моделей A и методов обучения μ:

$$\mathsf{P}\Big[Q\big(\mu(X^\ell), X^k\big) - Q\big(\mu(X^\ell), X^\ell\big) \geqslant \varepsilon\Big] \leqslant \eta(\varepsilon, A)$$

2. Тогда для любой X^L, любых A и μ и любого $\eta \in (0,1)$ с вероятностью не менее $(1-\eta)$ справедлива оценка

$$Q\big(\mu(X^\ell), X^k\big) \leqslant Q\big(\mu(X^\ell), X^\ell\big) + \varepsilon(\eta, A),$$

где $\varepsilon(\eta, A)$ — функция штрафа на A, обратная к $\eta(\varepsilon, A)$, не зависящая от скрытой контрольной выборки X^k

3. Обучение с регуляризатором: $Q(w, X^\ell) + \varepsilon(\eta, A) \to \min\limits_{w,A}$

Напоминание. Регуляризация линейных моделей

Регуляризатор — аддитивная добавка к внутреннему критерию, обычно *штраф за сложность* (complexity penalty) модели A:

$$Q(w, X^\ell) + \text{штраф}(A) \;\to\; \min_w$$

Линейные модели: $A = \{a(x) = \operatorname{sign}\langle w, x\rangle\}$ — классификация,
$A = \{a(x) = \langle w, x\rangle\}$ — регрессия.

L_2-регуляризация (ридж-регрессия):

$$\text{штраф}(w) = \tau\|w\|_2^2 = \tau\sum_{j=1}^n w_j^2$$

L_1-регуляризация (LASSO):

$$\text{штраф}(w) = \tau\|w\|_1 = \tau\sum_{j=1}^n |w_j|$$

L_0-регуляризация (AIC, BIC):

$$\text{штраф}(w) = \tau\|w\|_0 = \tau\sum_{j=1}^n [w_j \neq 0]$$

Разновидности L_0-регуляризации

Информационный критерий Акаике (Akaike Information Criterion):

$$\mathrm{AIC}(\mu, x) = Q_\mu(X^\ell) + \frac{2\hat{\sigma}^2}{\ell}|J|,$$

где $\hat{\sigma}^2$ — оценка дисперсии ошибки $\mathrm{D}\big(y_i - a(x_i)\big)$,
J — подмножество используемых признаков.

Байесовский информационный критерий (Bayes Inform. Criterion):

$$\mathrm{BIC}(\mu, X^\ell) = \frac{\ell}{\hat{\sigma}^2}\left(Q_\mu(X^\ell) + \frac{\hat{\sigma}^2 \ln \ell}{\ell}|J|\right).$$

Оценка Вапника-Червоненкиса (VC-bound):

$$\mathrm{VC}(\mu, X^\ell) = Q_\mu(X^\ell) + \sqrt{\frac{h}{\ell}\ln\frac{2e\ell}{h} + \frac{1}{\ell}\ln\frac{9}{4\eta}},$$

h — VC-размерность (ёмкость); для линейных моделей $h = |J|$
η — уровень значимости; обычно $\eta = 0.05$

Многокритериальный выбор модели

Модель, немного неоптимальная по обоим критериям, может оказаться лучше, чем модель, оптимальная по одному критерию, но сильно не оптимальная по другому.

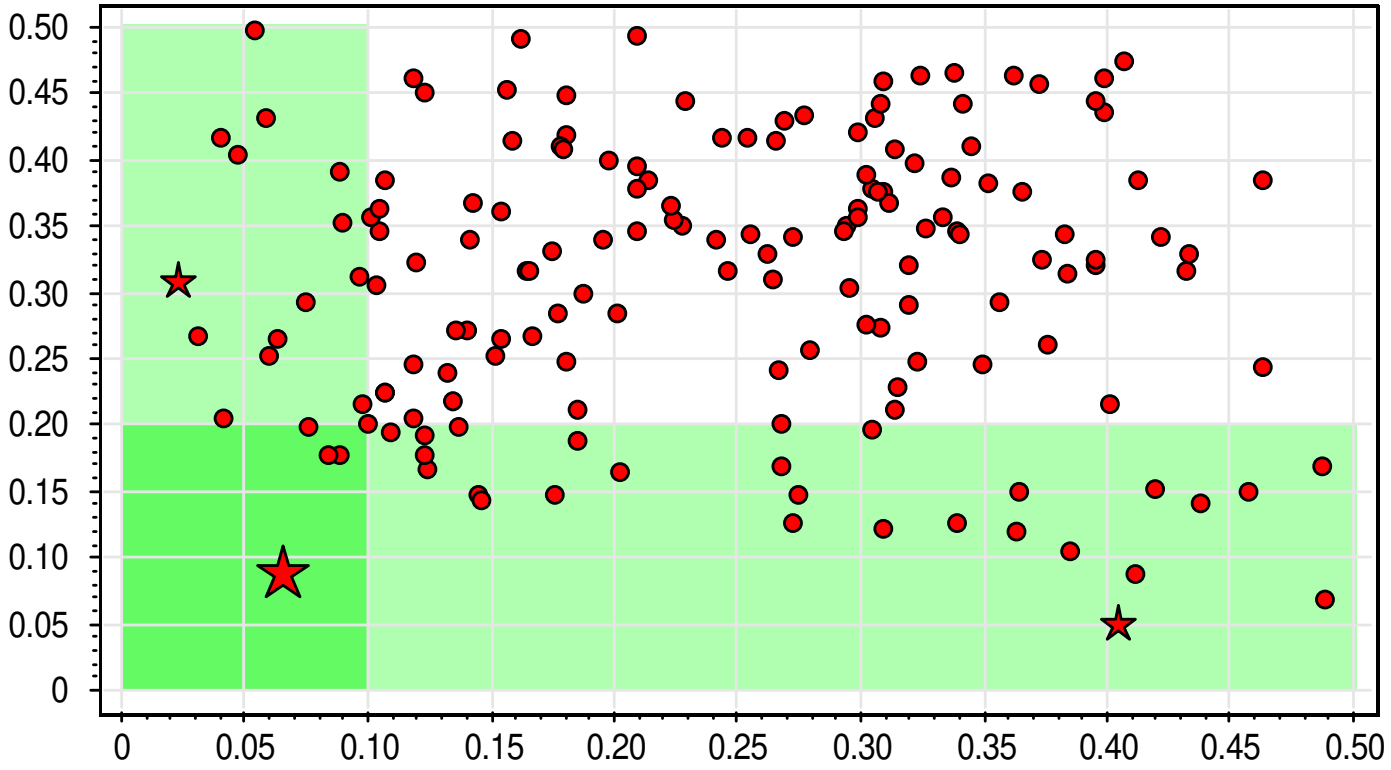

Задача отбора признаков по внешнему критерию

$F = \{f_j : X \to D_j : j = 1, \ldots, n\}$ — множество признаков;

μ_J — метод обучения, использующий только признаки $J \subseteq F$;

$Q(J) = Q(\mu_J, X^\ell)$ — выбранный внешний критерий.

$Q(J) \to \min$ — задача дискретной оптимизации.

Внутренний критерий и внешний критерий:

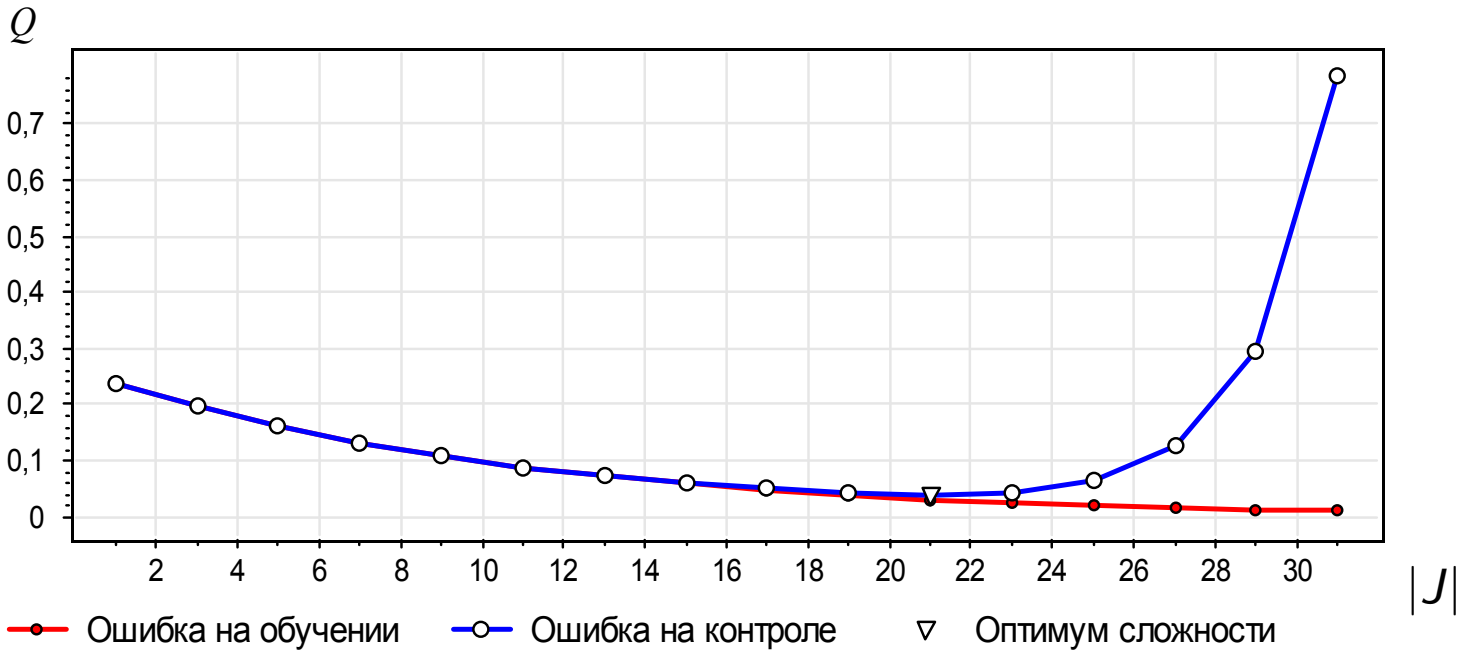

Напоминание. Отбор признаков в логических закономерностях

Закономерность R — *конъюнкция* пороговых условий:

$$R(x) = \bigwedge_{j \in J} \big[f_j(x) \geqslant a_j \big].$$

Критерий информативности относительно класса $c \in Y$:

$$I(p,n) \to \max_{J,\{a_j\}}; \quad \begin{cases} p(R) = \#\big\{x_i \colon R(x_i){=}1 \text{ и } y_i{=}c\big\} \to \max \\ n(R) = \#\big\{x_i \colon R(x_i){=}1 \text{ и } y_i{\neq}c\big\} \to \min \end{cases}$$

Аналогично внешним критериям,
информативность $I(p,n)$ имеет оптимум по сложности $|J|$:

- слишком мало признаков $\Rightarrow$ большие n, низкая $I(p,n)$
- оптимально признаков $\Rightarrow$ малые n, большие p, высокая $I(p,n)$
- слишком много признаков $\Rightarrow$ малые $p+n$, низкая $I(p,n)$

Алгоритм полного перебора (Full Search)

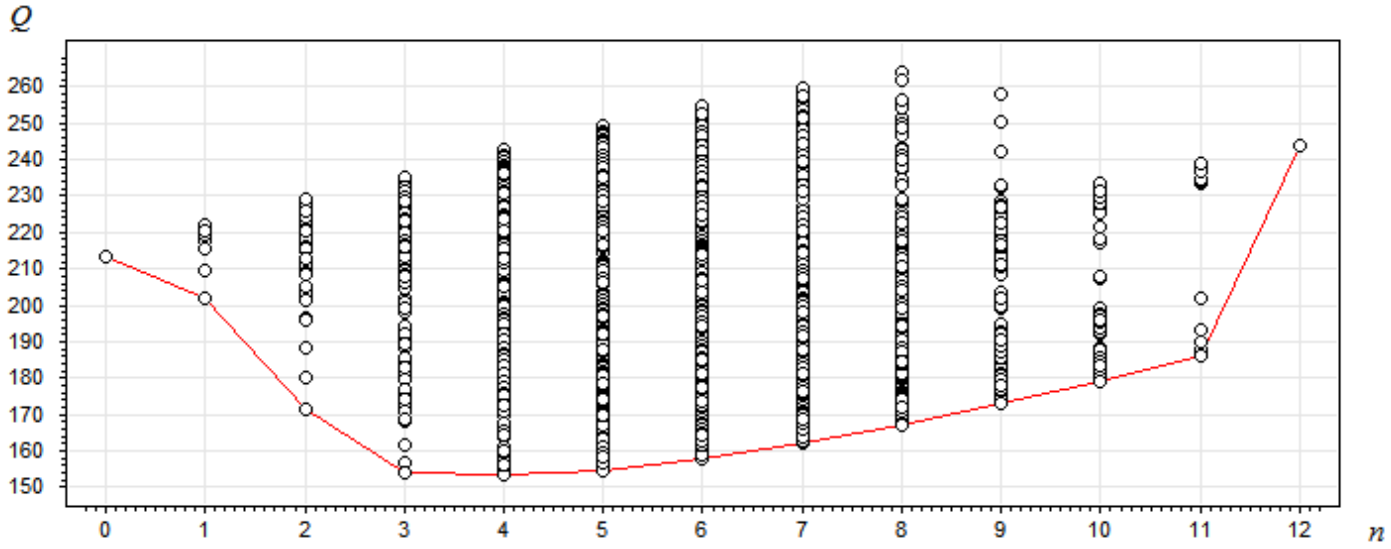

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

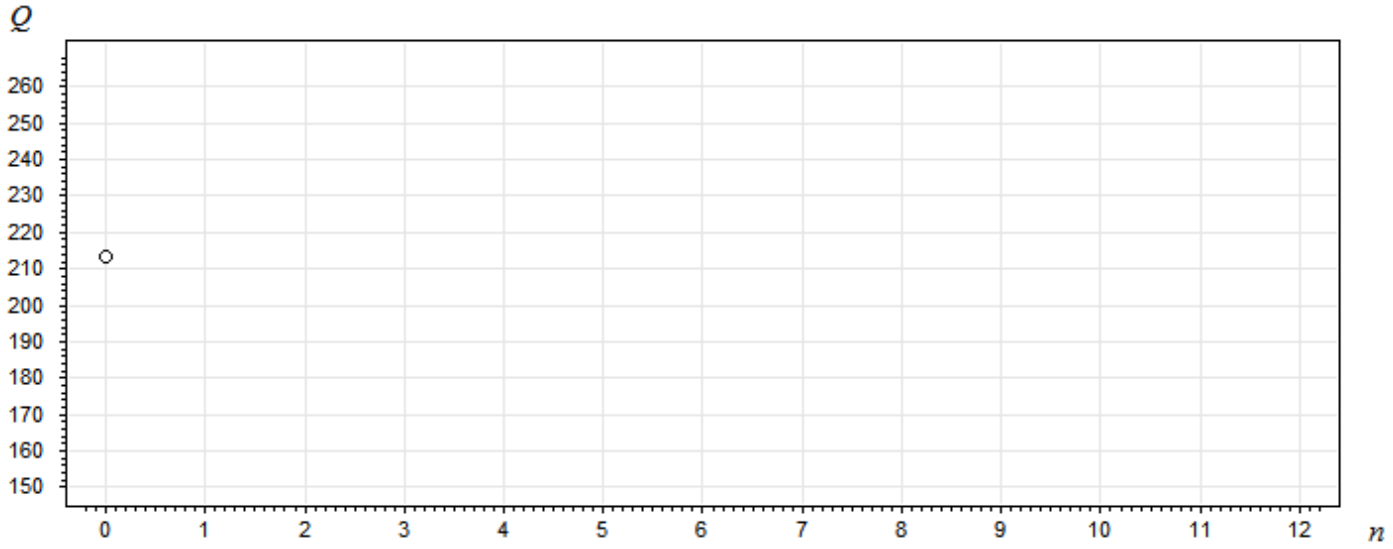

$d = 3$
$j = 0$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

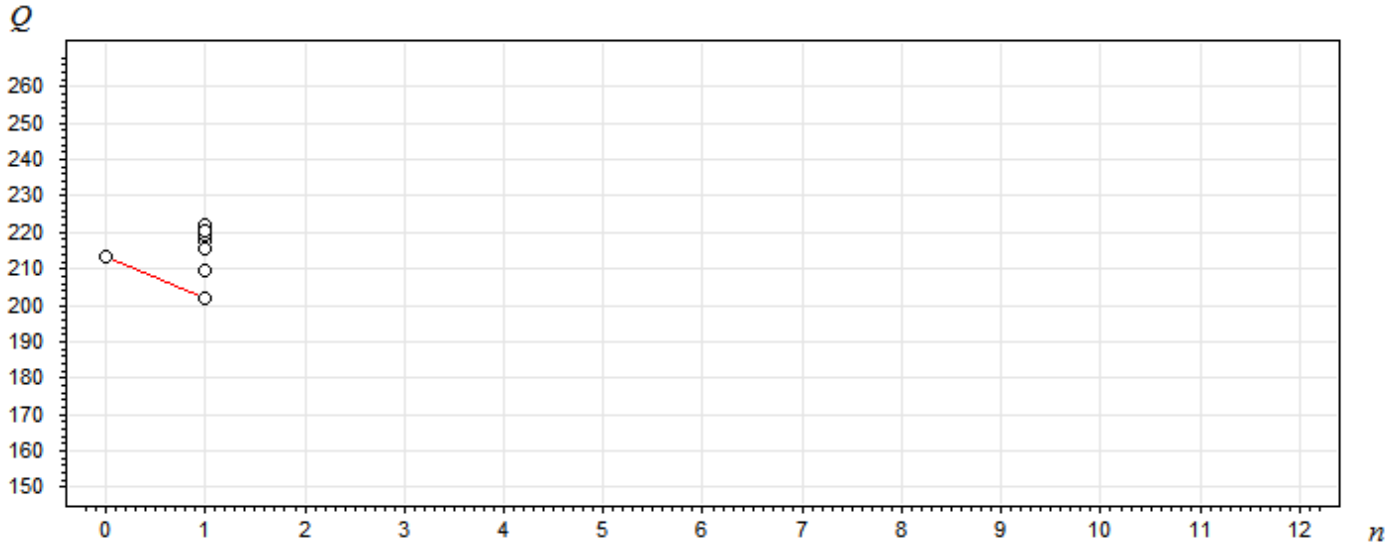

$d = 3$
$j = 1$
$j^* = 1$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

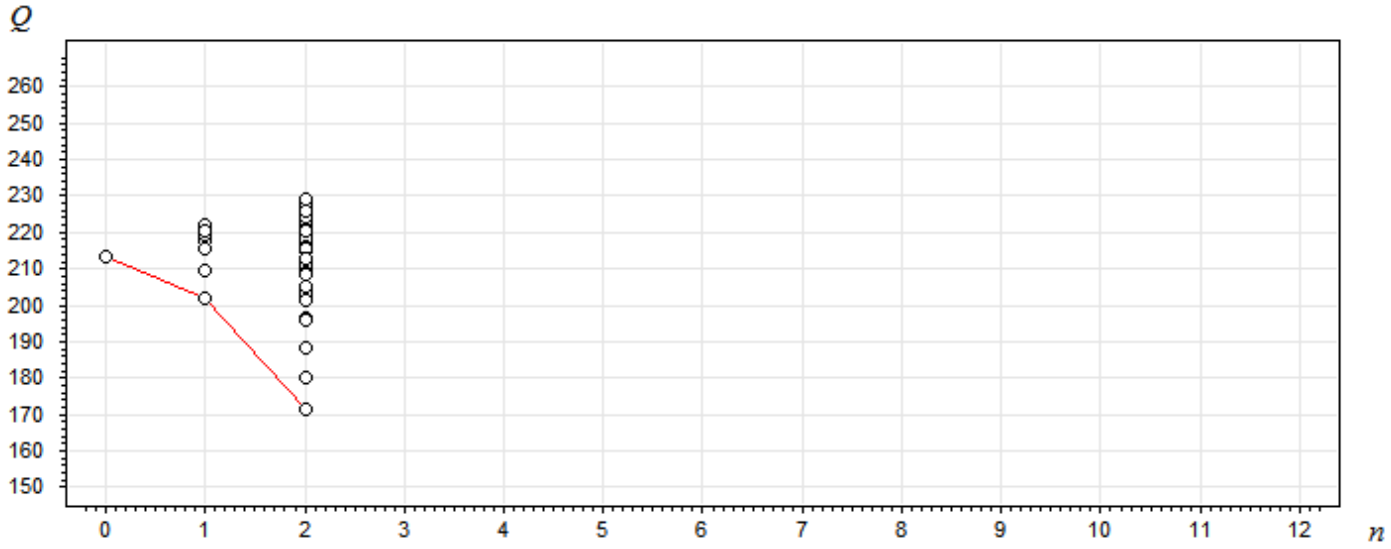

$d = 3$
$j = 2$
$j^* = 2$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

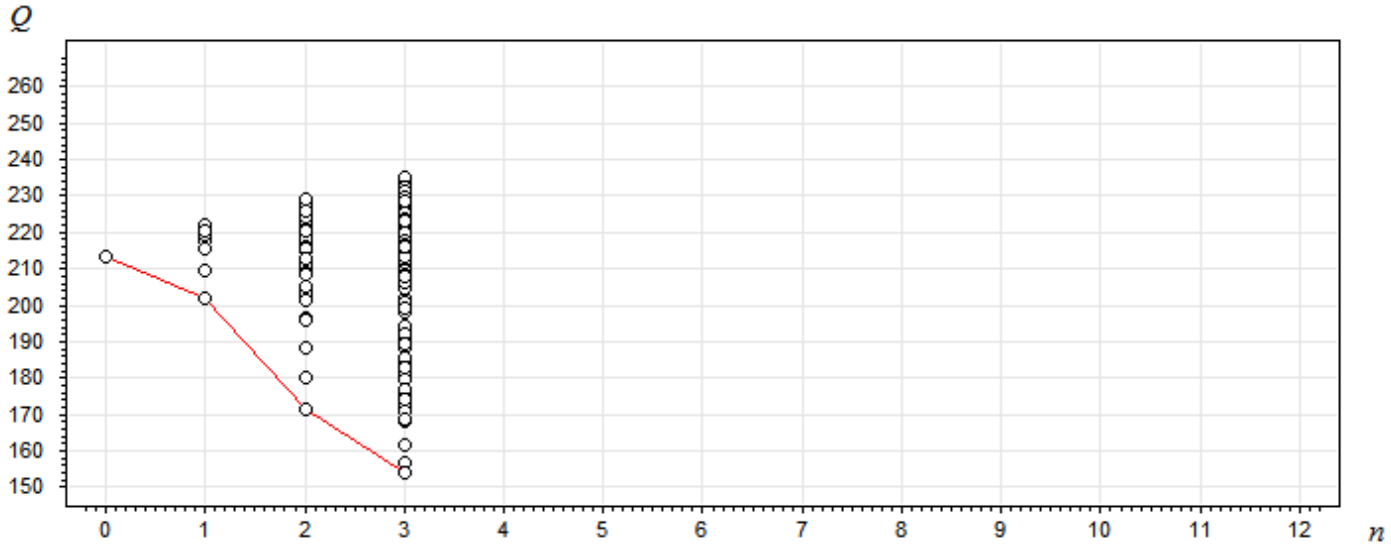

$d = 3$
$j = 3$
$j^* = 3$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

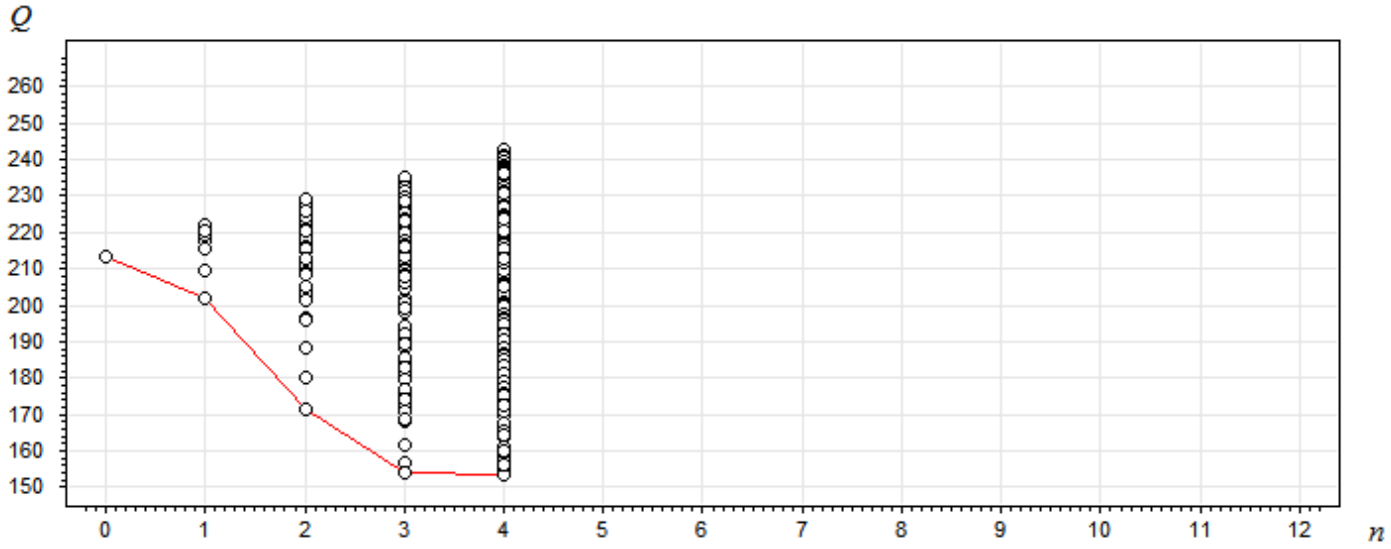

$d = 3$
$j = 4$
$j^* = 4$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

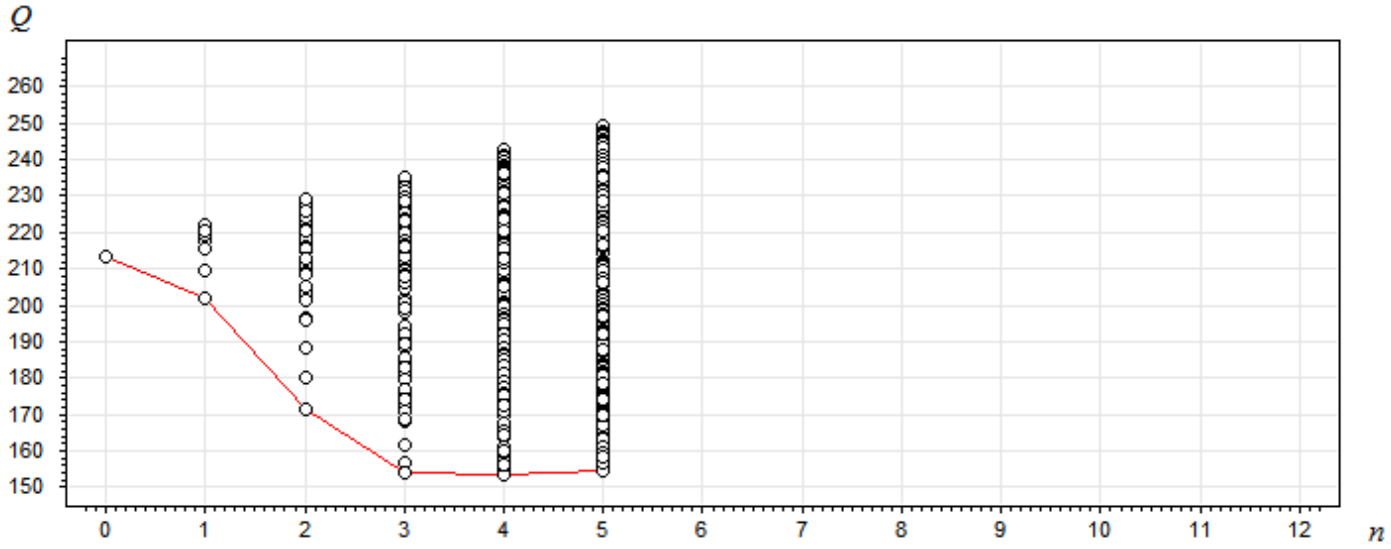

$d = 3$
$j = 5$
$j^* = 4$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

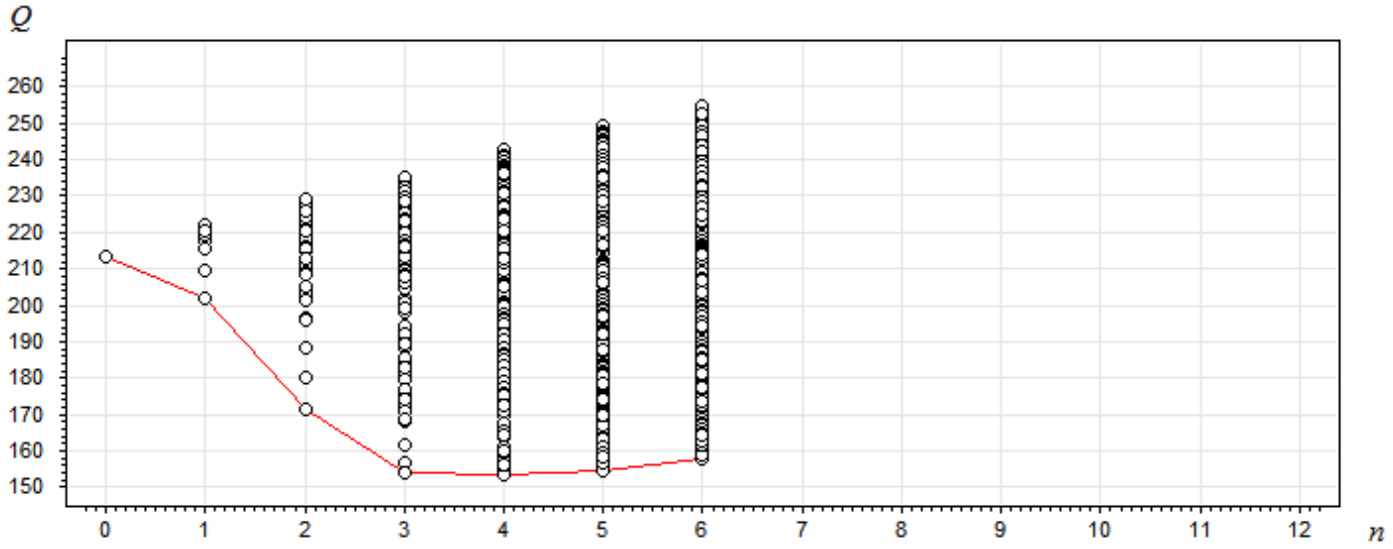

$d = 3$
$j = 6$
$j^* = 4$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

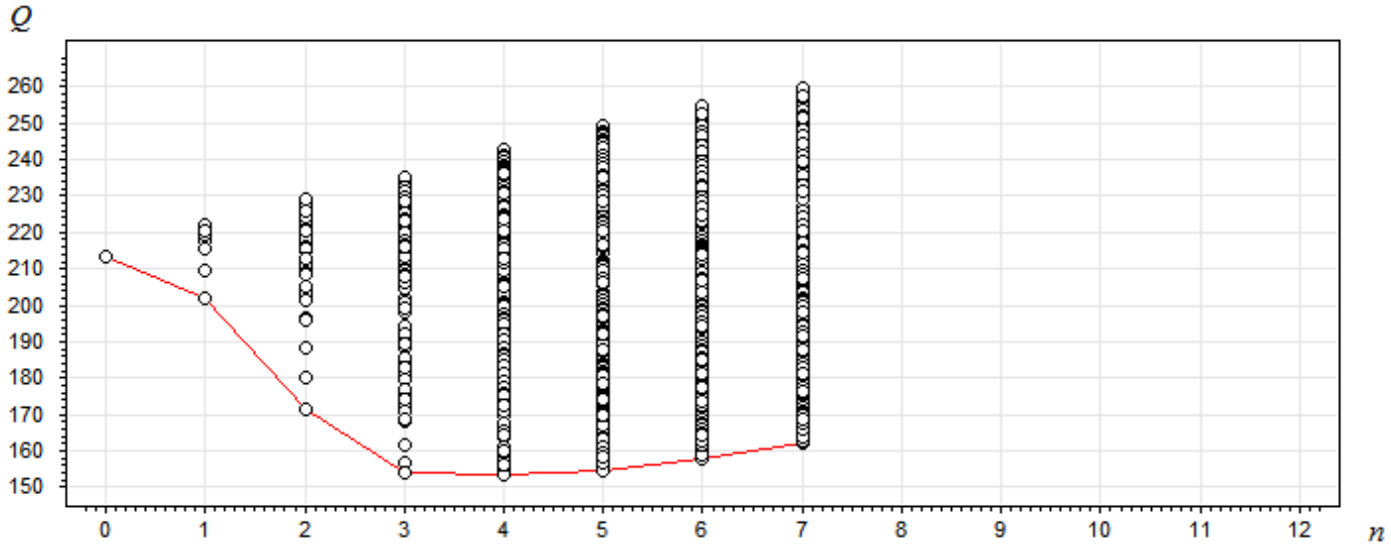

$d = 3$
$j = 7$
$j^* = 4$

Вход: множество F, внешний критерий Q, параметр d;

инициализация: $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов

$J_j := \arg\min\limits_{J:\,|J|=j} Q(J)$ — найти лучший набор сложности j;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Алгоритм полного перебора (Full Search)

Преимущества:

— простота реализации;
— гарантированный результат;
— полный перебор эффективен, когда
  — информативных признаков не много, $j^* \lesssim 5$;
  — всего признаков не много, $n \lesssim 20..100$.

Недостатки:

— в остальных случаях ооооооочень долго — $O(2^n)$;
— чем больше перебор вариантов, тем больше переобучение (особенно, если лучшие из вариантов существенно различны и одинаково плохи).

Способы устранения:

— эвристические методы сокращённого перебора.

Алгоритм жадного добавления (Add)

Вход: множество F, критерий Q, параметр d;

инициализация: $J_0 := \varnothing$; $Q^* := Q(\varnothing)$;

для $j = 1, \ldots, n$, где j — сложность наборов:

найти признак, наиболее выгодный для добавления:

$$f^* := \arg\min_{f \in F \setminus J_{j-1}} Q\big(J_{j-1} \cup \{f\}\big);$$

добавить этот признак в набор:

$J_j := J_{j-1} \cup \{f^*\}$;

если $Q(J_j) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j)$;

если $j - j^* \geqslant d$ **то вернуть** J_{j^*};

Преимущество: скорость $O(n^2)$, точнее $O(nj^*)$, вместо $O(2^n)$

Недостаток: склонность включать в набор лишние признаки

Способы устранения: Del, Add-Del, Beam Search

Алгоритм поочерёдного добавления и удаления (Add-Del)

Преимущества:

— как правило, лучше, чем Add и Del по отдельности;

— возможны быстрые инкрементные алгоритмы, пример — *шаговая регрессия* (step-wise regression).

Недостатки:

— работает дольше, оптимальность не гарантирует.

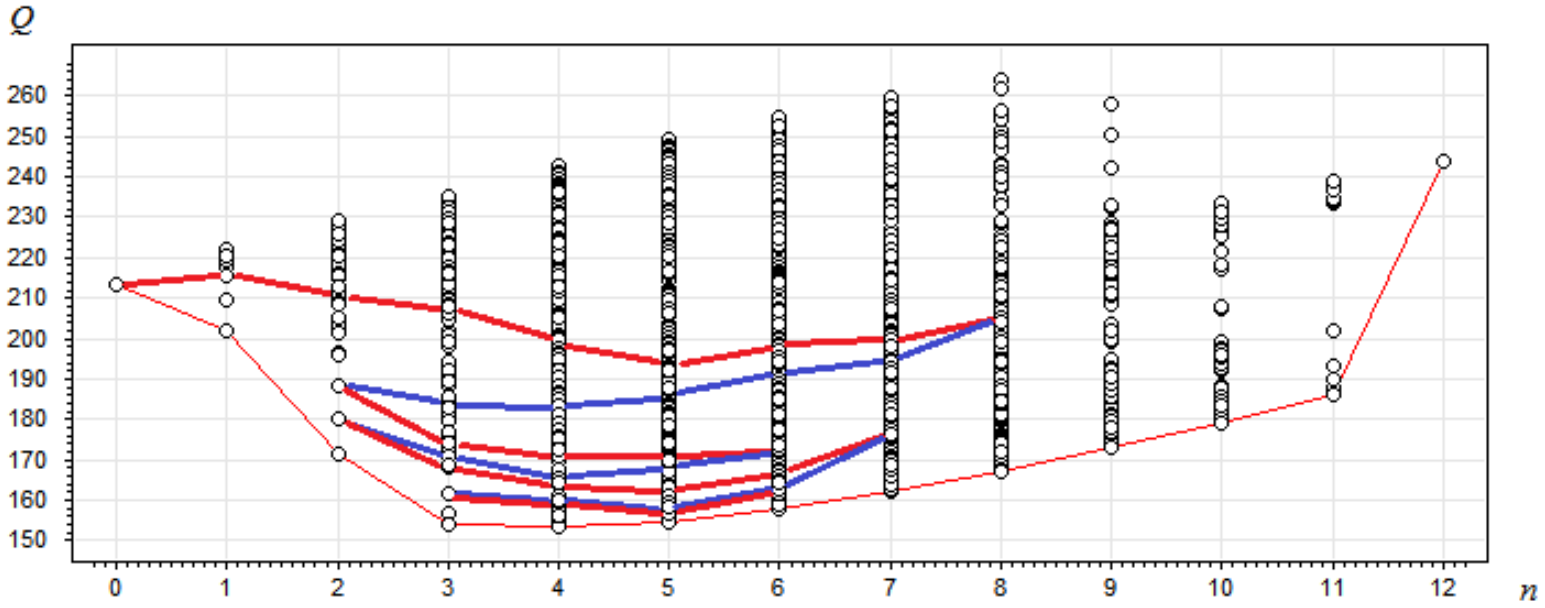

Алгоритм поочерёдного добавления и удаления (Add-Del)

инициализация: $J_0 := \varnothing$; $Q^* := Q(\varnothing)$; $t := 0$;

повторять

  пока $|J_t| < n$ добавлять признаки (итерации Add):

    $t := t + 1$ — началась следующая итерация;

    $f^* := \arg\min\limits_{f \in F \setminus J_{t-1}} Q\big(J_{t-1} \cup \{f\}\big)$; $J_t := J_{t-1} \cup \{f^*\}$;

    если $Q(J_t) < Q^*$ **то** $t^* := t$; $Q^* := Q(J_t)$;

    если $t - t^* \geqslant d$ **то прервать цикл**;

  пока $|J_t| > 0$ удалять признаки (итерации Del):

    $t := t + 1$ — началась следующая итерация;

    $f^* := \arg\min\limits_{f \in J_{t-1}} Q\big(J_{t-1} \setminus \{f\}\big)$; $J_t := J_{t-1} \setminus \{f^*\}$;

    если $Q(J_t) < Q^*$ **то** $t^* := t$; $Q^* := Q(J_t)$;

    если $t - t^* \geqslant d$ **то прервать цикл**;

пока значения критерия $Q(J_{t^*})$ уменьшаются;

вернуть J_{t^*};

Поиск в глубину (DFS, метод ветвей и границ)

Пример: дерево наборов признаков, $n = 4$

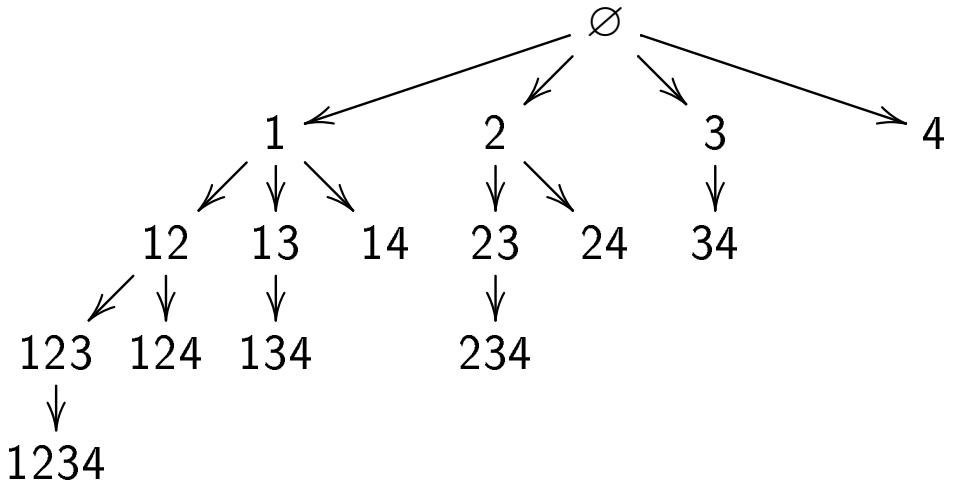

Основные идеи:

- нумерация признаков по возрастанию номеров — чтобы избежать повторов при переборе подмножеств;
- если набор J бесперспективен, то больше не пытаться его наращивать.

Поиск в глубину (DFS, метод ветвей и границ)

Обозначим Q_j^* — значение критерия на самом лучшем наборе мощности j из всех до сих пор просмотренных.

Оценка перспективности: набор J не наращивается, если найдётся j такой, что

$$\begin{cases} Q(J) \geqslant (1+\delta)Q_j^*; \\ |J| \geqslant j + d; \end{cases}$$

$d \geqslant 0$ и $\delta \geqslant 0$ — параметры.

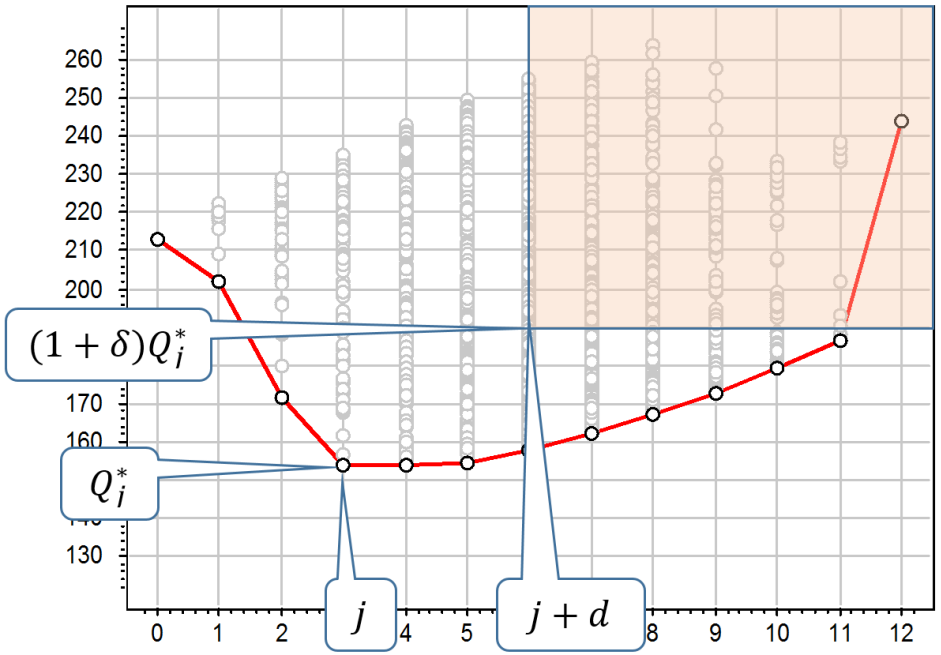

Чем меньше d и δ, тем сильнее сокращается перебор.

Поиск в глубину (DFS, метод ветвей и границ)

Вход: множество F, критерий Q, параметры d и δ;

процедура *нарастить* $(J \subseteq F)$
  если найдётся j: $j \leqslant |J| - d$ и $Q(J) \geqslant (1+\delta)Q^*_j$, **то**
    набор J бесперспективный; **выход**;
  $Q^*_{|J|} := \min\{Q^*_{|J|}, Q(J)\}$;
  для всех $f_s \in F$ таких, что $s > \max\{t \mid f_t \in J\}$:
    нарастить $(J \cup \{f_s\})$;

инициализировать массив лучших значений критерия:
$Q^*_j := Q(\varnothing)$ для всех $j = 1, \ldots, n$;
упорядочить признаки по убыванию информативности;
нарастить $(\varnothing)$;
вернуть J, для которого $Q(J) = \min\limits_{j=1,\ldots,n} Q^*_j$;

Поиск в ширину (beam search, breadth-first search, BFS)

(не пучка, не пучком, не лучом, и не «лучевой поиск»)
Он же *многорядный итерационный алгоритм МГУА*
(Метод Группового Учёта Аргументов А.Г.Ива́хненко)

Принцип неокончательных решений Габора: оставлять больше свободы выбора для принятия последующих решений

Усовершенствуем алгоритм Add:
на каждой j-й итерации будем строить не один набор,
а множество из B_j наборов, называемое *j-м рядом*:

$$R_j = \{J_j^1, \ldots, J_j^{B_j}\}, \quad J_j^b \subseteq F, \quad |J_j^b| = j, \quad b = 1, \ldots, B_j.$$

где $B_j \leqslant B$ — параметр *ширины* (пучка, ряда) *поиска*.

Ивахненко А. Г., Зайченко Ю. П., Димитров В. Д. Принятие решений на основе самоорганизации. 1976.
Ивахненко А. Г., Юрачковский Ю. П. Моделирование сложных систем по экспериментальным данным, 1987.

Усечённый поиск в ширину (Beam Search)

Вход: множество F, критерий Q, параметры d, B;

первый ряд состоит из всех наборов длины 1:
$R_1 := \{\{f_1\}, \ldots, \{f_n\}\}$; $Q^* = Q(\varnothing)$;
для $j = 1, \ldots, n$, где j — сложность наборов:

- отсортировать ряд $R_j = \{J_j^1, \ldots, J_j^{B_j}\}$
  по возрастанию критерия: $Q(J_j^1) \leqslant \ldots \leqslant Q(J_j^{B_j})$;
- **если** $B_j > B$ **то**
  - $R_j := \{J_j^1, \ldots, J_j^B\}$ — оставить B лучших наборов ряда;
- **если** $Q(J_j^1) < Q^*$ **то** $j^* := j$; $Q^* := Q(J_j^1)$;
- **если** $j - j^* \geqslant d$ **то вернуть** $J_{j^*}^1$;
- породить следующий ряд:
  $R_{j+1} := \{J \cup \{f\} \mid J \in R_j,\ f \in F \setminus J\}$;

Усечённый поиск в ширину: дополнительные эвристики

- **Трудоёмкость:**
  $O(Bn^2)$, точнее $O(Bn(j^* + d))$.
- **Проблема дубликатов:**
  после сортировки $Q\left(J_j^1\right) \leqslant \ldots \leqslant Q\left(J_j^{B_j}\right)$ проверить на совпадение только соседние наборы с равными значениями внутреннего и внешнего критерия.
- **Адаптивный отбор признаков:**
  на последнем шаге добавлять к j-му ряду только признаки f с наибольшей информативностью $I_j(f)$:

$$I_j(f) = \sum_{b=1}^{B_j} [f \in J_j^b].$$

Эволюционный алгоритм поиска (идея и терминология)

$J \subseteq F$ — *индивид* (в МГУА «модель»);

$R_t := \{J_t^1, \ldots, J_t^{B_t}\}$ — *поколение* (в МГУА — «ряд»);

$\beta = (\beta_j)_{j=1}^n$, $\beta_j = [f_j \in J]$ — *хромосома*, кодирующая J;

Бинарная операция *скрещивания* (crossover) $\beta = \beta' \times \beta''$:

- вариант 1: $\beta_j = \rho_j \beta'_j + (1 - \rho_j)\beta''_j$, $\rho_j \sim \text{uni}(0, 1)$
- вариант 2: $\beta = (\beta'_1, \ldots, \beta'_s, \beta''_{s+1}, \ldots, \beta''_n)$, $s \sim \text{uni}(1, \ldots, n)$,
  надо задавать «естественное» ранжирование признаков

Унарная операция *мутации* $\beta = {\sim}\beta'$:

- $\beta_j = \rho_j(1 - \beta'_j) + (1 - \rho_j)\beta'_j$, $\rho_j \sim \text{bin}(p_m)$,
  где p_m — параметр *вероятности мутации*.

Эволюционный (генетический) алгоритм

Вход: множество F, критерий Q, параметры: d, p_m,
B — размер популяции, T — число поколений;

инициализировать случайную популяцию из B наборов:
$B_1 := B$; $R_1 := \{J_1^1, \ldots, J_1^{B_1}\}$; $Q^* := Q(\varnothing)$;
для $t = 1, \ldots, T$, где t — номер поколения:
- ранжирование индивидов: $Q(J_t^1) \leqslant \ldots \leqslant Q(J_t^{B_t})$;
- **если** $B_t > B$ **то** селекция: $R_t := \{J_t^1, \ldots, J_t^B\}$;
- **если** $Q(J_t^1) < Q^*$ **то** $t^* := t$; $Q^* := Q(J_t^1)$;
- **если** $t - t^* \geqslant d$ **то вернуть** $J_{t^*}^1$;
- породить $t{+}1$-е поколение путём скрещиваний и мутаций:
- $R_{t+1} := \{\sim(J' \times J'') \mid J', J'' \in R_t\} \cup R_t$;

Эвристики для управления процессом эволюции

- Увеличивать вероятности перехода признаков от более успешного родителя к потомку.
- Накапливать оценки информативности признаков. Чем более информативен признак, тем выше вероятность его включения в набор во время мутации.
- Применение совокупности критериев качества.
- Скрещивать только лучшие индивиды (элитаризм).
- Переносить лучшие индивиды в следующее поколение.
- В случае стагнации увеличивать вероятность мутаций.
- Параллельно выращивается несколько изолированных популяций (островная модель эволюции).

Попытка обоснования. Теорема схемы

Схема — вектор $H = (h_1, \ldots, h_n)$, где $h_j \in \{0, 1, *\}$

$o(H)$ — *порядок схемы*, число не$*$ в схеме

$d(H)$ — *длина схемы*, расстояние между первым и последним не$*$, число мест, в которых кроссовер может нарушить схему

$f(H, t)$ — *степень приспособленности* схемы, среднее Q по всем векторам, подходящим под схему в поколении t

$\bar{f}(t) = f(*^n, t)$ — *средняя приспособленность* популяции

p_c — вероятность кроссовера (только второй вариант)

p_m — вероятность мутации

Теорема схемы [Холланд, 1975]

Число индивидов схемы H в популяции поколения t:

$$\mathrm{E}m(H, t+1) \geqslant m(H, t)\frac{f(H, t)}{\bar{f}(t)}\left(1 - p_c\frac{d(H)}{n-1} - p_m o(H)\right)$$

Интерпретация теоремы схемы

Число индивидов схемы H в популяции поколения t:

$$\mathrm{E}m(H,t+1) \geqslant m(H,t)\frac{f(H,t)}{\bar{f}(t)}\left(1 - p_c\frac{d(H)}{n-1} - p_m o(H)\right)$$

- *Строительный блок* — схема H с низким порядком $o(H)$, короткой длиной $d(H)$, высокой приспособленностью $f(H,t)$
- Если приспособленность строительного блока оказалась выше средней в популяции, то число его индивидов будет расти экспоненциально в последующих популяциях
- **Гипотеза** (building block hypothesis): «строительные блоки объединяются, чтобы сформировать ещё лучшие блоки»

John Henry Holland. Adaptation in natural and artificial systems. 1992
David White. An overview of schema theory. 2014

Обобщение: случайный поиск с адаптацией (СПА)

Вход: множество F, критерий Q, параметры: d,
B — размер популяции, T — число поколений;

инициализация $p_1 = \dots = p_n := 1/n$;

популяция $R_1 := \{J_1^1, \dots, J_1^{B_1} \sim \{p_1, \dots, p_n\}\}$; $Q^* := Q(\varnothing)$;

для $t = 1, \dots, T$, где t — номер поколения:

- ранжирование индивидов: $Q(J_t^1) \leqslant \dots \leqslant Q(J_t^{B_t})$;
- **если** $B_t > B$ **то** селекция: $R_t := \{J_t^1, \dots, J_t^B\}$;
- **если** $Q(J_t^1) < Q^*$ **то** $t^* := t$; $Q^* := Q(J_t^1)$;
- **если** $t - t^* \geqslant d$ **то вернуть** $J_{t^*}^1$;
- увеличить p_j для признаков из лучших наборов;
- уменьшить p_j для признаков из худших наборов;
- породить $t{+}1$-е поколение из B_t наборов:
  $R_{t+1} := \{J_{t+1}^1, \dots, J_{t+1}^{B_t} \sim \{p_1, \dots, p_n\}\} \cup R_t$;

Н.Г.Загоруйко, В.Н.Ёлкина, Г.С.Лбов. Алгоритмы обнаружения эмпирических закономерностей. 1985

Научная школа А. Г. Ива́хненко

Метод группового учёта аргументов, МГУА (Group Method of Data Handling, GMDH)

Принцип *самоорганизации моделей* — перебор структур и оптимизация параметров модели

- Качество моделей оценивается в процессе перебора по многим *внешним критериям:*
  — скользящий контроль
  — помехоустойчивость моделирования
  — баланс / согласованность прогнозов и др.
- Первая 8-слойная глубокая нейросеть (1965)
- Сотни применений, около 300 диссертаций

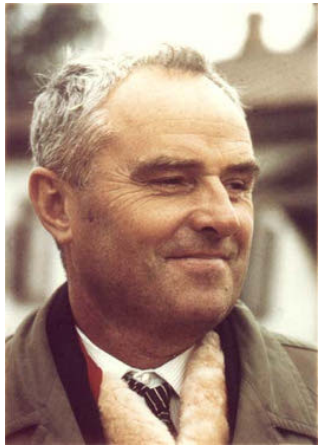

Алексей Григорьевич Ива́хненко (1913–2007)

Ивахненко А. Г., Лапа В. Г. Кибернетические предсказывающие устройства. 1965.
Ivakhnenko A. G. Heuristic self-organization in problems of engineering cybernetics. 1970.
Ивахненко А. Г. Индуктивный метод самоорганизации моделей сложных систем. 1982.

Символьная регрессия

1. система порождающих функций $g_k(x; w)$ с параметрами w
2. механизм перебора суперпозиций (генетическое программирование)
   — обмен поддеревьями
   — случайные мутации
3. обучение параметров суперпозиции: SG
4. отбор моделей по внешним критериям
5. ограничение сложности суперпозиций
   — регуляризация, байесовское обучение

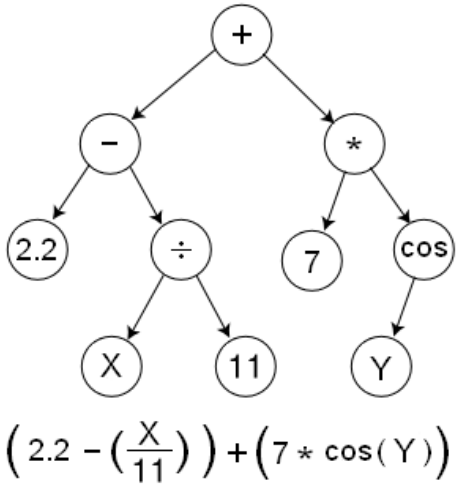

J.Koza. On the programming of computers by means of natural selection. 1992
Ying Jin et al. Bayesian Symbolic Regression. 2019
Р.А.Сологуб. Алгоритмы индуктивного порождения и трансформации моделей в задачах нелинейной регрессии. Диссертация к.ф.-м.н., 2014.

Пример. Эксперимент на синтетических данных

Модель: $y = f(\mathrm{w}, \mathrm{x}) = \sin(x_1) * \sin(w_1 x_2 + w_2)$

Выборка из 380 точек, $x_i \in \mathbb{R}^2$, $y_i \in \mathbb{R}$

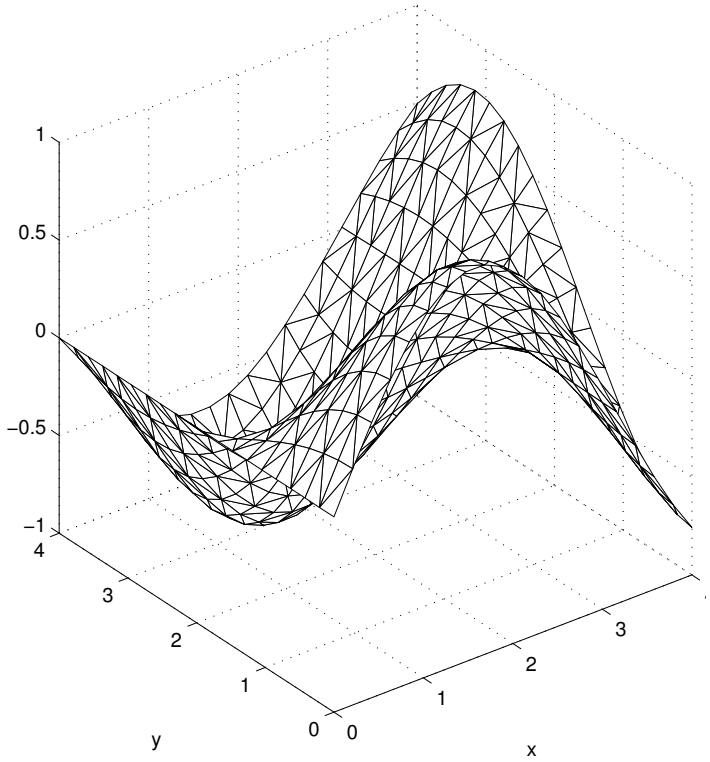

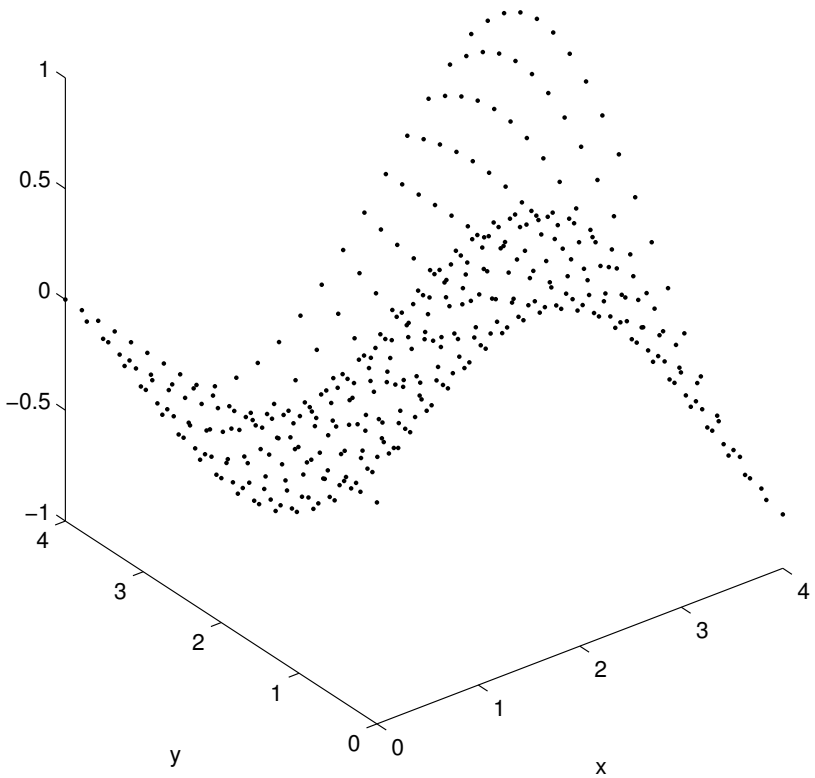

Р.А.Сологуб. Алгоритмы индуктивного порождения и трансформации моделей в задачах нелинейной регрессии. Диссертация к.ф.-м.н., 2014.

Пример. Система порождающих функций

Функция	Описание	Параметры
	$g(x_1, x_2; w)$	
plus	$y = x_1 + x_2$	–
times	$y = x_1 x_2$	–
	$g(x_1; w)$	
divide	$y = 1/x$	–
multiply	$y = ax$	a
add	$y = x + a$	a
normal	$y = \frac{\lambda}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\xi)^2}{2\sigma^2}\right) + a$	λ, σ, ξ, a
linear	$y = ax + b$	a, b
parab	$y = ax^2 + bx + c$	a, b, c
sin	$y = \sin(x)$	–
logsig	$y = \frac{\lambda}{1+\exp(-\sigma(x-\xi))} + a$	λ, σ, ξ, a

Пример. Перебор моделей-претендентов

$\text{normal}(w_{1:3}, x_2)$

normal

x_2

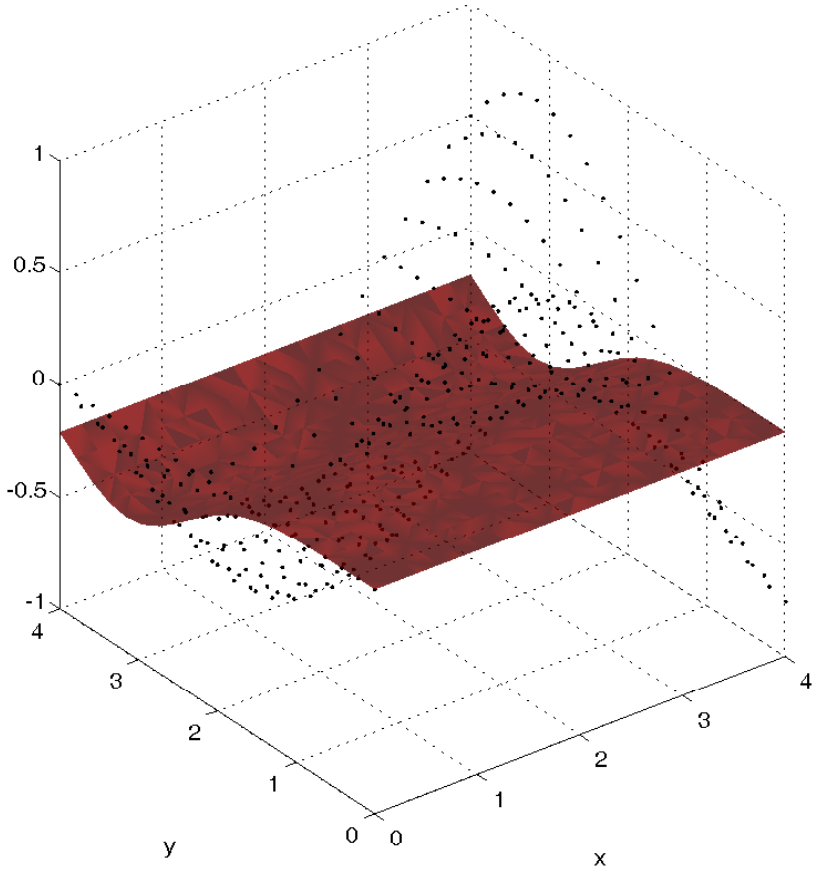

Пример. Перебор моделей-претендентов

$$\text{plus}(\varnothing,\text{times}(\varnothing,\text{plus}(\varnothing,x_2,x_1),\text{linear}(w_{1:2},x_1)),\text{linear}(w_{3:4},x_2))$$

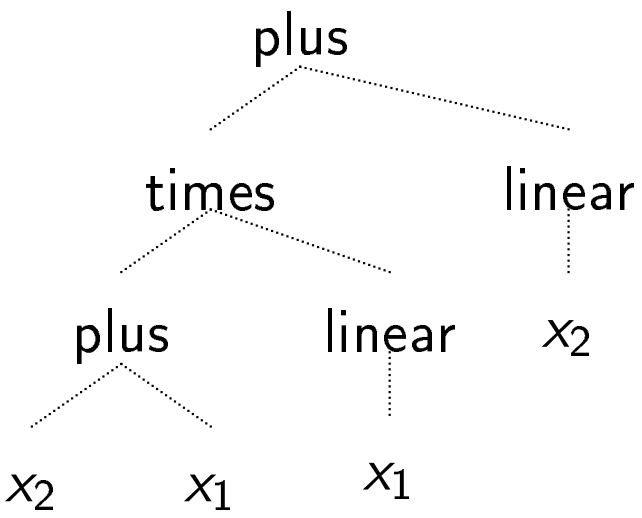

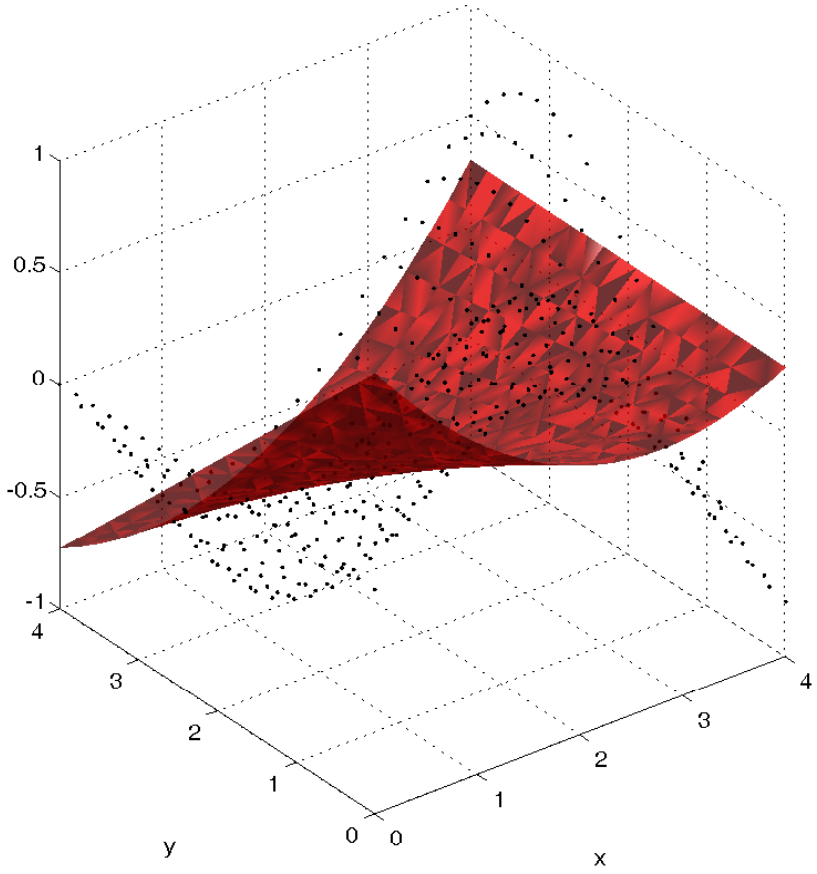

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\text{times}(\varnothing,\text{plus}(\varnothing,x_2,\text{linear}(w_{1:2},x_1)),\text{linear}(w_{3:4},x_1)),x_2)$$

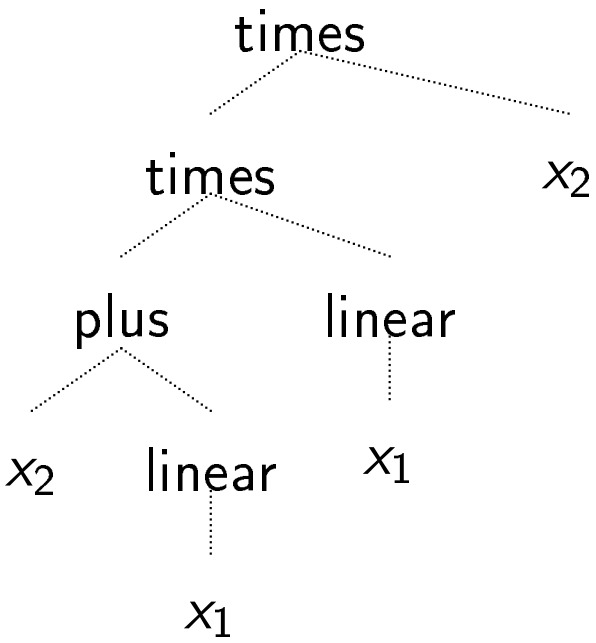

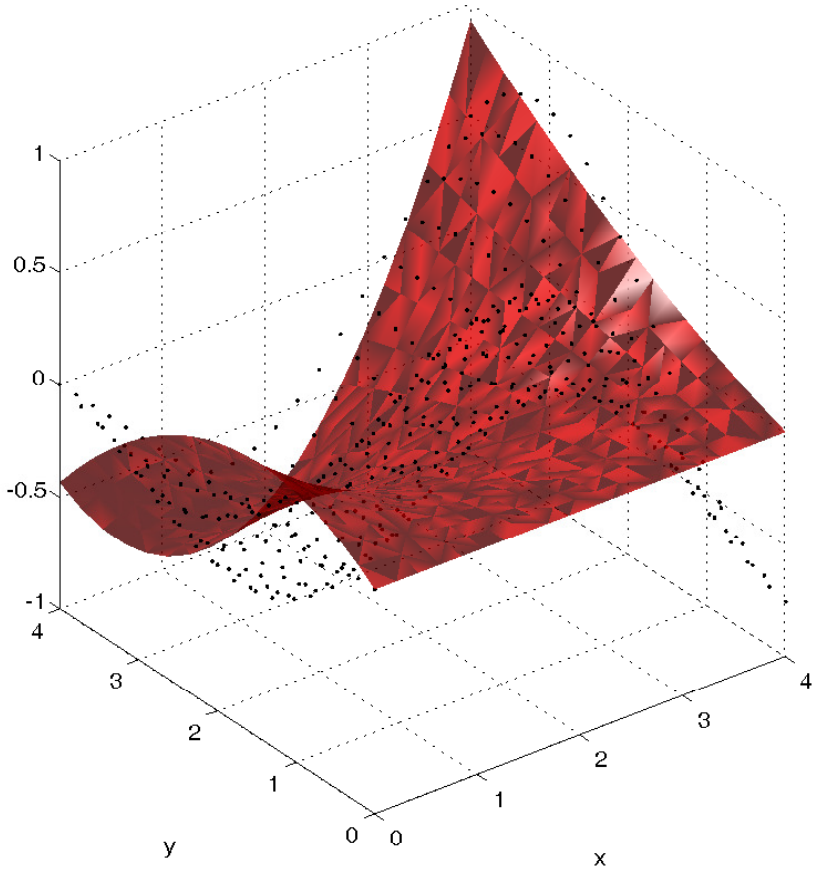

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\text{times}(\varnothing,\text{plus}(\varnothing,\text{parab}(w_{1:3},x_2),x_2),\sin(\varnothing,x_1)),\sin(\varnothing,x_1))$$

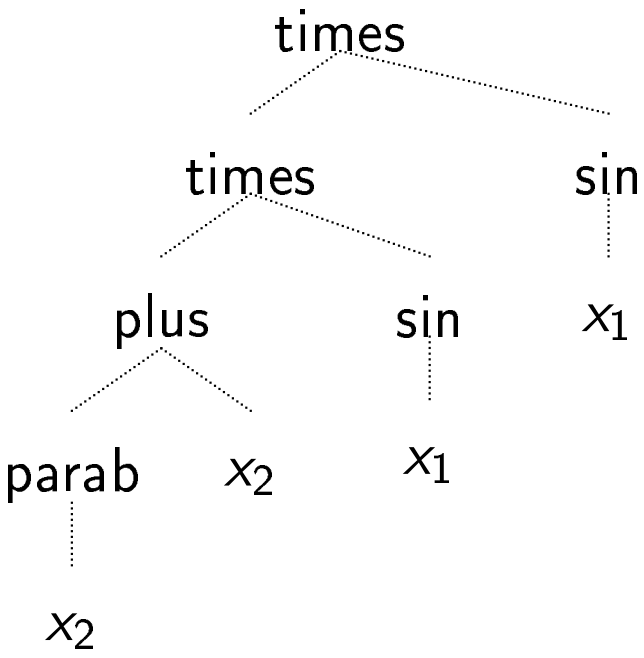

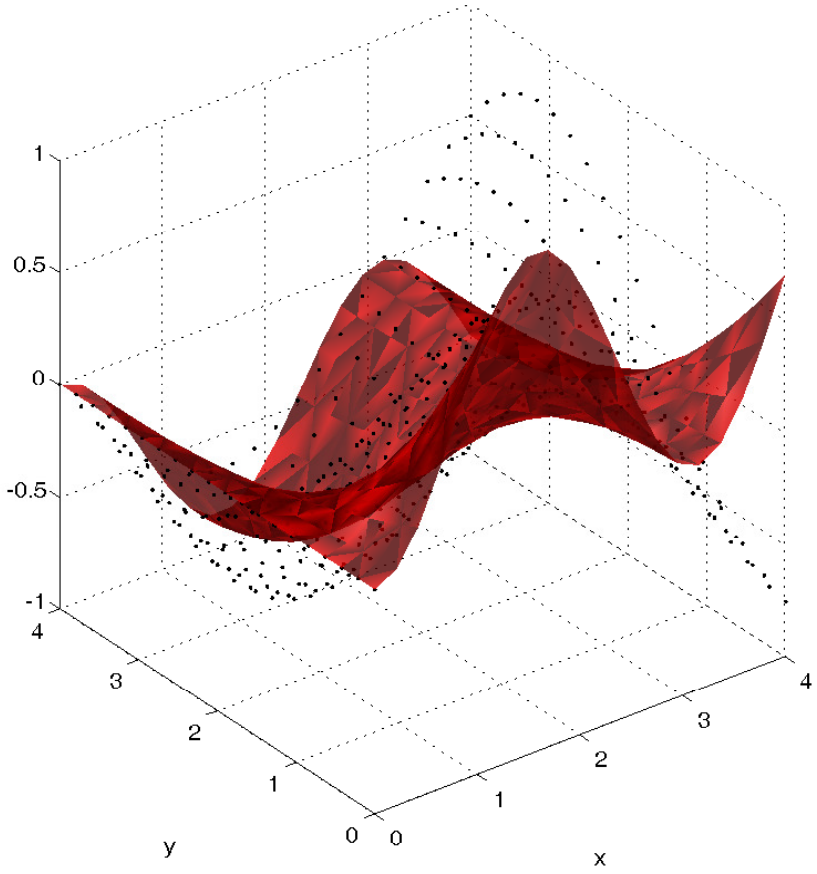

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\text{plus}(\varnothing,\text{linear}(w_{1:2},x_1),\sin(\varnothing,x_2)),\sin(\varnothing,x_1))$$

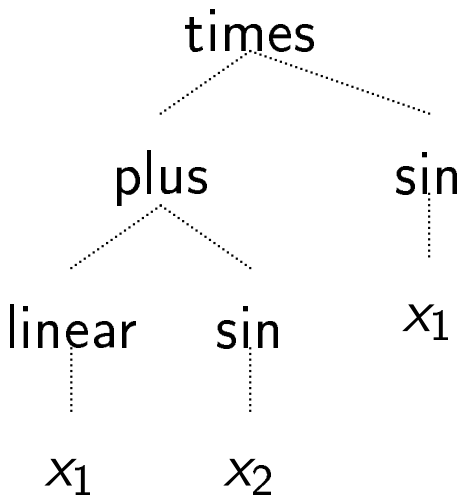

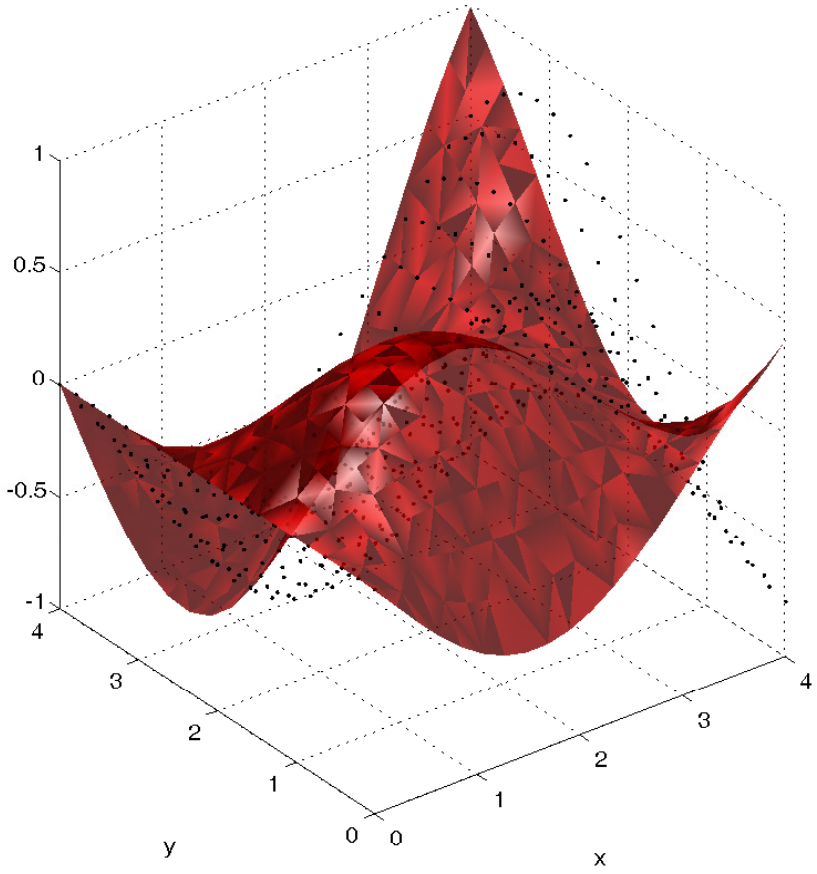

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\text{plus}(\varnothing,\text{parab}(w_{1:3},\text{parab}(w_{4:6},x_2)),\sin(\varnothing,x_1)),\sin(\varnothing,x_1))$$

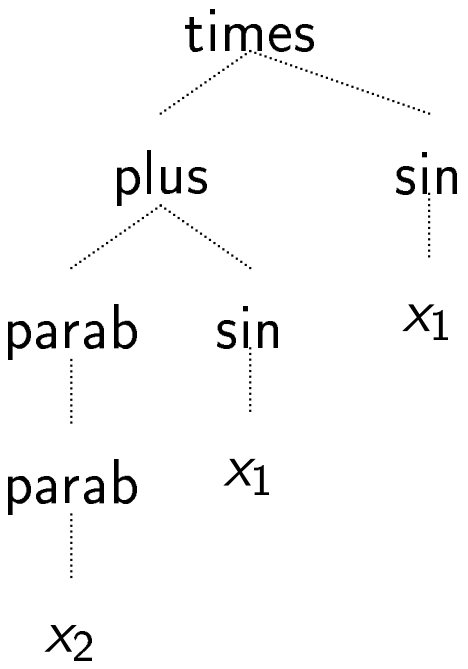

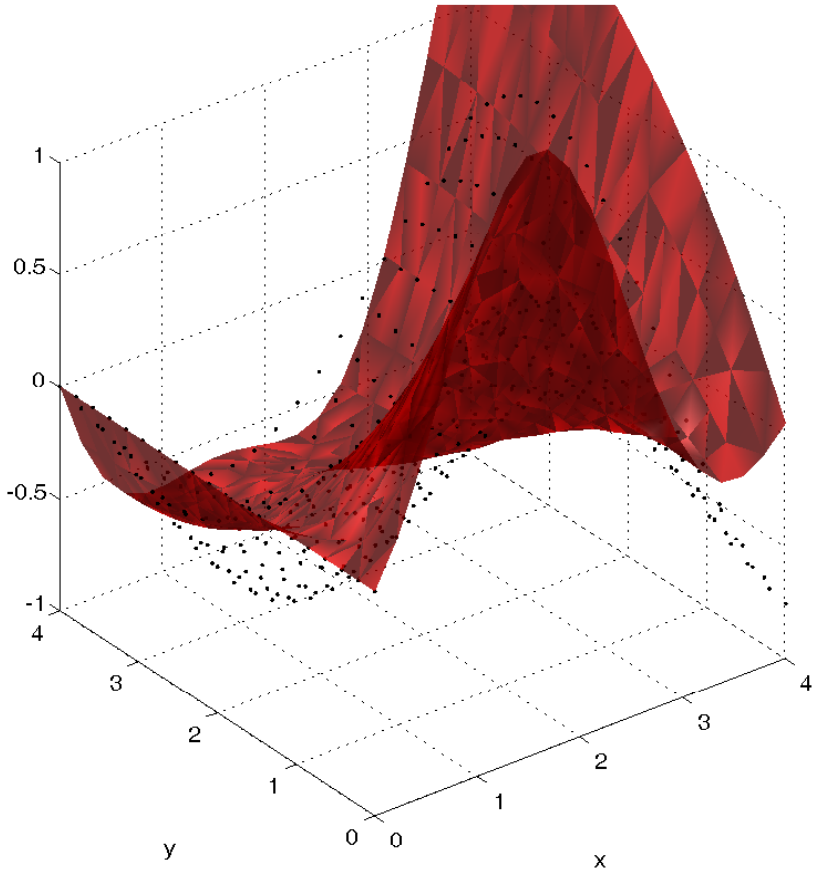

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\text{plus}(\varnothing,\text{plus}(w_1,\text{linear}(w_{2:3},x_1)),\text{linear}(w_{4:5},x_2)),\sin(\varnothing,\sin(\varnothing,x_1)))$$

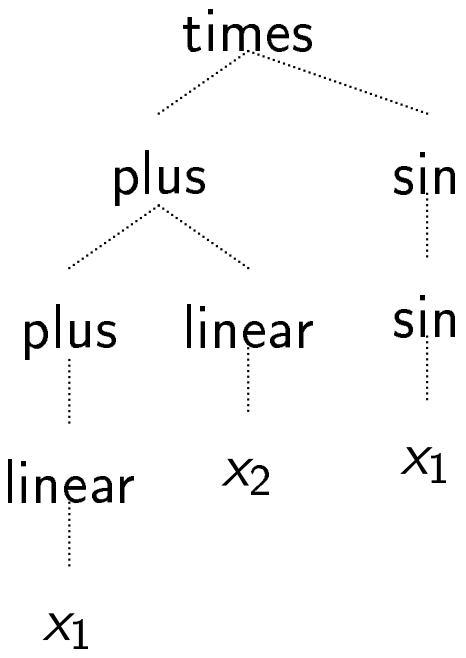

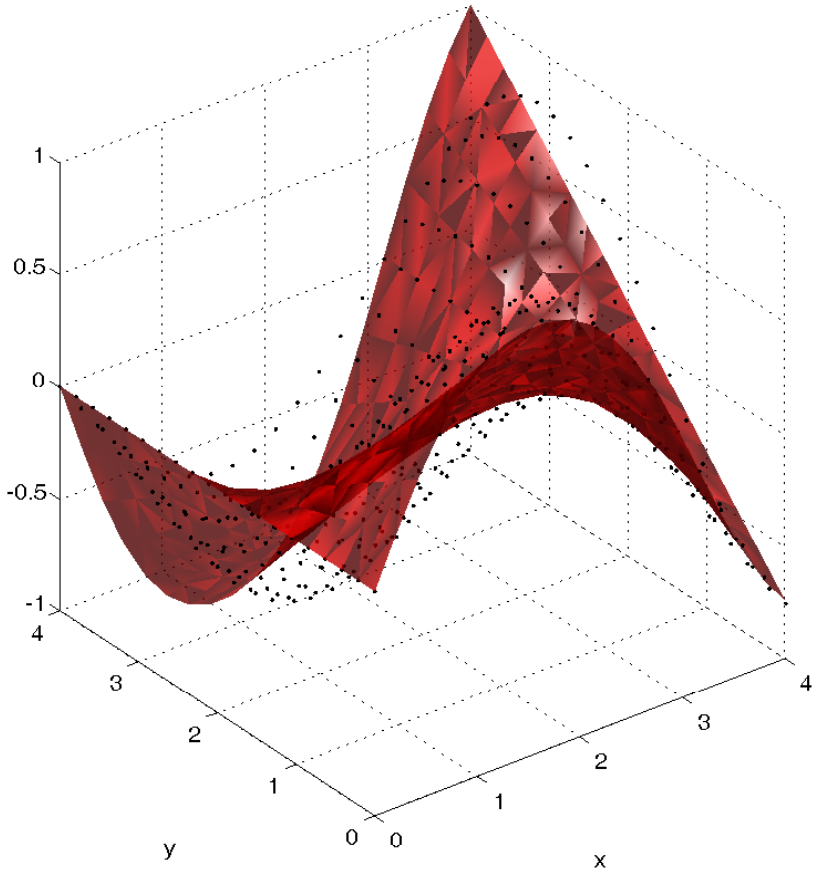

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\text{parab}(w_{1:3},\text{linear}(w_{4:5},x_2)),\text{linear}(w_{6:7},\sin(\varnothing,x_1)))$$

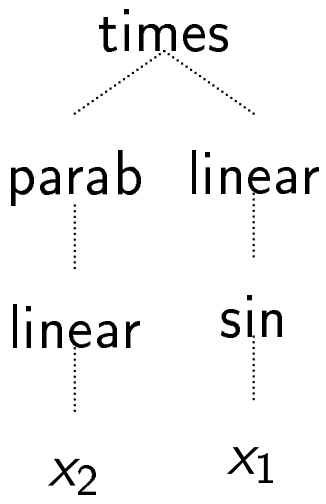

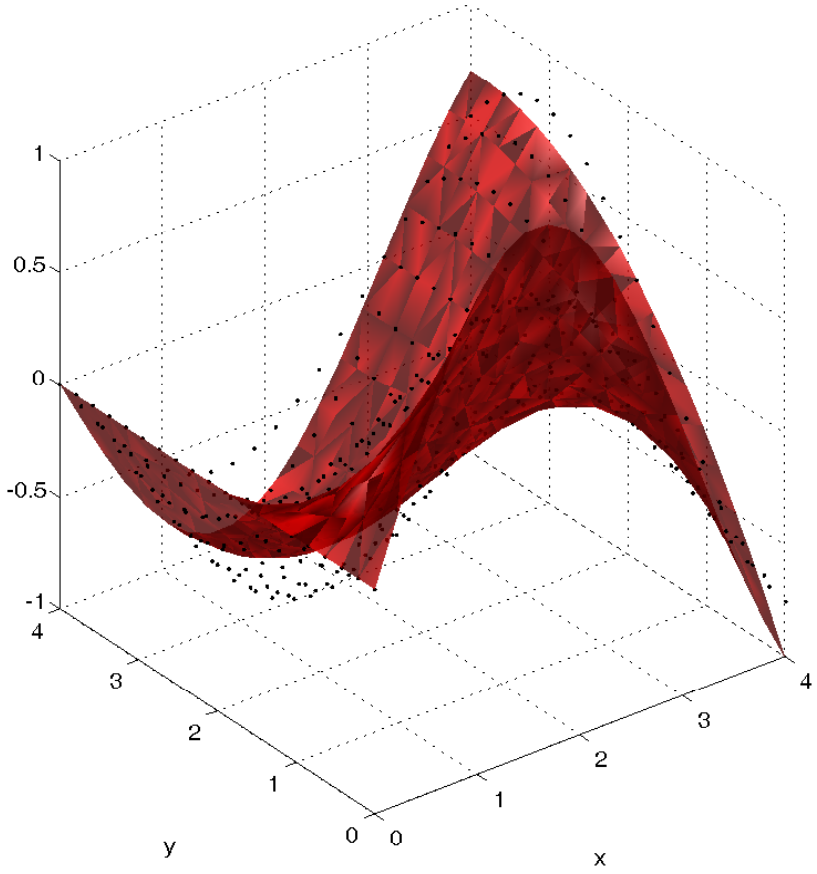

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\text{plus}(\varnothing,\text{parab}(w_{1:3},x_2),\sin(\varnothing,x_2)),\sin(\varnothing,x_1))$$

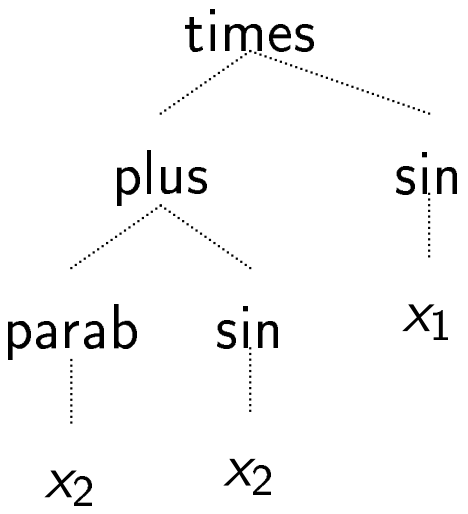

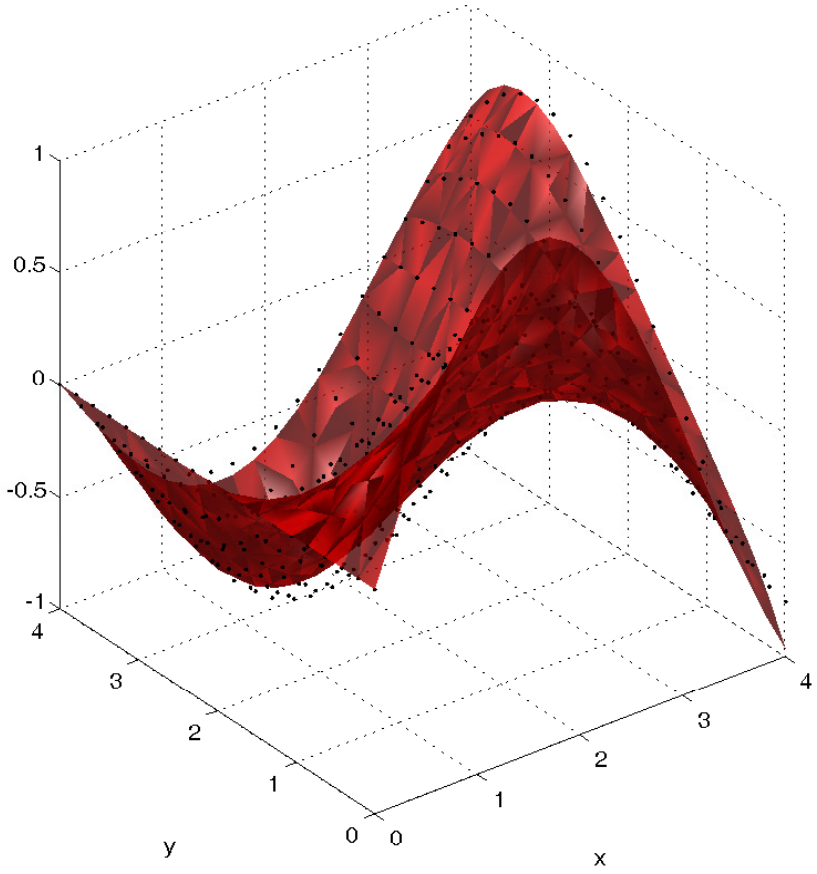

Пример. Перебор моделей-претендентов

$$\text{times}(\varnothing,\sin(\varnothing,\text{linear}(w_{1:2},x_2)),\sin(\varnothing,x_1))$$

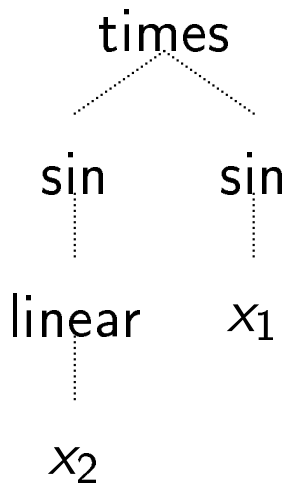

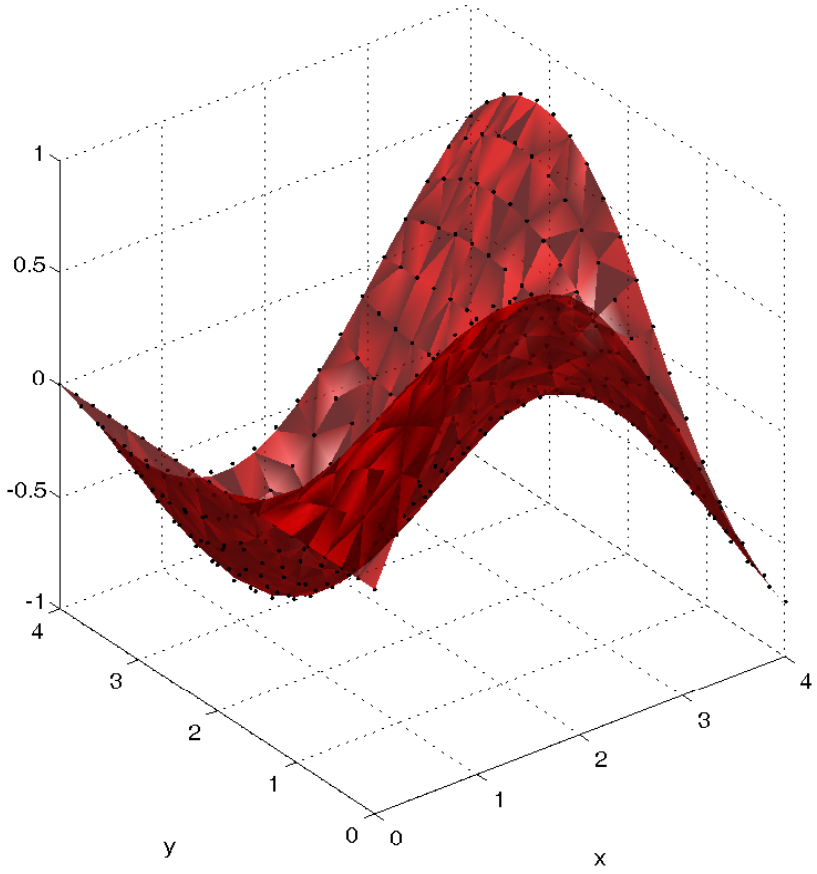

Идеальная модель найдена!

Р.А.Сологуб. Алгоритмы индуктивного порождения и трансформации моделей в задачах нелинейной регрессии. Диссертация к.ф.-м.н., 2014.

Резюме. Методы отбора признаков

- Комбинаторный отбор признаков может использовать любые эвристические методы дискретной оптимизации

$$Q(J) \to \min_{J \subseteq F}$$

- $Q(J)$ должен быть внешним критерием, с характерным минимумом по сложности модели
- Большинство эвристик эксплуатируют две основные идеи:
  — признаки ранжируются по их полезности
  — $Q(J)$ изменяется не сильно при малом изменении J
- МГУА, ЭА и СПА очень похожи — на их основе можно изобретать новые «симбиотические» мета-эвристики
- Символьная регрессия — перебор суперпозиций формул
- Генетическое программирование — перебор программ