Методы машинного обучения. Обучение без учителя: векторизация графовых и текстовых данных

Воронцов Константин Вячеславович
www.MachineLearning.ru/wiki?title=User:Vokov
вопросы к лектору: k.vorontsov@iai.msu.ru

материалы курса:
github.com/MSU-ML-COURSE/ML-COURSE-25-26
орг.вопросы по курсу: ml.cmc@mail.ru

ВМК МГУ • 17 марта 2026

Содержание

1. **Многомерное шкалирование**
   - Постановка задачи многомерного шкалирования
   - Визуализация данных
   - Векторизация отношения соседства
2. **Векторные представления графов**
   - Модели матричных разложений
   - Модель случайных блужданий
   - Графовые автокодировщики
3. **Векторные представления текста**
   - Гипотеза дистрибутивной семантики
   - Модели word2vec
   - Модель FastText

Примеры прикладных задач с графовыми данными

Дано: попарные расстояния между объектами $R(x_i, x_j)$
Найти: представления объектов в $\mathbb{R}^d$, сохраняющие расстояния

Дано: молекулярные графы (вершины-атомы, рёбра-связи)
Найти: (предсказать) свойства химических соединений

Дано: граф связей между пользователями соцсети
Найти: сообщества, социальные роли, центры влияния

Дано: граф транзакций между клиентами и товарами
Найти: рекомендации, аномалии, прогнозы спроса

Дано: граф транспортной сети
Найти: прогноз трафика, оптимальные маршруты

Основные типы задач:

- классификация вершин графа
- рекомендации, предсказание связей (Link Prediction)
- классификация графа или компонент связности целиком

Многомерное шкалирование (multidimensional scaling, MDS)

Дано: $(i,j) \in E$ — выборка рёбер графа $\langle V, E\rangle$
R_{ij} — расстояния между вершинами ребра (i,j)
Например, R_{ij} — длина кратчайшего пути по графу (IsoMAP)

Найти: векторные представления вершин $z_i \in \mathbb{R}^d$ так, чтобы близкие вершины (в смысле малого R_{ij}) имели близкие z_i и z_j

Критерий стресса (stress):

$$\sum_{(i,j)\in E} R_{ij}^{\gamma}\big(\rho(z_i,z_j) - R_{ij}\big)^2 \to \min_{Z}, \quad Z \in \mathbb{R}^{V\times d},$$

где $\rho(z_i,z_j) = \|z_i - z_j\|$ — обычно евклидово расстояние,
R_{ij}^{γ} — веса, важнее расстояния большие ($\gamma > 0$) или малые ($\gamma < 0$)

Обычно решается методом стохастического градиента (SG)

I.Chami et al. Machine learning on graphs: a model and comprehensive taxonomy. 2020.

Многомерное шкалирование для визуализации данных

При $d = 2$ осуществляется проекция выборки на плоскость

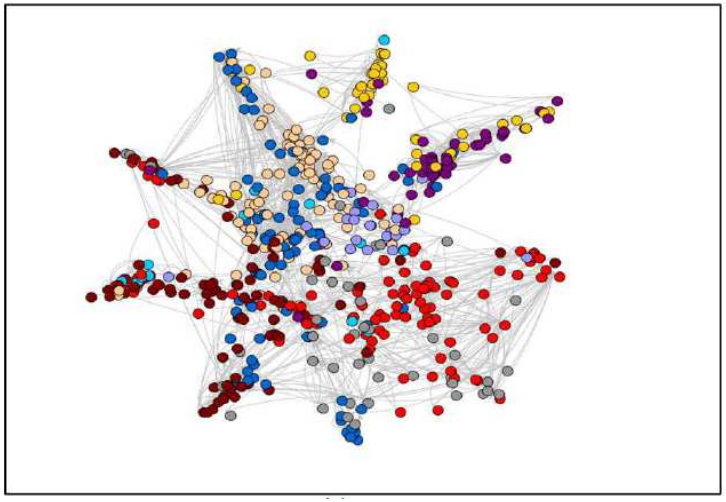

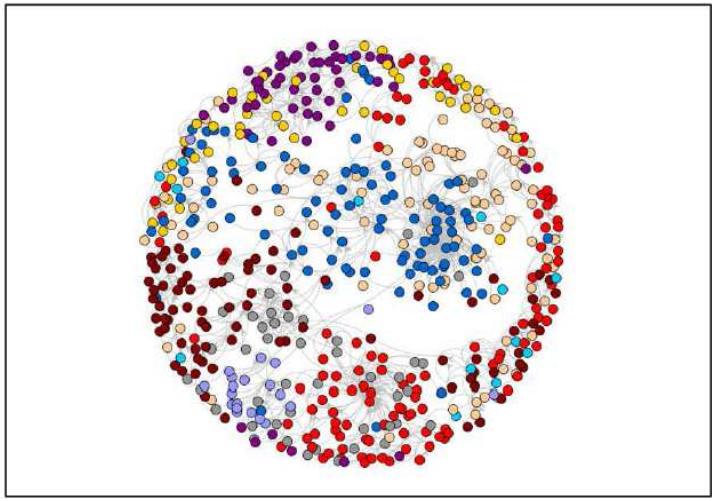

- используется для визуализации кластерных структур
- форму облака точек можно настраивать весами и метрикой
- наиболее популярные методы — t-SNE, UMAP
- недостаток всех методов — искажения неизбежны

Laurens van der Maaten, Geoffrey Hinton. Visualizing data using t-SNE. 2008
Leland McInnes, John Healy, James Melville. UMAP: Uniform manifold approximation and projection for dimension reduction. 2020

Вероятностная модель векторного представления соседства (Stochastic Neighbor Embedding, SNE)

Дано: исходные точки $x_i \in \mathbb{R}^n, \quad i = 1, \ldots, \ell$

Найти: точки на карте-проекции $z_i \in \mathbb{R}^d, \quad i = 1, \ldots, \ell, \quad d \ll n$

Критерий: расстояния $\|z_i - z_j\|$ близки к исходным $\|x_i - x_j\|$

Вероятностная модель события «j является соседом i»
на основе перенормированных гауссовских распределений:

$$p(j|i) = \operatorname*{norm}_{j \neq i} \exp\Big(-\frac{1}{2\sigma_i^2}\|x_i - x_j\|^2\Big) \text{ — в исходном пространстве;}$$

$$q(j|i) = \operatorname*{norm}_{j \neq i} \exp\Big(-\|z_i - z_j\|^2\Big) \text{ — в пространстве проекции;}$$

где $p(j) = \operatorname*{norm}_j(z_j) = \frac{z_j}{\sum_k z_k}$ — операция нормировки вектора.

Максимизация правдоподобия (стохастическим градиентом):

$$\sum_i \sum_{j \neq i} p(j|i) \ln q(j|i) \;\to\; \max_{\{z_i\}}$$

Преимущества метода SNE

- Преобразование расстояний в вероятности устраняет дисбалансы между большими и малыми расстояниями
- Дисбаланс между точками с большой и малой плотностью соседей выравнивается настройкой σ_i по перплексии

$H(i) = -\sum_j p(j|i) \log_2 p(j|i)$ — энтропия распределения $p(j|i)$;
$2^{H(i)}$ это *перплексия* = «эффективное число соседей у x_i»
(если $p(j|i) = \frac{1}{k}$, то $2^{H(i)} = k$); обычно перплексия = 5..50.

Выбор перплексии может существенно влиять на вид проекции:

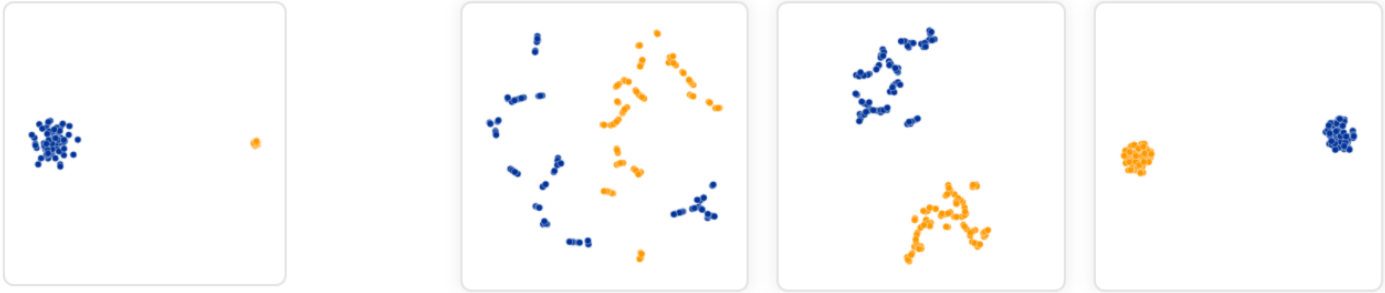

Original Perplexity: 2 Perplexity: 5 Perplexity: 30

G.E.Hinton, S.T.Roweis. Stochastic Neighbor Embedding. 2002.

Вероятностная модель t-SNE: два усовершенствования SNE

Проблема скученности в SNE: окрестность вмещает гораздо больше точек в n-мерном пространстве, чем в d-мерном

- Использование t-распределения Стьюдента с более тяжёлым хвостом и симметричного совместного распределения $q(i,j)$:

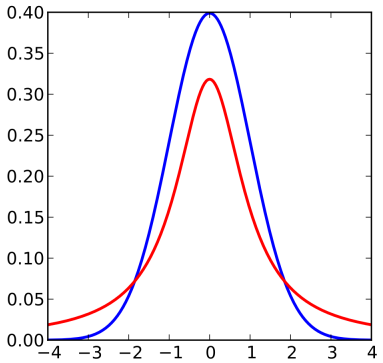

$$q(i,j) = \underset{(i,j)\colon i\neq j}{\operatorname{norm}} \left(1 + \|z_i - z_j\|^2\right)^{-1}$$

- Использование совместного распределения $p(i,j)$:

$$p(i,j) = \tfrac{1}{2\ell}\big(p(j|i) + p(i|j)\big)$$

Максимизация правдоподобия (стохастическим градиентом):

$$\sum_{(i,j)\colon j\neq i} p(i,j) \ln q(i,j) \to \max_{\{z_i\}}$$

L.J.P. van der Maaten, G.Hinton. Visualizing data using t-SNE. 2008

Преимущества и недостатки t-SNE

Лучшее представление структур сходства по сравнению с другими методами многомерного шкалирования (mnist)

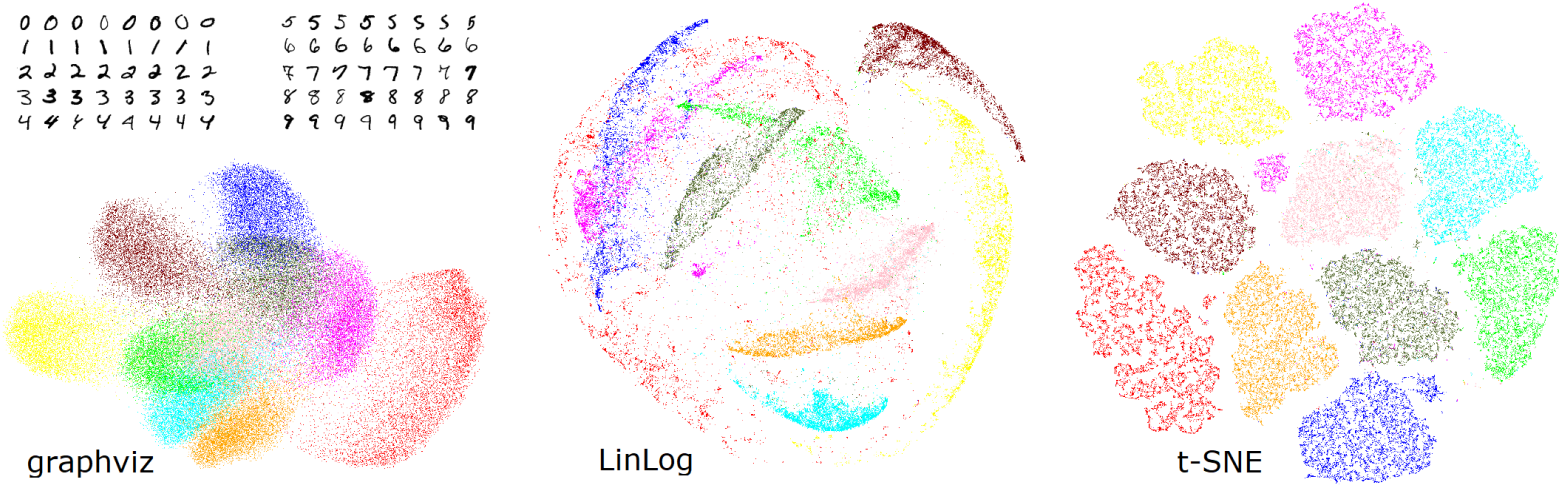

Ложные кластерные структуры при низкой перплексии

Размеры кластеров и расстояния между ними неинформативны

Трудно отличить реальные структуры от артефактов метода

Нет ясного критерия качества для подбора перплексии

M.Wattenberg, F.Viegas, I.Johnson (Google). How to use t-SNE effectively. 2016. https://distill.pub/2016/misread-tsne

Графовые матричные разложения (graph factorization)

Дано: граф $\langle V, E\rangle$
S_{ij} — близость между вершинами $(i,j) \in E$
Например, $S_{ij} = [(i,j) \in E]$ — матрица смежности вершин

Найти: векторные представления вершин, так, чтобы близкие (по графу) вершины имели близкие векторы.

Критерий для неориентированного графа (S симметрична):

$$\left\|S - ZZ^{\mathsf{T}}\right\|_E = \sum_{(i,j)\in E} \left(\langle z_i, z_j\rangle - S_{ij}\right)^2 \to \min_Z, \quad Z \in \mathbb{R}^{V\times d}$$

Критерий для ориентированного графа (S несимметрична):

$$\left\|S - \Phi\Theta^{\mathsf{T}}\right\|_E = \sum_{(i,j)\in E} \left(\langle \varphi_i, \theta_j\rangle - S_{ij}\right)^2 \to \min_{\Phi,\Theta}, \quad \Phi, \Theta \in \mathbb{R}^{V\times d}$$

Обычно решается методом стохастического градиента (SG)

I.Chami et al. Machine learning on graphs: a model and comprehensive taxonomy. 2020.

Модель случайных блужданий для больших графов

Дано: граф $\langle V, E\rangle$

Найти: векторные представления вершин φ_v, θ_v, $v \in V$

Критерий для вероятностной модели P($\exists$ короткий путь $i \to j$)

$$\sum_{i\in V}\Bigg(\sum_{j\in C_i}\ln\sigma\big(\langle\varphi_i,\theta_j\rangle\big)+\sum_{j\in\bar{C}_i}\ln\sigma\big(-\langle\varphi_i,\theta_j\rangle\big)\Bigg)\to\max_{\Phi,\Theta}$$

C_i — окрестность («контекст») вершины i, сэмплируемая случайным блужданием длины k (DeepWalk, node2vec)

$\bar{C}_i$ — далёкие от i вершины, сэмплируемые $j \sim p(j)^{3/4}$

Параметризация случайных блужданий:

вероятность $p(v{\to}x_k)$ после перехода $t{\to}v$

$p\downarrow$ $q\uparrow$ — ближе к поиску в ширину (BFS)

$p\uparrow$ $q\downarrow$ — ближе к поиску в глубину (DFS)

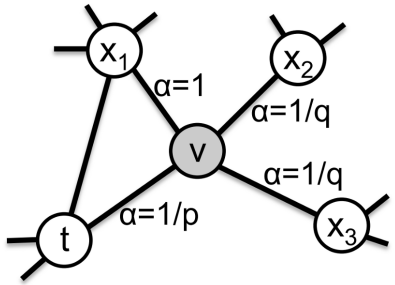

B.Perozzi et al. DeepWalk: online learning of social representations. SIGKDD-2014.
A.Grover, J.Leskovec. Node2vec: scalable feature learning for networks. SIGKDD-2016.

Векторные представления графов как автокодировщики

Дано: граф $\langle V, E\rangle$
$X = (x_i \in \mathbb{R}^n \colon i \in V)$ — векторы признаков в вершинах графа
$W = (w_{ij} \in \mathbb{R} \colon (i,j) \in E)$ — числовые данные о рёбрах графа
$Y = (y_i \in Y \colon i \in V')$ — целевой отклик на вершинах из $V' \subseteq V$

Найти:
$Z = (z_i \in \mathbb{R}^d \colon i \in V)$ — векторные представления вершин графа
параметры α кодировщика $z_i(\alpha) = f_i(W, X, \alpha)$
параметры β декодировщика $\hat{w}_{ij} = g(z_i, z_j, \beta)$
параметры γ предсказательной модели $y_i = \hat{y}(z_i, \gamma)$

Критерий: потери реконструкции рёбер $\hat{w}_{ij}$ по вершинам (z_i, z_j) и потери предсказательного моделирования y_i по z_i:

$$\sum_{(i,j)\in E} \mathscr{L}\big(g(z_i(\alpha), z_j(\alpha), \beta), w_{ij}\big) + \lambda \sum_{i \in V'} \tilde{\mathscr{L}}\big(\hat{y}(z_i(\alpha), \gamma), y_i\big) \to \min_{\alpha,\beta,\gamma}$$

I.Chami et al. Machine learning on graphs: a model and comprehensive taxonomy. 2020.

GraphEDM: обобщённый автокодировщик на графах

Graph Encoder Decoder Model — обобщает более 30 моделей:

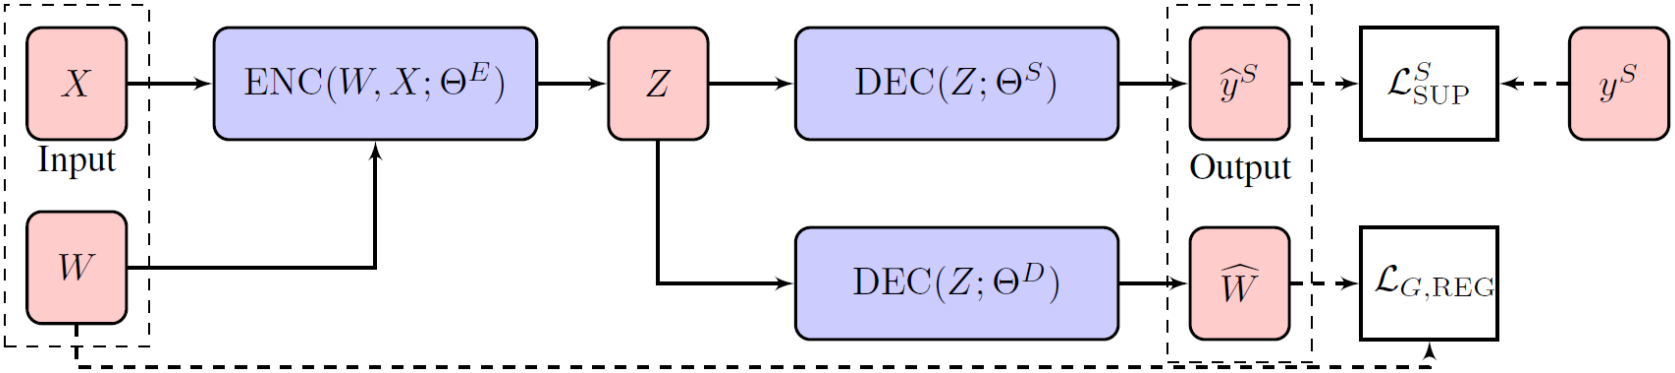

$W \in \mathbb{R}^{V \times V}$ — входные данные о рёбрах
$X \in \mathbb{R}^{V \times n}$ — входные признаковые описания вершин
$Z \in \mathbb{R}^{V \times d}$ — векторные представления вершин графа
$\mathrm{DEC}(Z; \Theta^D)$ — декодер, реконструирующий данные о рёбрах
$\mathrm{DEC}(Z; \Theta^S)$ — декодер, решающий supervised-задачу
y^S — данные о вершинах в supervised-задаче
$\mathcal{L}$ — функции потерь

I.Chami et al. Machine learning on graphs: a model and comprehensive taxonomy. 2020.

Эволюция подходов машинного обучения в анализе текстов

Декомпозиция задач по уровням пирамиды NLP

- морфологический анализ, лемматизация, опечатки
- синтаксический анализ, выделение терминов, NER
- семантический анализ, выделение фактов, тем

Контекстно независимые эмбединги слов в вероятностных моделях языка на основе матричных разложений

- модели дистрибутивной семантики word2vec [Mikolov, 2013], FastText [Bojanowski, 2016]
- тематические модели LDA [Blei, 2001], ARTM [2014]

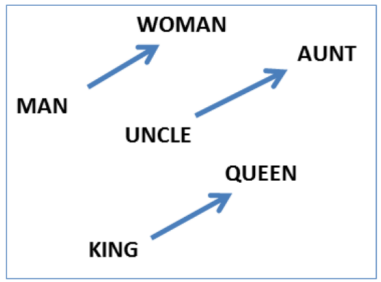

Контекстно зависимые нейросетевые эмбединги

- рекуррентные нейронные сети LSTM [1997]
- модели внимания и трансформеры NMT [2015] BERT [2018], GPT-3 [2020], GPT-4 [2023]

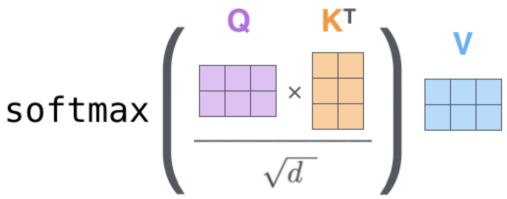

Дистрибутивная гипотеза и виды семантической близости слов

«Смысл слова определяется множеством его контекстов»

- Words that occur in the same contexts tend to have similar meanings [Harris, 1954].
- You shall know a word by the company it keeps [Firth, 1957].

Синтагматическая близость слов:
сочетаемость слов в одном контексте
(здание–строитель, кран–вода, функция–точка)

Парадигматическая близость слов:
взаимозаменяемость слов в одном контексте
(здание–дом, кран–смеситель, функция–отображение)

Z.Harris. Distributional structure. 1954.
J.R.Firth. A synopsis of linguistic theory 1930-1955. Oxford, 1957.
P.Turney, P.Pantel. From frequency to meaning: vector space models of semantics. 2010.

Формализация дистрибутивной гипотезы

Дано: текст $(w_1 \dots w_n)$, последовательность слов словаря W

Найти: векторные представления слов $v_w \in \mathbb{R}^d$, так, чтобы близкие по смыслу слова имели близкие векторы

Модель Skip-gram для предсказания вероятности слов контекста $C_i = (w_{i-k} \dots w_{i-1} w_{i+1} \dots w_{i+k})$ по слову w_i:

$$p(w|w_i) \;=\; \underset{w \in W}{\mathrm{SoftMax}} \langle u_w, v_{w_i} \rangle \;\equiv\; \frac{\exp(\langle u_w, v_{w_i} \rangle)}{\sum_w \exp(\langle u_w, v_{w_i} \rangle)},$$

v_w — вектор предсказывающего слова,
u_w — вектор предсказываемого слова, в общем случае $u_w \neq v_w$.

Критерий максимума log-правдоподобия, $U, V \in \mathbb{R}^{|W| \times d}$:

$$\sum_{i=1}^{n} \sum_{w \in C_i} \ln p(w|w_i) \to \max_{U,V}$$

T.Mikolov et al. Efficient estimation of word representations in vector space, 2013.

Ещё одна формализация дистрибутивной гипотезы

Дано: текст $(w_1 \dots w_n)$, последовательность слов словаря W

Найти: векторные представления слов $v_w \in \mathbb{R}^d$, так, чтобы близкие по смыслу слова имели близкие векторы

Модель CBOW (continuous bag-of-words) для вероятности слова w_i в заданном контексте $C_i = (w_{i-k} \dots w_{i-1} w_{i+1} \dots w_{i+k})$:

$$p(w_i = w | C_i) \;=\; \underset{w \in W}{\mathrm{SoftMax}} \langle u_w, v[C_i] \rangle,$$

$v[C_i] = \frac{1}{|C_i|} \sum\limits_{w \in C_i} v_w$ — средний вектор слов из контекста C_i,
v_w — векторы предсказывающих слов,
u_w — вектор предсказываемого слова, в общем случае $u_w \neq v_w$.

Критерий максимума log-правдоподобия, $U, V \in \mathbb{R}^{|W| \times d}$:

$$\sum_{i=1}^{n} \ln p(w_i | C_i) \to \max_{U,V}$$

Сравнение моделей CBOW и Skip-gram

- Различие — в структуре оптимизационного критерия:

$$\text{Skip-gram:} \quad \sum_{i=1}^{n} \sum_{c \in C_i} \ln \operatorname*{SoftMax}_{c \in W} \langle u_c, v_{w_i} \rangle \to \max_{U,V}$$

$$\text{CBOW:} \quad \sum_{i=1}^{n} \ln \operatorname*{SoftMax}_{w_i \in W} \left(\frac{1}{|C_i|} \sum_{c \in C_i} \langle u_{w_i}, v_c \rangle \right) \to \max_{U,V}$$

- Skip-gram точнее моделирует вероятности редких слов
- Обе модели можно обучать с помощью SGD
- Обе модели реализованы в программе word2vec [Mikolov]
- Оба критерия трудно оптимизировать из-за SoftMax
- Что делать? Заменять либо SoftMax, либо критерий

T.Mikolov et al. Efficient estimation of word representations in vector space, 2013.

Иерархический SoftMax

Идея: заменить SoftMax на другую функцию потерь, сложность вычисления которой $O(\log_2 |W|)$ вместо $O(|W|)$

Предварительный этап:

- По словарю частот строится *бинарное дерево Хаффмана*
  — каждому слову $w \in W$ соответствует ровно один лист
  — путь от корня до w тем короче, чем выше частота w
- Каждая внутренняя вершина n хранит вектор $u_n \in \mathbb{R}^d$
- Каждый лист хранит вектор $v_w \in \mathbb{R}^d$ для слова w
- Модель перехода из внутренней вершины n в дочернюю:

$$\text{направо:} \quad p(+1|n,w) = \sigma(\langle u_n, v_w \rangle)$$

$$\text{налево:} \quad p(-1|n,w) = \sigma(-\langle u_n, v_w \rangle) = 1 - p(+1|n,w)$$

Обучаются векторы v_w в листьях и u_n во внутренних вершинах

F.Morin, Y.Bengio. Hierarchical probabilistic neural network language model. 2005.
A.Mnih, G.E.Hinton. A scalable hierarchical distributed language model. 2009.

Иерархический SoftMax: обучение модели

Модель $p(w|w_i)$, гарантирующая нормировку $\sum_w p(w|w_i) = 1$:

$$p(w|w_i) = \prod_{j=1}^{\ell(w)} p\big(\beta_{jw}|n_{jw}, w_i\big) = \prod_{j=1}^{\ell(w)} \sigma\big(\beta_{jw}\langle u_{n_{jw}}, v_{w_i}\rangle\big)$$

где $\ell(w)$ — длина пути от корня дерева к листу w

n_{jw} — j-я внутренняя вершина на пути к листу w

$\beta_{jw} \in \{-1, +1\}$ — переход из n_{jw} в дочернюю на пути к w

Пример: $p(w|w_i) = p(-1|n_{1w}, w_i)\, p(-1|n_{2w}, w_i)\, p(+1|n_{3w}, w_i)$

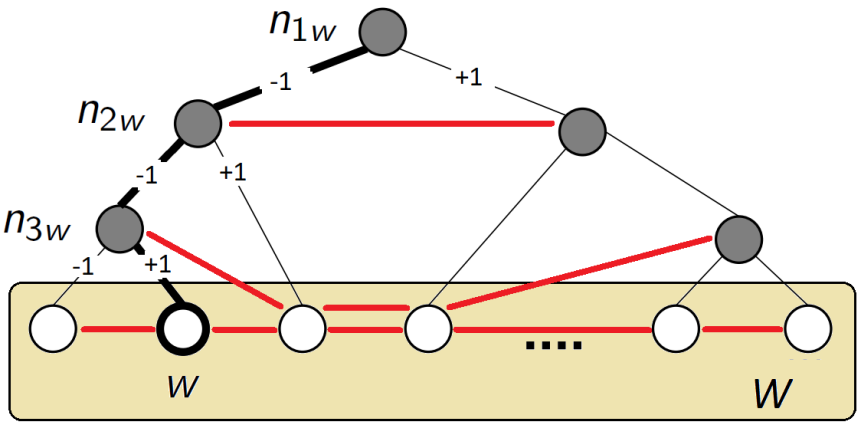

На каждом уровне дерева сохраняется нормировка $\sum_w p(w|w_i) = 1$

Третья формализация: классификация пар слов на два класса

Критерий log-loss для SGNS (Skip-gram Negative Sampling):

$$\sum_{i=1}^{n} \sum_{w \in C_i} \Big(\ln p(+1|w, w_i) + \ln p(-1|\bar{w}, w_i) \Big) \to \max_{U,V}$$

где $p(y|w, w_i) = \sigma\big(y\langle u_w, v_{w_i}\rangle\big)$ — модель классификации, $y = \pm 1$;
$y = +1$, если пара слов (w, w_i) находится в общем контексте;
$y = -1$, если пара слов (w, w_i) не находится в общем контексте;
$\bar{w} \sim p(w)^{3/4}$ сэмплируется из $W \backslash C_i$ в методе SG.

Эвристики и прочие замечания:

- Dynamic window: случайная ширина контекста $k \sim [3..10]$
- Итоговые векторы слов: $\alpha v_w + (1 - \alpha) u_w$
- Приём NS применяют, когда не хватает второго класса
- Что делать со словами, которые встречаются впервые?

Связь word2vec с матричными разложениями

d — размерность векторов слов v_w и u_w
$V = (v_w)_{W \times d}$ — матрица предсказывающих векторов слов
$U = (u_w)_{W \times d}$ — матрица предсказываемых векторов слов

SGNS строит матричное разложение $P \approx UV^{\mathsf{T}}$ матрицы Shifted PMI (Point-wise Mutual Information):

$$P_{ab} = \ln \frac{n_{ab} n}{n_a n_b} - \ln k,$$

n_{ab} — частота пары слов a, b в окне $\pm k$ слов,
n_a, n_b — число пар с участием слова a и b соответственно,
n — число всех пар слов в коллекции.

В качестве эвристики используют также Shifted Positive PMI:

$$P^{+}_{ab} = \left(\ln \frac{n_{ab} n}{n_a n_b} - \ln k \right)_{+}.$$

O.Levy, Y.Goldberg. Neural word embedding as implicit matrix factorization. 2014.

Проверка на задачах семантической близости и аналогии слов

Задача семантической близости слов:
по выборке пар слов (a, b) оценивается корреляция Спирмена между $\cos(v_a, v_b)$ и экспертными оценками близости $y(a, b)$

Задача семантической аналогии слов:
по трём словам угадать четвёртое

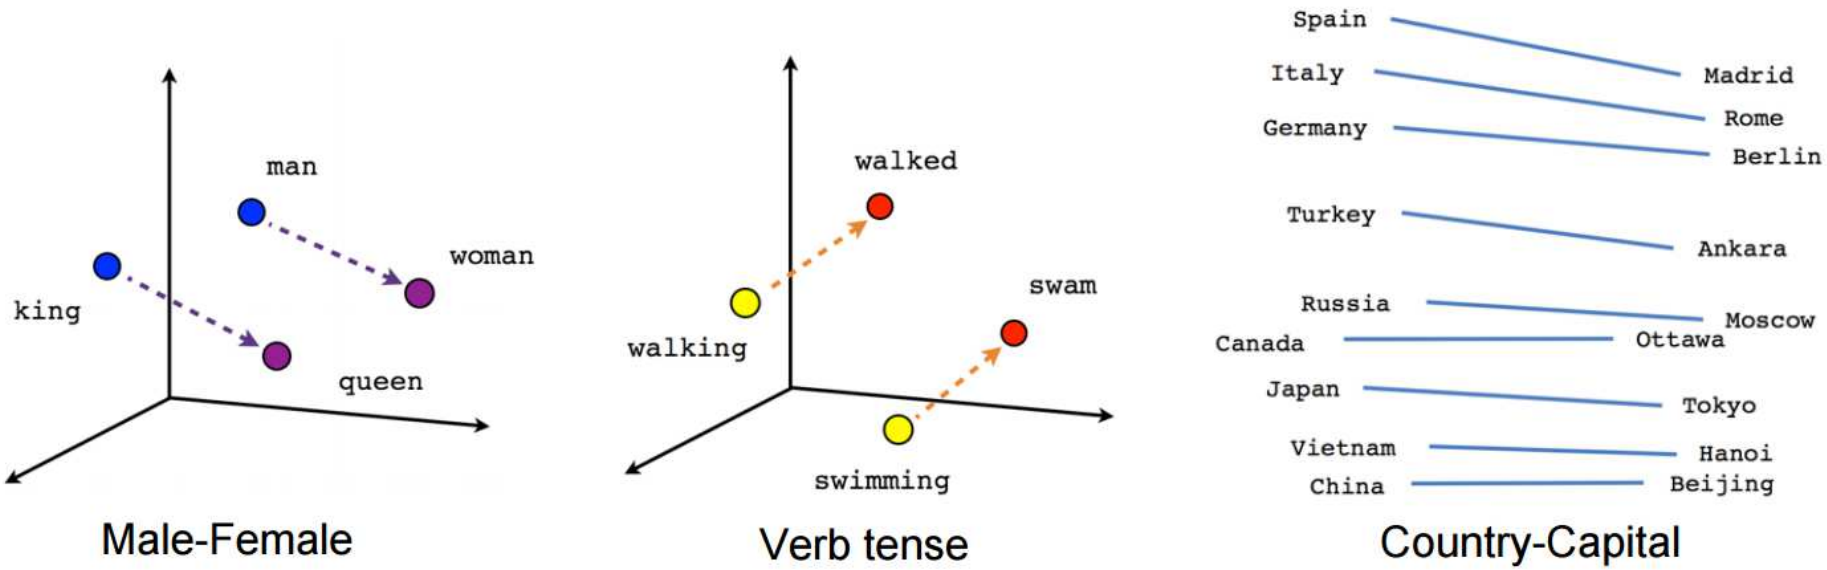

Модель векторных представлений FastText

Идея: векторное представление слова w определяется как сумма векторов всех его буквенных n-грамм $G(w)$:

$$u_w = \sum_{g \in G(w)} u_g$$

В Skip-gram вместо векторов слов u_w обучаются векторы u_g

Пример: $G(\text{дармолюб}) = \{\text{<да, арм, рмо, мол, олю, люб, юб>}\}$

Преимущества:

- Это решает проблемы новых слов и слов с опечатками
- Подходит для обработки текстов социальных медиа
- Словарь 2- и 3-грамм обычно меньше словаря W
- Существует много предобученных моделей

Bojanowski et al. Enriching word vectors with subword information. 2016.

Модели векторных представлений для текстов и графов

word2vec: *эмбединги* (векторные представления) слов
T.Mikolov et al. Efficient estimation of word representations in vector space. 2013.

paragraph2vec: эмбединги фрагментов или документов
Q.Le, T.Mikolov. Distributed representations of sentences and documents. 2014.

sent2vec: эмбединги предложений
M.Pagliardini et al. Unsupervised learning of sentence embeddings using compositional n-gram features. 2017.

FastText: эмбединги символьных *n*-грамм
`https://github.com/facebookresearch/fastText`

node2vec: эмбединги вершин графа
A.Grover, J.Leskovec. Node2vec: scalable feature learning for networks. 2016.

graph2vec: более общие эмбединги на графах
A.Narayanan et al. Graph2vec: learning distributed representations of graphs. 2017.

StarSpace: эмбединги чего угодно от Facebook AI Research
L.Wu, A.Fisch, S.Chopra, K.Adams, A.B.J.Weston. StarSpace: embed all the things! 2018.

BERT: контекстно-зависимые эмбединги от Google AI Language
J.Devlin et al. BERT: pre-training of deep bidirectional transformers for language understanding. 2018.

GPT-3: эмбединги, предобученные по 570Gb текстов от OpenAI
T.B.Brown et al. Language Models are Few-Shot Learners. 2020.

Резюме

Разновидности векторизации данных:

- *Автокодировщики* — синтез векторных представлений (эмбедингов) объектов, обычно с понижением размерности
- *Матричные разложения графовых данных (GF, graph2vec)* и *многомерное шкалирование (MDS, SNE)* — синтез эмбедингов объектов по данным об их взаимодействии
- *Обобщённая модель GraphEDM* — синтез эмбедингов объектов по данным об объектах и их взаимодействии

Методы обучения — на основе SG

Текстовые данные — частный случай графовых данных:

- слова — вершины графа, сочетаемость пары слов — ребро
- слова и документы — вершины двух разных долей графа, вхождение слова в документ — ребро двудольного графа