Методы машинного обучения. Обучение без учителя: обучаемая векторизация данных

Воронцов Константин Вячеславович
www.MachineLearning.ru/wiki?title=User:Vokov
вопросы к лектору: k.vorontsov@iai.msu.ru

материалы курса:
github.com/MSU-ML-COURSE/ML-COURSE-25-26
орг.вопросы по курсу: ml.cmc@mail.ru

ВМК МГУ • 10 марта 2026

Содержание

1. **Сети Кохонена**
   - Задача кластеризации и сеть Кохонена
   - Обучаемое векторное квантование
   - Карты Кохонена
2. **Автокодировщики**
   - Задача понижения размерности
   - Методы регуляризации
   - Автокодировщик с частичным обучением
3. **Векторизация сложно структурированных данных**
   - Изображения, сигналы, тексты, игры
   - Предобучение и перенос обучения
   - Многозадачное обучение

Постановка задачи кластеризации. Квантизация данных

Дано:
$X^\ell = \{x_i\}_{i=1}^\ell$ — обучающая выборка объектов, $x_i \in \mathbb{R}^n$
$\rho^2(x, w) = \|x - w\|^2$ — евклидова метрика в $\mathbb{R}^n$

Найти:
центры кластеров $w_y \in \mathbb{R}^n$, $y \in Y$; модель кластеризации «правило жёсткой конкуренции» (WTA, Winner Takes All):

$$a(x) = \arg\min_{y \in Y} \rho(x, w_y)$$

Критерий: среднее внутрикластерное расстояние

$$Q(w; X^\ell) = \sum_{i=1}^{\ell} \rho^2(x_i, w_{a(x_i)}) \to \min_{w_y \,:\, y \in Y}$$

Квантизация данных — замена x_i на ближайший центр $w_{a(x_i)}$

Сеть Кохонена (сеть с конкурентным обучением)

Структура модели — (якобы) двухслойная нейронная сеть:

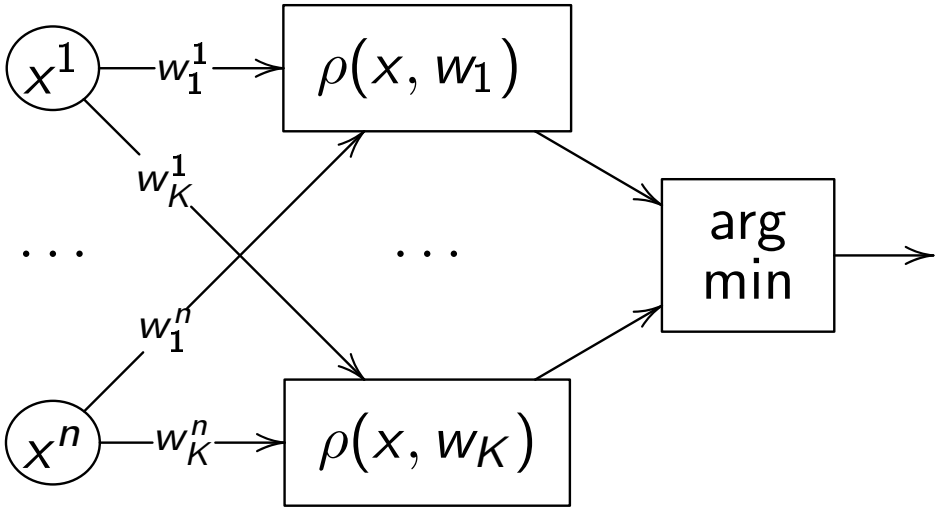

$$a(x) = \arg\min_{y \in Y} \rho(x, w_y)$$

Градиентный шаг в методе SG: для выбранного $x_i \in X^\ell$

$$w_y := w_y + \eta(x_i - w_y)\big[a(x_i) = y\big]$$

Если x_i относится к кластеру y, то w_y сдвигается в сторону x_i:

$$w_y := (1 - \eta)w_y + \eta x_i$$

T.Kohonen. Self-organized formation of topologically correct feature maps. 1982.

Алгоритм SG (Stochastic Gradient) для сети Кохонена

Вход: выборка X^ℓ; темп обучения η; параметр λ;
Выход: центры кластеров $w_y \in \mathbb{R}^n$, $y \in Y$;

инициализировать центры w_y, $y \in Y$;
инициализировать текущую оценку функционала:
$Q := \sum_{i=1}^{\ell} \rho^2(x_i, w_{a(x_i)})$;
повторять
  выбрать объект x_i из X^ℓ (например, случайно);
  найти ближайший центр: $y := \arg\min_{y \in Y} \rho(x_i, w_y)$;
  градиентный шаг: $w_y := w_y + \eta(x_i - w_y)$;
  оценить значение функционала:
  $Q := (1-\lambda)Q + \lambda\rho^2(x_i, w_y)$;
пока значение Q и/или веса w не стабилизируются;

Жёсткая и мягкая конкуренция

Правило жёсткой конкуренции WTA (winner takes all):

$$w_y := w_y + \eta(x_i - w_y)\big[a(x_i) = y\big], \quad y \in Y$$

Недостатки правила WTA:

- медленная скорость сходимости
- некоторые w_y могут никогда не выбираться

Правило мягкой конкуренции WTM (winner takes most):

$$w_y := w_y + \eta(x_i - w_y)\, K\big(\rho(x_i, w_y)\big), \quad y \in Y$$

где ядро $K(\rho)$ — неотрицательная невозрастающая функция

Теперь центры *всех* кластеров смещаются в сторону x_i,
но чем дальше от x_i, тем меньше величина смещения

Задача классификации LVQ (Learning Vector Quantization)

Дано:

$X^\ell = \{x_i, y_i\}_{i=1}^\ell$ — объекты $x_i \in \mathbb{R}^n$ с классификацией $y_i \in Y$

$y(c) \in Y$ задаёт деление классов на кластеры $c \in C$, $|C| > |Y|$

Найти:

центры кластеров $w_c \in \mathbb{R}^n$, $c \in C$ в модели кластеризации WTA

$$c(x) = \arg\min_{c \in C} \rho(x, w_c)$$

и модель классификации $a(x) = y(c(x))$

Критерий:

min внутрикластерных расстояний в своём классе,

max внутрикластерных расстояний с чужими классами:

$$Q = \sum_{i=1}^{\ell} \rho^2(x_i, w_{c(x_i)}) \Big([y(c(x_i)) = y_i] - [y(c(x_i)) \neq y_i] \Big) \to \min_{w_c:\, c \in C}$$

Алгоритм SG (Stochastic Gradient) для LVQ

Вход: выборка X^ℓ; темп обучения η; параметр λ;
Выход: центры кластеров $w_c \in \mathbb{R}^n$, $c \in C$;

инициализировать центры w_c и задать $y(c)$, $c \in C$;
инициализировать текущую оценку функционала Q;
повторять
  выбрать объект x_i из X^ℓ (например, случайно);
  вычислить кластеризацию: $c := \arg\min\limits_{c \in C} \rho(x_i, w_c)$;
  вычислить классификацию: $a := y(c)$;
  $w_c := w_c + \eta(x_i - w_c)$, если $a = y_i$;
  $w_c := w_c - \eta(x_i - w_c)$, если $a \neq y_i$;
  оценить значение функционала:
  $Q := (1-\lambda)Q + \lambda\rho^2(x_i, w_y)\Big([a{=}y_i] - [a{\neq}y_i]\Big)$;
пока значение Q и/или веса w не стабилизируются;

Обучаемое векторное квантование (LVQ)

- кластеризация, реализуемая (якобы) нейронной сетью
- классификация путём разбиения каждого класса на заданное число кластеров
- позволяет моделировать классы сложной формы
- похоже на отбор эталонов (prototype selection)
- похоже на байесовский классификатор с GMM-классами

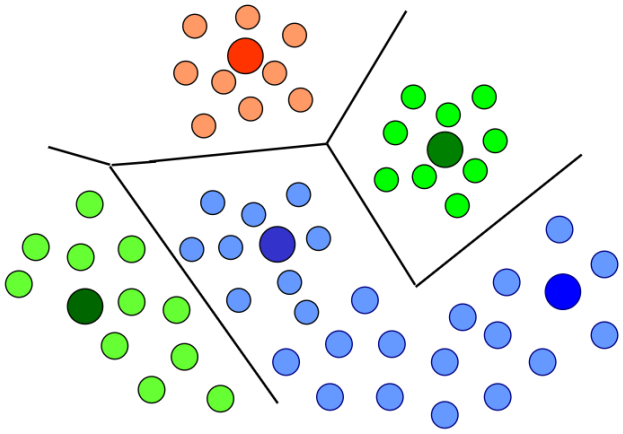

Teuvo Kohonen. Improved versions of learning vector quantization. 1990

Карта Кохонена (Self Organizing Map, SOM)

Дано: обучающая выборка $X^\ell = \{x_i\}_{i=1}^\ell$, $x_i \in \mathbb{R}^n$, $\rho(x, x')$

Найти: центры кластеров $w_{mh} \in \mathbb{R}^n$, $m \in \{1..M\}$, $h \in \{1..H\}$

Наряду с метрикой $\rho(x, x')$ на X вводится метрика на сетке:

$$r\big((m_i, h_i), (m, h)\big) = \sqrt{(m - m_i)^2 + (h - h_i)^2}$$

Окрестность(m_i, h_i) на прямоугольной сетке центров кластеров:

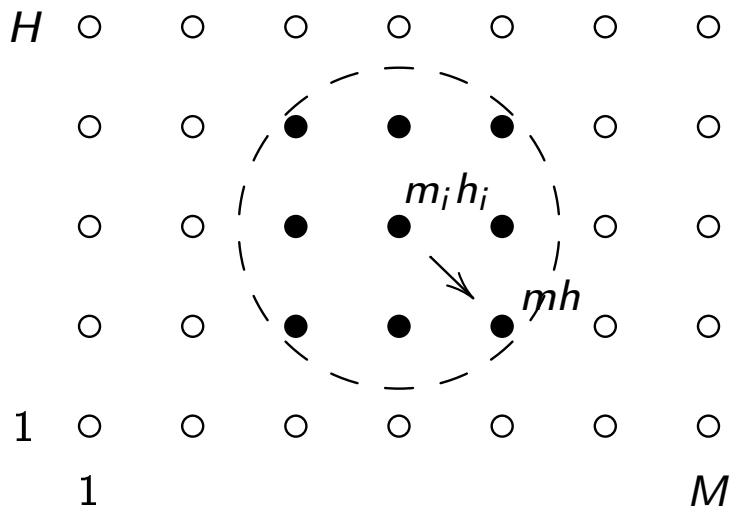

Teuvo Kohonen. Self-Organizing Maps. 2001.

Обучение карты Кохонена

Вход: X^ℓ — обучающая выборка; η — темп обучения;
Выход: $w_{mh} \in \mathbb{R}^n$ — векторы весов, $m = 1..M$, $h = 1..H$;

$w_{mh} := \text{random}\left(-\frac{1}{2MH}, \frac{1}{2MH}\right)$ — инициализация весов;

повторять
- выбрать объект x_i из X^ℓ случайным образом;
- WTA: вычислить координаты кластера:
- $(m_i, h_i) := a(x_i) \equiv \arg\min\limits_{(m,h)\in Y} \rho(x_i, w_{mh})$;
- **для всех** $(m, h) \in$ Окрестность(m_i, h_i)
  - WTM: сделать шаг градиентного спуска:
  - $w_{mh} := w_{mh} + \eta(x_i - w_{mh})\, K\big(r((m_i, h_i), (m, h))\big)$;

пока кластеризация не стабилизируется;

Teuvo Kohonen. Self-Organizing Maps. 2001.

Интерпретация карт Кохонена

Два типа графиков — цветных карт $M \times H$:

- Цвет узла (m, h) — локальная плотность в точке (m, h) — среднее расстояние до k ближайших точек выборки
- По одной карте на каждый признак:
  цвет узла (m, h) — значение j-й компоненты вектора $w_{m,h}$

Пример: задача UCI house-votes (US Congress voting patterns)
Объекты — конгрессмены
Признаки — результаты голосования по различным вопросам
Есть целевой признак «партия» $\in$ {демократ, республиканец}

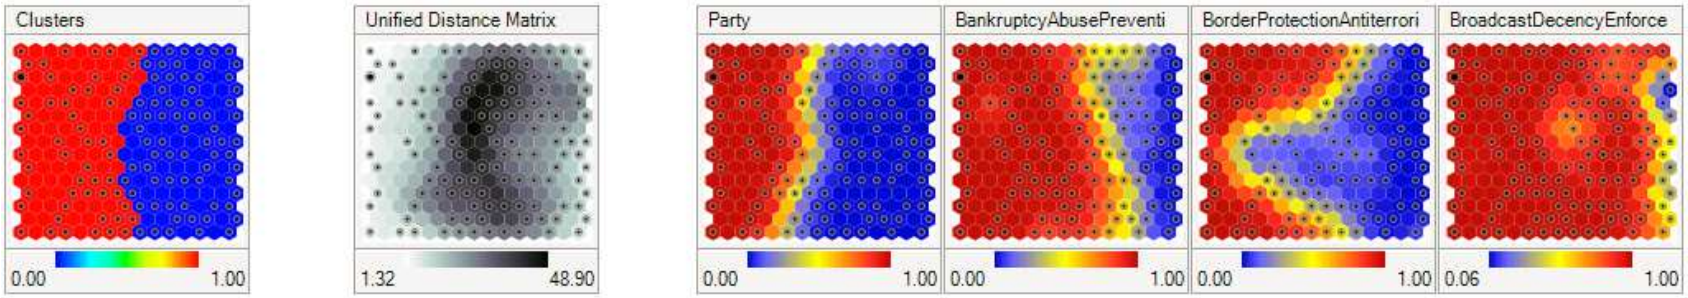

Интерпретация карт Кохонена (продолжение примера)

Пример: задача UCI house-votes (US Congress voting patterns)

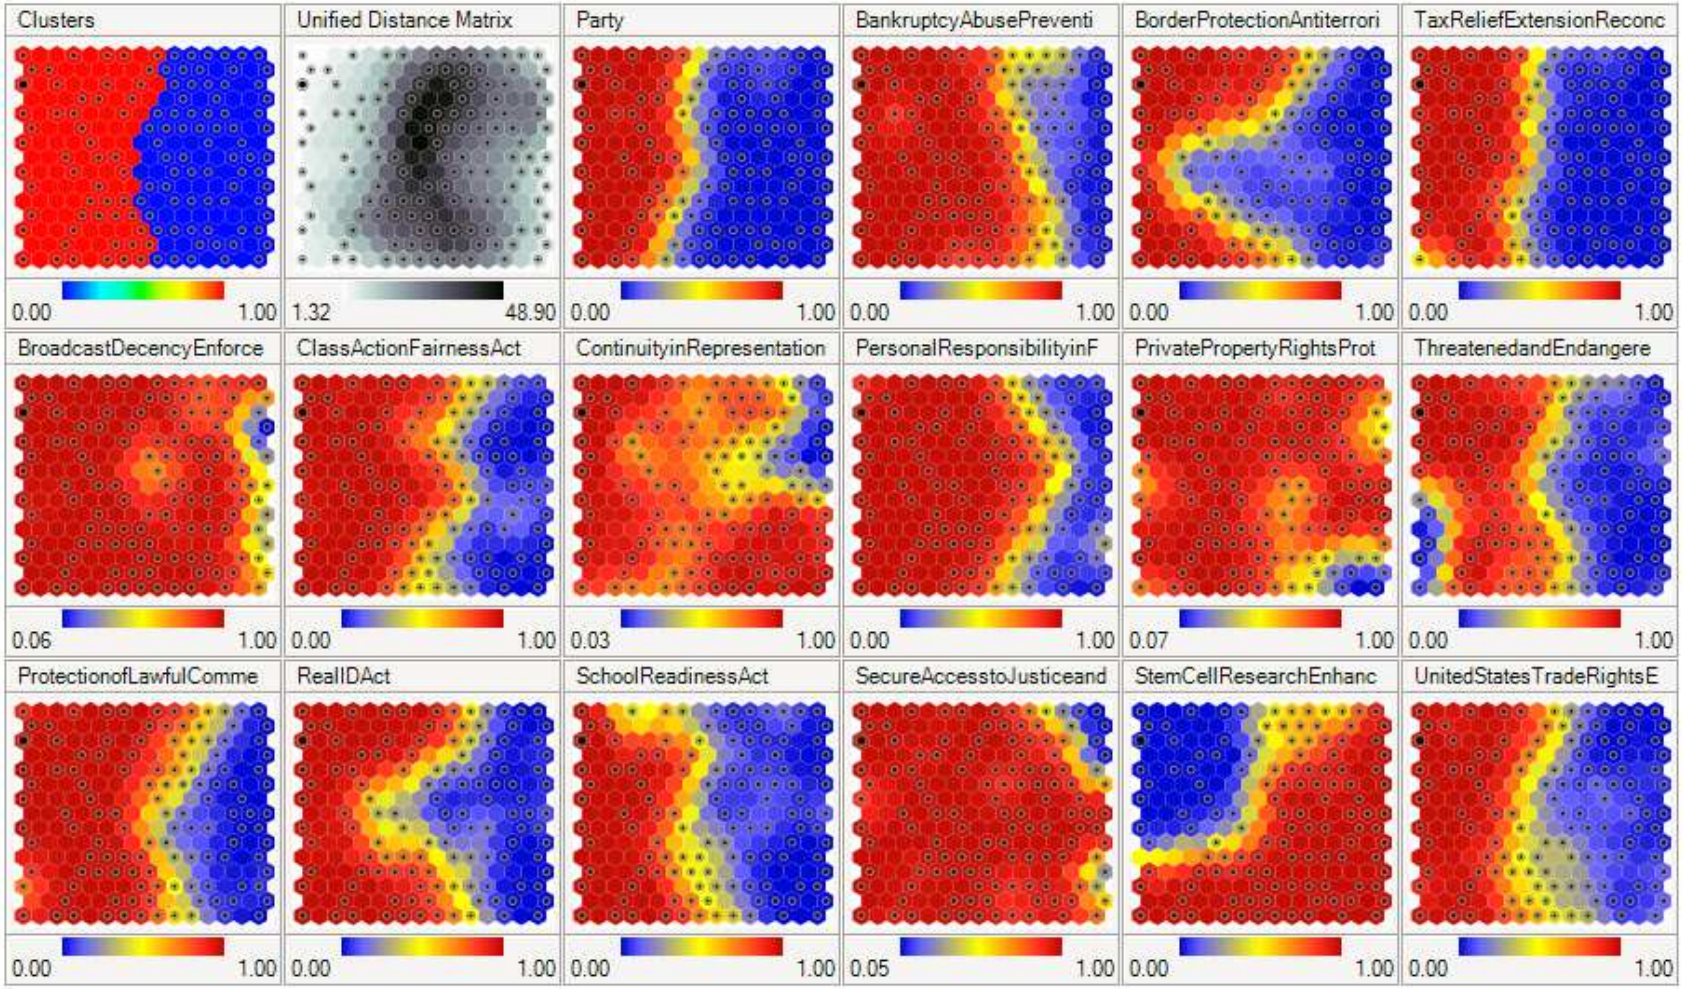

Достоинства и недостатки карт Кохонена

Достоинства:

- Возможность визуального анализа многомерных данных
- Квантование выборки по кластерам,
  с автоматическим определением числа непустых кластеров

Недостатки:

- **Субъективность.** Карта отражает не только кластерную структуру данных, но также зависит от...
  — свойств сглаживающего ядра;
  — (случайной) инициализации;
  — (случайного) выбора x_i в ходе итераций.
- **Искажения.** Близкие объекты исходного пространства могут переходить в далёкие точки на карте, и наоборот.

Рекомендуется только для разведочного анализа данных.

Автокодировщик (AutoEncoder) — обучение без учителя

Дано: $X^\ell = \{x_1, \ldots, x_\ell\}$ — обучающая выборка

Найти две модели одновременно:
$f\colon X \to Z$ — кодировщик (encoder), кодовый вектор $z = f(x, \alpha)$
$g\colon Z \to X$ — декодировщик (decoder), реконструкция $\hat{x} = g(z, \beta)$

Критерий: качество реконструкции исходных объектов x_i:

$$\sum_{i=1}^{\ell} \mathscr{L}\big(g(f(x_i, \alpha), \beta), x_i\big) \to \min_{\alpha,\beta}$$

Квадратичная функция потерь: $\mathscr{L}(\hat{x}, x) = \|\hat{x} - x\|^2$

Пример 1. Линейный автокодировщик: $x \in \mathbb{R}^n$, $z \in \mathbb{R}^m$

$$f(x, A) = \underset{m\times n}{A}\, x, \quad g(z, B) = \underset{n\times m}{B}\, z$$

Пример 2. Двухслойная сеть с функциями активации σ_f, σ_g

$$f(x, A) = \sigma_f(Ax + a), \quad g(z, B) = \sigma_g(Bz + b)$$

Обучение и использование автокодировщиков

Метод обучения:

- Стохастический градиент (SG) по параметрам (α, β)
- Одновременно обучаются две модели — $f(x, \alpha)$ и $g(z, \beta)$

Способы использования:

- Сжатие данных с минимальной потерей информации
- Векторизация данных:
  — понижение размерности (dimensionality reduction)
  — синтез более удачных признаков (feature generation)
- Обучение с учителем в новом пространстве признаков
- Генерация синтетических объектов, похожих на реальные

Rumelhart, Hinton, Williams. Learning internal representations by error propagation. 1985.

David Charte et al. A practical tutorial on autoencoders for nonlinear feature fusion: taxonomy, models, software and guidelines. 2018.

Линейный автокодировщик и метод главных компонент

Линейный автокодировщик: $f(x, A) = Ax, \quad g(z, B) = Bz,$

$$\mathscr{L}_{\text{AE}}(A, B) = \sum_{i=1}^{\ell} \|BAx_i - x_i\|^2 \to \min_{A,B}$$

Метод главных компонент: $f(x, U) = U^{\intercal}x, \quad g(z, U) = Uz,$
в матричных обозначениях $F = (x_1 \ldots x_\ell)^{\intercal}, \quad U^{\intercal}U = I_m, \quad G = FU,$

$$\|F - GU^{\intercal}\|^2 = \sum_{i=1}^{\ell} \|UU^{\intercal}x_i - x_i\|^2 \to \min_{U}$$

Автокодировщик обобщает метод главных компонент:

- не обязательно $B = A^{\intercal}$ (хотя часто именно так и делают)
- произвольные A, B вместо ортогональных
- нелинейные модели $f(x, \alpha)$, $g(z, \beta)$ вместо Ax, Bz
- произвольная функция потерь $\mathscr{L}$ вместо квадратичной
- SG оптимизация вместо сингулярного разложения SVD

Разреживающие автокодировщики (Sparse AE)

Применение L_1 или L_2-регуляризации к векторам весов α, β:

$$\mathscr{L}_{\mathsf{AE}}(\alpha,\beta) + \lambda\|\alpha\| + \lambda\|\beta\| \to \min_{\alpha,\beta}$$

Применение L_1-регуляризации к кодовым векторам z_i:

$$\mathscr{L}_{\mathsf{AE}}(\alpha,\beta) + \lambda \sum_{i=1}^{\ell}\sum_{j=1}^{m} |f_j(x_i,\alpha)| \to \min_{\alpha,\beta}$$

Энтропийная регуляризация для случая $f_j \in [0,1]$:

$$\mathscr{L}_{\mathsf{AE}}(\alpha,\beta) + \lambda \sum_{j=1}^{m} \mathsf{KL}(\varepsilon\|\bar{f}_j) \to \min_{\alpha,\beta},$$

где $\bar{f}_j = \frac{1}{\ell}\sum_{i=1}^{\ell} f_j(x_i,\alpha)$; $\quad \varepsilon \in (0,1)$ — близкий к нулю параметр,

$\mathsf{KL}(\varepsilon\|\rho) = \varepsilon \log\frac{\varepsilon}{\rho} + (1-\varepsilon)\log\frac{1-\varepsilon}{1-\rho}$ — KL-дивергенция.

D.Arpit et al. Why regularized auto-encoders learn sparse representation? 2015.

Шумоподавляющий автокодировщик (Denoising AE)

Устойчивость кодовых векторов z_i относительно шума в x_i:

$$\mathscr{L}_{\text{DAE}}(\alpha,\beta) = \sum_{i=1}^{\ell} \mathsf{E}_{\tilde{x}\sim q(\tilde{x}|x_i)} \mathscr{L}\big(g(f(\tilde{x},\alpha),\beta),x_i\big) \to \min_{\alpha,\beta}$$

Вместо вычисления $\mathsf{E}_{\tilde{x}}$ в методе SG объекты x_i сэмплируются и зашумляются по одному: $\tilde{x} \sim q(\tilde{x}|x_i)$.

Варианты зашумления $q(\tilde{x}|x_i)$:

- $\tilde{x} \sim \mathcal{N}(x_i, \sigma^2 I)$ — добавление гауссовского шума
- обнуление компонент вектора x_i с вероятностью p_0
- такие искажения $x_i \to \tilde{x}$, относительно которых реконструкция $\hat{x}_i$ должна быть устойчивой

P. Vincent, H. Larochelle, Y. Bengio, P.-A. Manzagol. Extracting and composing robust features with denoising autoencoders. ICML-2008.

Реляционный автокодировщик (Relational AE)

Наряду с потерями реконструкции объектов минимизируем потери реконструкции отношений между объектами:

$$\mathscr{L}_{\mathsf{AE}}(\alpha,\beta) + \lambda \sum_{i<j} \mathscr{L}\big(\sigma(\hat{x}_i^{\mathsf{T}}\hat{x}_j), \sigma(x_i^{\mathsf{T}}x_j)\big) \to \min_{\alpha,\beta}$$

где $\hat{x}_i = g(f(x_i,\alpha),\beta)$ — реконструкция объекта x_i,
$x_i^{\mathsf{T}}x_j$ — скалярное произведение (близость) пары объектов,
$\sigma(s) = (s - s_0)_+$ — пороговая функция с параметром s_0
(если векторы не близки, то неважно, насколько),
$\mathscr{L}(\hat{s}, s)$ — функция потерь, например, $(\hat{s} - s)^2$.

Эксперимент: улучшается качество классификации изображений с помощью кодовых векторов на задачах MNIST, CIFAR-10

Qinxue Meng et al. Relational autoencoder for feature extraction. 2018.

Вариационный автокодировщик (Variational AE)

Дано: выборка объектов $X^\ell = \{x_1, \ldots, x_\ell\}$

Найти: модель для генерации новых объектов, похожих на x_i:

$q_\alpha(z|x)$ — вероятностный кодировщик с параметром α

$p_\beta(\hat{x}|z)$ — вероятностный декодировщик с параметром β

Критерий: max нижней оценки log-правдоподобия

$$\sum_{i=1}^{\ell} \ln p(x_i) = \sum_{i=1}^{\ell} \ln \int q_\alpha(z|x_i) \frac{p_\beta(x_i|z)p(z)}{q_\alpha(z|x_i)} dz \geqslant$$

$$\geqslant \sum_{i=1}^{\ell} \int q_\alpha(z|x_i) \ln \frac{p_\beta(x_i|z)p(z)}{q_\alpha(z|x_i)} dz =$$

$$= \sum_{i=1}^{\ell} \int q_\alpha(z|x_i) \ln p_\beta(x_i|z) dz - \mathrm{KL}\big(q_\alpha(z|x_i) \,\big\|\, p(z)\big) \to \max_{\alpha,\beta}$$

D.P.Kingma, M.Welling. Auto-encoding Variational Bayes. 2013.
C.Doersch. Tutorial on variational autoencoders. 2016.

Вариационный автокодировщик (Variational AE)

Оптимизационная задача для вариационного автокодировщика:

$$\sum_{i=1}^{\ell} \underbrace{\mathsf{E}_{z\sim q_\alpha(z|x_i)} \ln p_\beta(x_i|z)}_{\substack{\text{качество реконструкции} \\ \approx \ln p_\beta(x_i|z),\ z\sim q_\alpha(z|x_i)}} - \underbrace{\mathsf{KL}\big(q_\alpha(z|x_i) \,\big\|\, p(z)\big)}_{\text{регуляризатор по } \alpha} \to \max_{\alpha,\beta}$$

где $p(z)$ — априорное распределение, обычно $\mathcal{N}(0, \sigma^2 I)$

Репараметризация $q_\alpha(z|x_i)$: $\quad z = f(x_i, \alpha, \varepsilon)$, $\varepsilon \sim \mathcal{N}(0, I)$

Метод стохастического градиента:

- сэмплировать $x_i \sim X^\ell$, $\varepsilon \sim \mathcal{N}(0, I)$, $z = f(x_i, \alpha, \varepsilon)$
- градиентный шаг:
  $\alpha := \alpha + h\nabla_\alpha \big[\ln p_\beta\big(x_i|f(x_i, \alpha, \varepsilon)\big) - \mathsf{KL}\big(q_\alpha(z|x_i)\|p(z)\big)\big]$;
  $\beta := \beta + h\nabla_\beta \big[\ln p_\beta(x_i|f(x_i, \alpha, \varepsilon))\big]$;

Генерация похожих объектов: $x \sim p_\beta\big(x|f(x_i, \alpha, \varepsilon)\big)$, $\varepsilon \sim \mathcal{N}(0, I)$

Автокодировщики для векторизации и обучения с учителем

Данные: размеченные $(x_i, y_i)_{i=1}^{k}$, неразмеченные $(x_i)_{i=k+1}^{\ell}$

Найти:

$z_i = f(x_i, \alpha)$ — кодировщик

$\hat{x}_i = g(z_i, \beta)$ — декодировщик

$\hat{y}_i = \hat{y}(z_i, \gamma)$ — предиктор

Задаются функции потерь:

$\mathscr{L}(\hat{x}_i, x_i)$ — реконструкция

$\tilde{\mathscr{L}}(\hat{y}_i, y_i)$ — предсказание

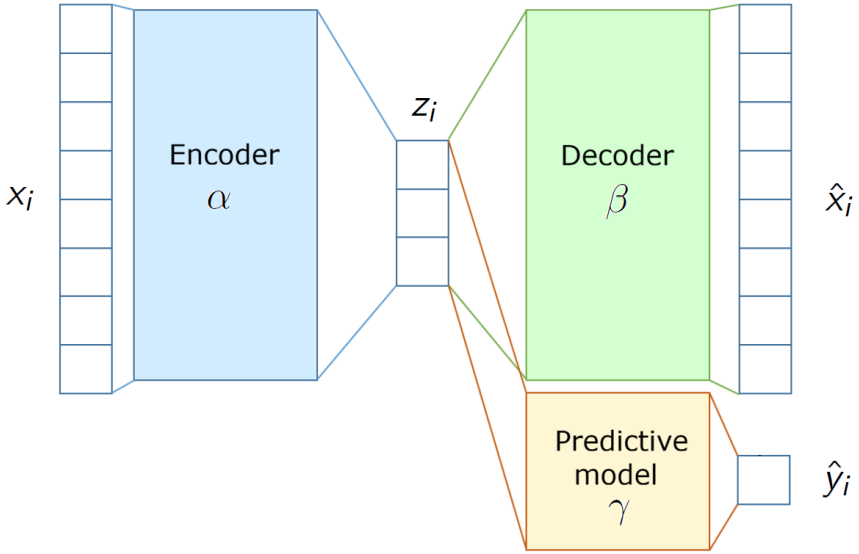

Критерий: совместное обучение автокодировщика и предсказательной модели (классификации, регрессии или др.):

$$\sum_{i=1}^{\ell} \mathscr{L}\big(g(f(x_i, \alpha), \beta), x_i\big) + \lambda \sum_{i=1}^{k} \tilde{\mathscr{L}}\big(\hat{y}(f(x_i, \alpha), \gamma), y_i\big) \to \min_{\alpha, \beta, \gamma}$$

Dor Bank, Noam Koenigstein, Raja Giryes. Autoencoders. 2020

Глубокие свёрточные сети для классификации изображений

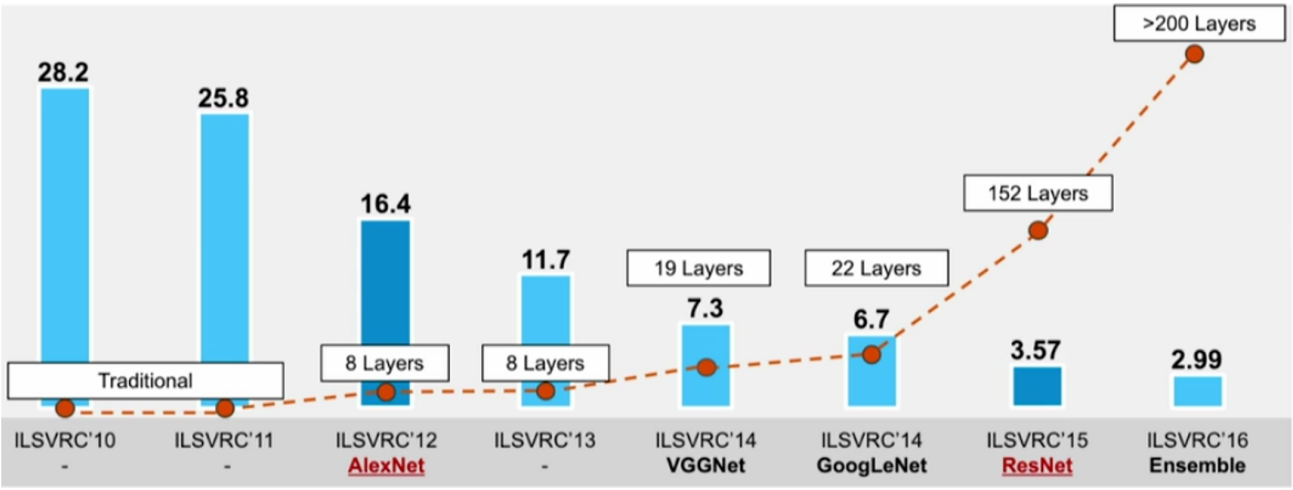

Старт в 2009. Человеческий уровень ошибок 5% пройден в 2015

Свёрточная сеть **AlexNet**:
+ ReLU + Dropout
+ 60M параметров
+ пополнение выборки
+ подбор размеров слоёв
+ GPU

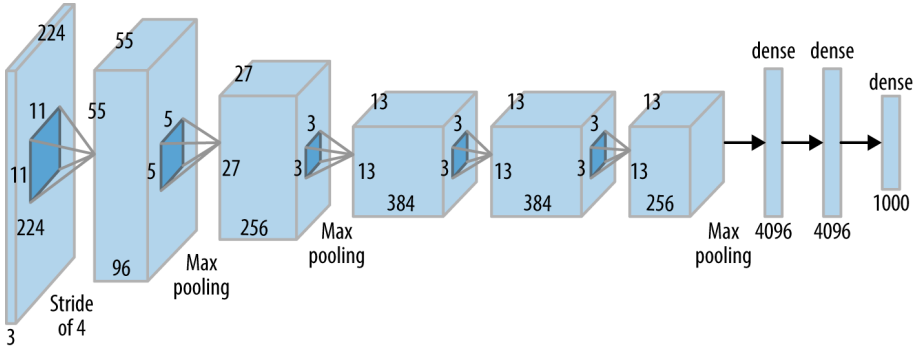

Krizhevsky A. et al. ImageNet classification with deep convolutional neural networks. 2012.

Приложение: распознавание речевых сигналов

Последовательные фрагменты сигнала представляются векторами спектрального разложения

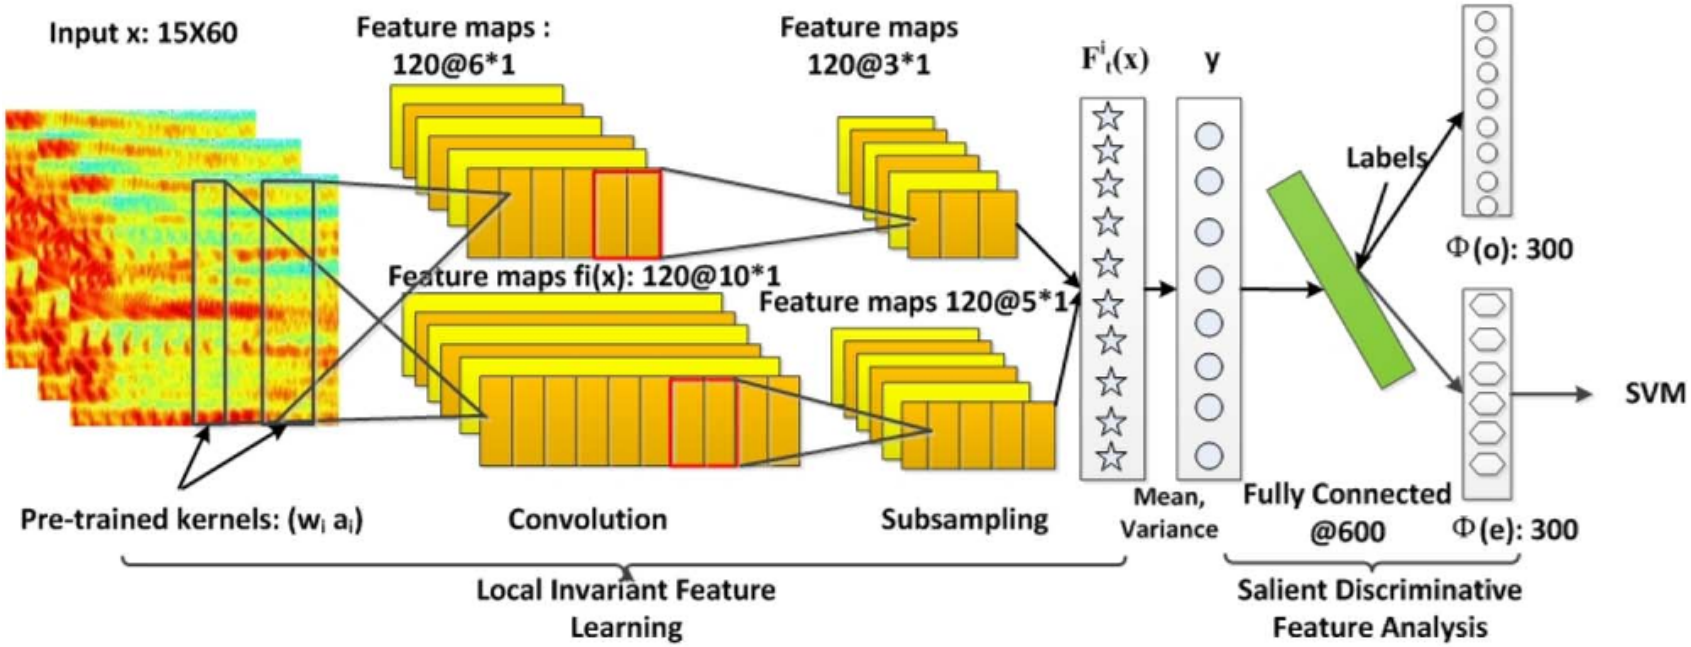

Qirong Mao, Ming Dong, Zhengwei Huang, Yongzhao Zhan. Learning salient features for speech emotion recognition using convolutional neural networks. 2014.

Приложение: классификация предложений в тексте

Последовательные слова в тексте представляются векторами с помощью обучаемых векторных представлений

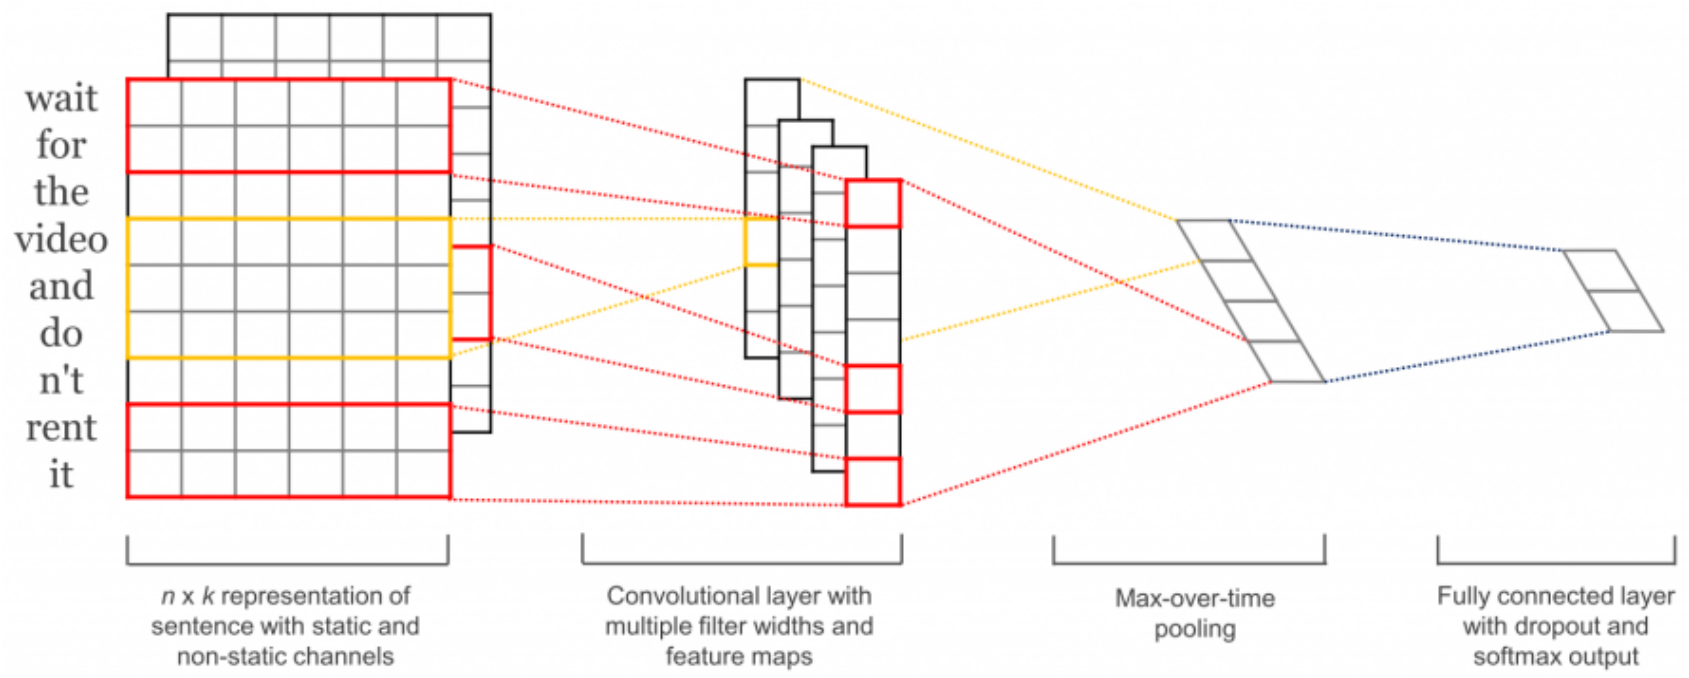

Yoon Kim. Convolutional neural networks for sentence classification. 2014

Yann N. Dauphin et al. Language modeling with gated convolutional networks, 2017.

Приложение: принятие решений в логических играх

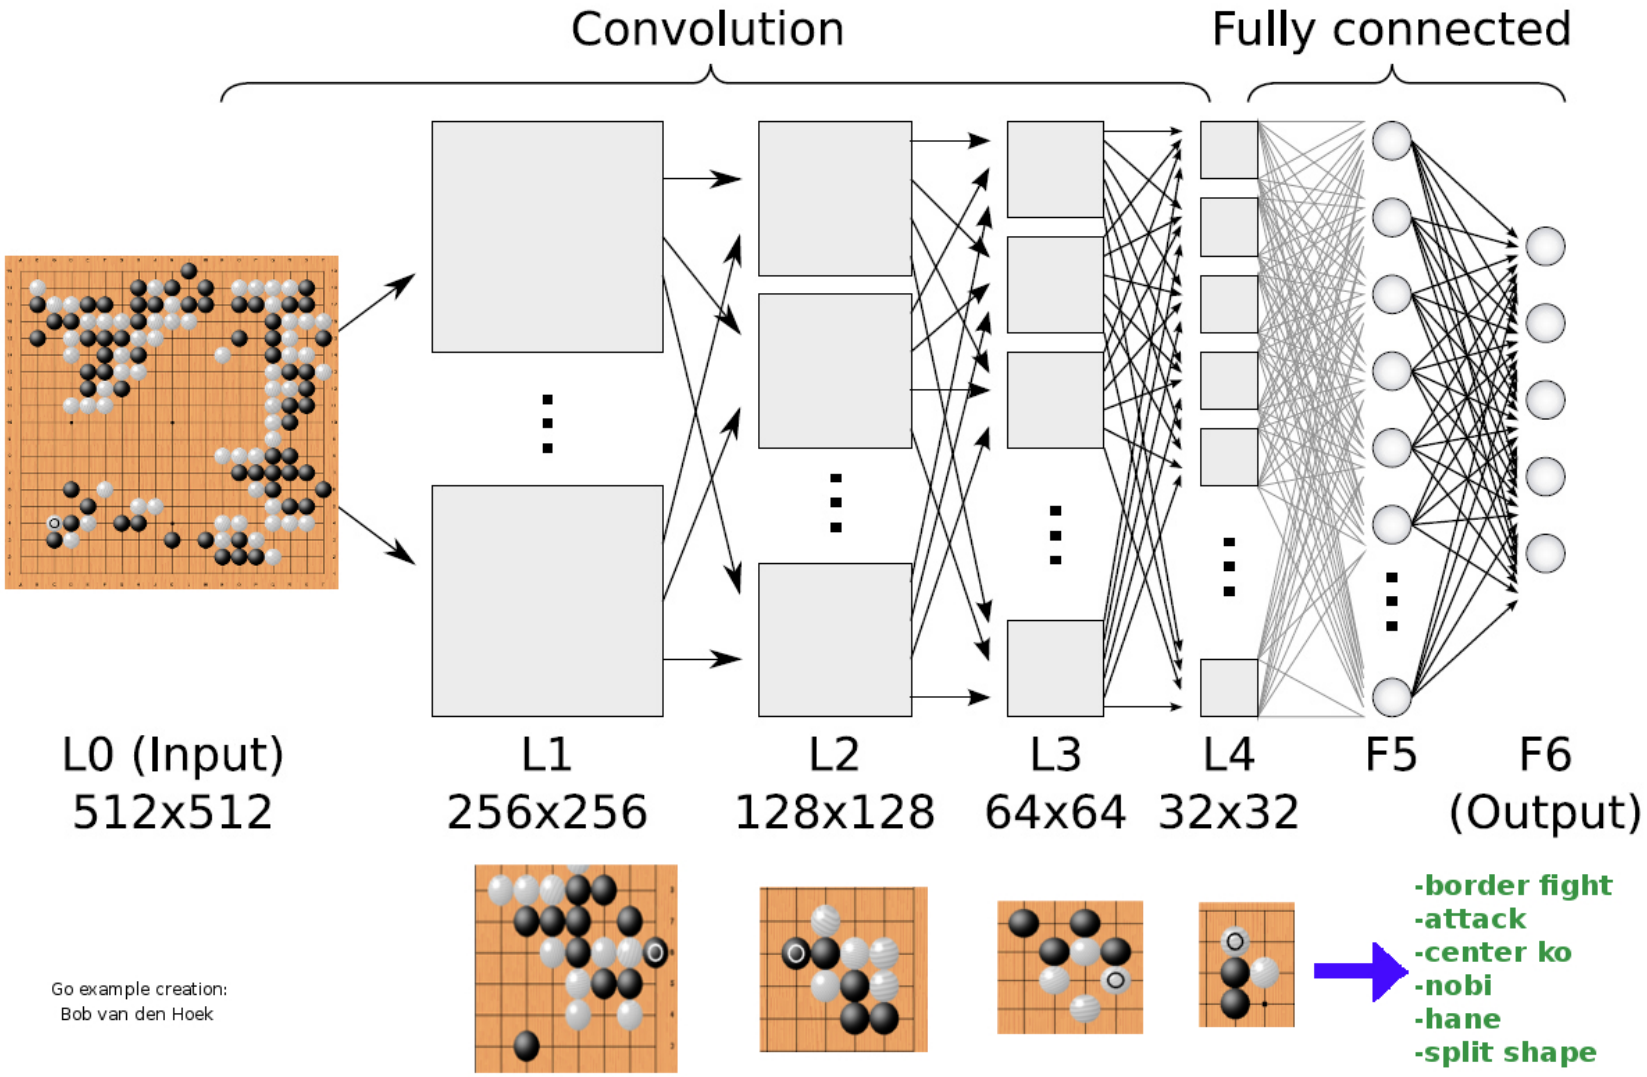

David Silver et al. (DeepMind) Mastering the game of Go without human knowledge. 2017

Предобучение (pre-training), перенос обучения (transfer learning)

Обучение модели векторизации $z = f(x, \alpha)$ на выборке $\{x_i\}_{i=1}^{\ell}$:

$$\sum_{i=1}^{\ell} \mathscr{L}_i\big(g(f(x_i, \alpha), \beta)\big) \;\to\; \min_{\alpha,\beta}$$

Обучение целевой модели $y = g(z, \beta)$ на малых данных $\{x'_i\}_{i=1}^{m}$:

$$\sum_{i=1}^{m} \mathscr{L}'_i\big(g'(f(x'_i, \alpha), \beta')\big) \;\to\; \min_{\beta'}$$

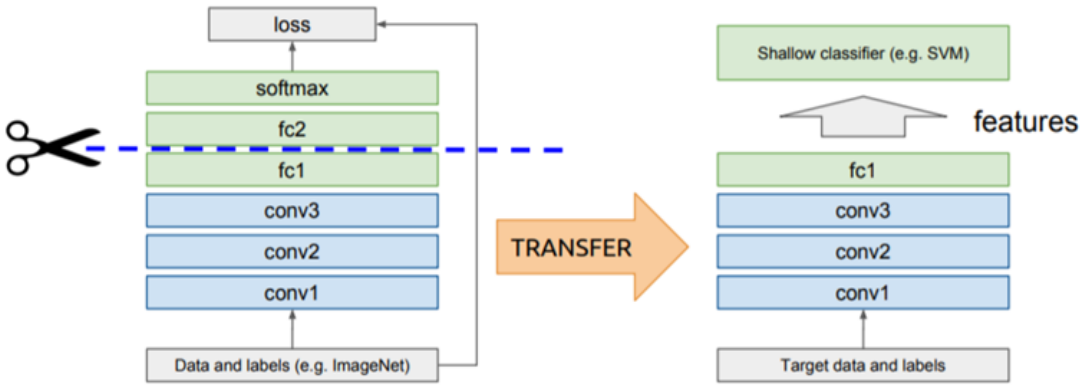

Sinno Jialin Pan, Qiang Yang. A Survey on Transfer Learning. 2009
J.Yosinski et al. How transferable are features in deep neural networks? 2014.

Самостоятельное обучение (self-supervised learning)

Модель векторизации $z = f(x, \alpha)$ обучается предсказывать взаимное расположение пар фрагментов одного изображения

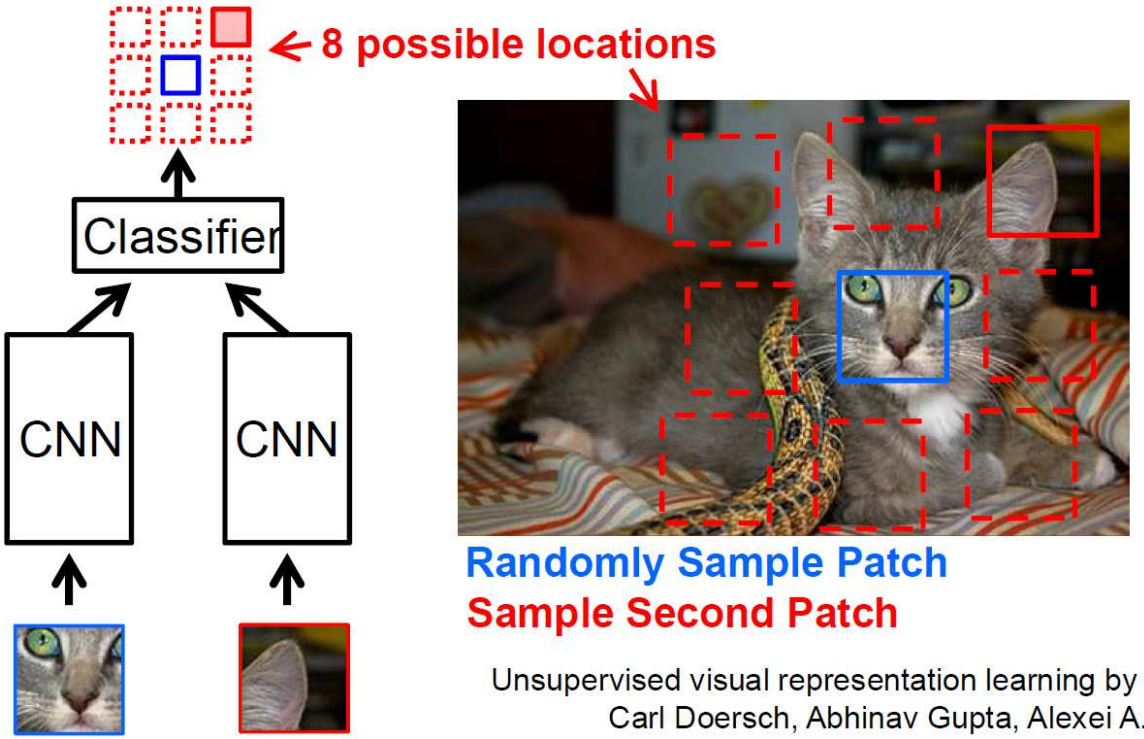

Unsupervised visual representation learning by context prediction,
Carl Doersch, Abhinav Gupta, Alexei A. Efros, ICCV 2015

Преимущество: сеть выучивает векторные представления объектов без размеченной обучающей выборки (без ImageNet).

Многозадачное обучение (multi-task learning)

$z = f(x, \alpha)$ — векторизация, универсальная для всех моделей
$g_t(z, \beta)$ — специфичная часть модели для задачи $t \in T$

Одновременное обучение модели f по задачам X_t, $t \in T$:

$$\sum_{t \in T} \sum_{i \in X_t} \mathscr{L}_{ti}\big(g_t(f(x_{ti}, \alpha), \beta_t)\big) \;\to\; \min_{\alpha, \{\beta_t\}}$$

Обучаемость (learnability): качество решения отдельной задачи $\langle X_t, \mathscr{L}_t, g_t \rangle$ улучшается с ростом объёма выборки $\ell_t = |X_t|$.

Learning to learn: качество решения каждой из задач $t \in T$ улучшается с ростом как ℓ_t, так и общего числа задач $|T|$.

Few-shot learning: для решения новой задачи t достаточно небольшого числа примеров, даже одного (*one-shot learning*).

Yu Zhang, Qiang Yang. A survey on multi-task learning. 2021
M.Crawshaw. Multi-task learning with deep neural networks: a survey. 2020
Y.Wang et al. Generalizing from a few examples: a survey on few-shot learning. 2020

Место обучаемой векторизации в машинном обучении

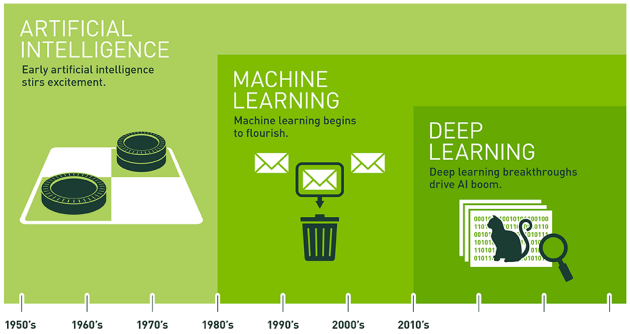

ИИ вне машинного обучения:
— экспертные системы
— системы представления знаний
— системы логического вывода
— автоматическое док-во теорем

Три этапа развития машинного обучения

- **вектор** $\to$ **вектор** $\to$ **скаляр** (shallow learning)
  конструирование признаков (feature engineering)
- **структура** $\to$ **вектор** $\to$ **скаляр** (deep learning)
  векторизация сложно структурированных данных, обучаемая совместно с предсказательной моделью
- **структура** $\to$ **вектор** $\to$ **структура** (generative models)
  генеративные модели сложно структурированных данных, единое пространство эмбедингов (foundation models)

Резюме

Обучение без учителя — выявление структур в данных

- Сети Кохонена — никакие не сети, просто кластеризация
- LVQ — кластеризация для классификации и квантизации
- Карты Кохонена — кластеризация для 2D-визуализации

Разновидности векторизации данных:

- *Квантизация* — сокращение объёма выборки, замена объектов ближайшими центрами кластеров
- *Автокодировщики* — синтез векторных представлений (эмбедингов) объектов, обычно с понижением размерности
- *Метод главных компонент* — частный случай линейного автокодировщика
- *Вариационный автокодировщик* — синтез объектов, похожих на обучающие
- *Глубокие сети* от CNN до GPT — основная части сети для обучаемой векторизации, последние слои для предсказания

Методы обучения — на основе SG