Лекция 13: Бустинг

«Самый древний» дискретный бустинг

- Усиление за счет фильтрации (Schapire 1989):
  - Случайно выбрать $n_1 < n$ примеров из выборки D без удаления
  - Получить D_1 и построить «слабую» модель $b_1(x)$
  - Выбрать $n_2 < n$ примеров из D с фильтрацией по $b_1(x)$ - применить к примерам $b_1(x)$, и с вероятностью ½ добавлять ошибки в D_2 и с вероятностью ½ не ошибки
  - На D_2, где половина – ошибки $b_1(x)$, построить «слабую» модель $b_2(x)$
  - Выбрать все D_3 из D где $b_1(x)$ и $b_2(x)$ дают разный прогноз и построить «слабую» модель $b_3(x)$
  - Финальный «усиленный» классификатор – голосование $b_1(x), b_2(x), b_3(x)$
- Почему работает?
  - в голосовании должно быть 2+ голосов
  - $b_1(x)$ и $b_2(x)$ - максимально не похожи
  - если $b_1(x) \neq b_2(x)$, то решает $b_3(x)$, который для этого учился
  - если $b_1(x) = b_2(x)$, то мнение $b_3(x)$ не интересно

Идея адаптивного бустинга

- Развивает идею «старого» бустинга с фильтрацией:
  - Вместо случайной выборки – перевзвешивание, т.е. оценка **«важности»** или **«сложности» примеров** (зависит от ошибки ансамбля на примере)
  - Построение «слабых» классификаторов (точность хотя бы >50%)
  - Результирующий «сильный» классификатор может иметь много слабых классификаторов и пользуется взвешенным голосованием, здесь **вес базового классификатора – его «сила»**
- Заимствует постановку задачи и подход у Forward Stagewise Additive Modeling (FSAM), решающего задачу прогнозирования:
  - Выборка $Z = \{(x_i, y_i)\}_{i=1}^{l} \in X \times Y$
  - Модель – взвешенный с весами α_i ансамбль *M* базовых моделей $a(x) = \sum_m \alpha_m b_m(x)$, который строится последовательно $a_m(x) = a_{m-1}(x) + \alpha_m b_m(x)$, где ищутся α_m, b_m при фиксированном a_{m-1}
  - Функция потерь $L: Y \times Y \to \mathbb{R}^+$

Forward Stagewise Additive Modeling

- FSAM
  - строит модель **последовательно**, добавляя к текущей модели a_m на шаге m «лучший» b_m с «лучшим» весом α_m :
  - Инициализация $a_0(x) = 0$
  - Цикл *M* итераций по m :

$$(b_m, \alpha_m) = \underset{b,\alpha}{\operatorname{argmin}} \sum_{i=1}^{l} L\big(y_i, a_{m-1}(x_i) + \boldsymbol{\alpha b}(\boldsymbol{x_i})\big)$$

$$a_m(x) = a_{m-1}(x) + \alpha_m b_m(x)$$

- Для некоторых L и b_i - простое аналитическое решение, примеры:
  - **AdaBoost:** L – экспоненциальная функция потерь, b_i - простое дерево (или даже «пень»), a_i вычисляются аналитически
  - **Additive Groves**: L – квадратичная, а b_i - дерево, $a_i = 1$, получаем ансамбль на остатках, для борьбы с переобучением используется bagging и специальный алгоритм, ищущий «оптимальное» сочетание сложности ансамбля и индивидуальных моделей

Additive (Tree) Groves

- Особенности метода:
  - Аддитивный ансамбль (без весов) $a(x) = \sum_m b_m(x)$, деревьев решений $b_m(x)$, построенных на $Z_m = \{(x_i, y_i - a_{m-1}(x_i))\}_i^l$, где вместо отклика используются остатки от предыдущего ансамбля.

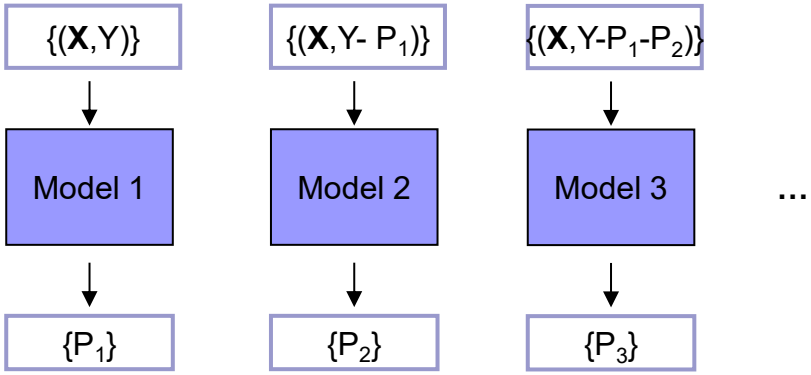

  - Поскольку обучение на остатках, то на сложных b_m быстро переобучается при увеличении, исчерпываются остатки $\{(x_i, 0)\}_i^{n<l}$
  - Использует бутсрепинг подвыборку меньшего размера Z_m^* (как в random forest)
  - специальный алгоритм для контроля сложности на основе роста дерева «по слоям»

Контроль сложности Additive Groves

- Переборный алгоритм контроля сложности:
  - От простого (одно маленькое дерево) делаются шаги в сторону увеличения ансамбля без изменения сложности деревьев (увеличивается параметр M – размер ансамбля) и в сторону увеличения глубины деревьев без увеличения ансамбля (меняется параметр обрубания или число листьев D)
  - Если качество по OOB улучшается, то шаг принимается
  - Осуществляется поиск «оптимальной» точки гиперпарамтеров (N,D), без повторных вычислений (если пришли в точку разными путями)

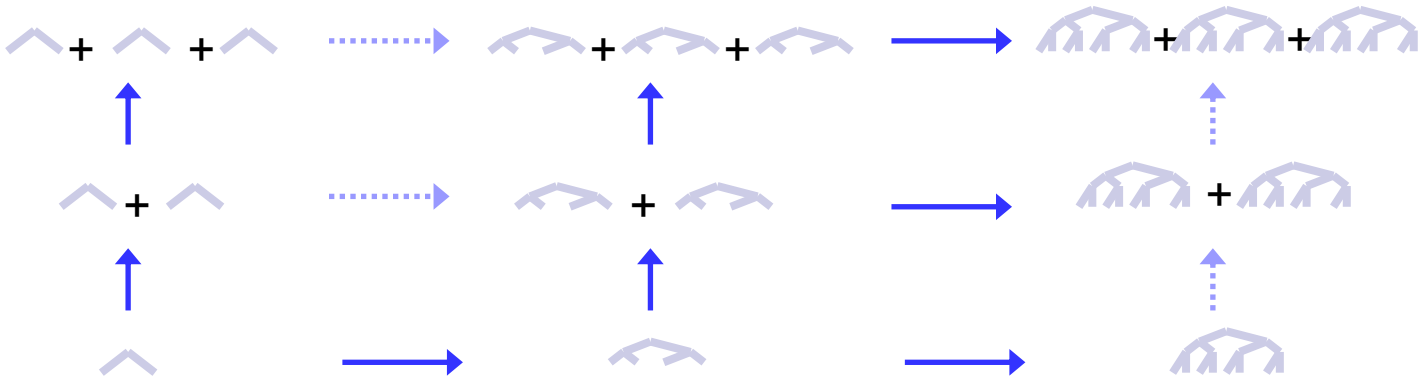

Адаптивный дискретный бустинг

- Основные допущения:
  - Выборка $Z = \{(x_i, y_i)\}_{i=1}^{l} \in X \times \{-1, +1\}$, где у каждого наблюдения (x_i, y_i) свой вес $w_i \geq 0$, причем $\sum_i w_i = 1$ (распределение)
  - Модель-ансамбль с взв. голосованием $a(x) = sign[\sum_m \alpha_m b_m(x)]$
  - Введем понятие взвешенной (по распределению w_i) ошибки классификации:

$$Err_w\big(a(x)\big) = \sum_{i=1}^{l} w_i \, I[y_i \neq a(x_i)]$$

  - Будем использовать экспоненциальную функцию потерь $L_{exp}\big(y, a(x)\big) = \exp(-y \sum_m \alpha_m b_m(x))$
- Идея алгоритма обучения (цикл):
  1. считаем ошибки для всех примеров
  2. перевзвешиваем все примеры
  3. обучаем базовый классификатор
  4. добавляем его в ансамбль с новым весом

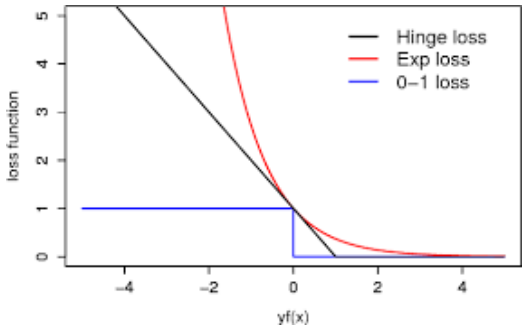

AdaBoost (алгоритм)

- Инициализация:
  - $a_0(x) = 0, \forall i: w_i^{(1)} = 1/l$
- Итераций по m от 1 до M:
  - Строим **слабый классификатор** $b_m(x)$, минимизирующий и допускающий ошибку $Err_{w^{(m)}}(b_m) < 0.5$

$$b_m(x) = \underset{b}{\operatorname{argmin}} \sum_{i=1}^{l} w_i^{(m)} I[b(x_i) \neq y_i]$$

  - Добавляем b_m в ансамбль $a_m(x) = a_{m-1}(x) + \alpha_m b_m(x)$, где **силу классификатора** вычисляем как:

$$\alpha_m = \frac{1}{2} \log\left(\frac{\left(1 - Err_{w^{(m)}}(b_m)\right)}{Err_{w^{(m)}}(b_m)}\right)$$

  - Пересчитываем и нормируем **веса важности** примеров:

$$\widetilde{w}_i = w_i^{(m)} \exp\left(-y_i \alpha_m b_m(x_i)\right), \; w_i^{(m+1)} = \widetilde{w}_i \; / \sum_j \widetilde{w}_j$$

- Откуда взялись формулы для b_m, α_m и $w^{(m)}$?

Adaboost (демо)

- Простой пример Adaboost (длины 3) на «пнях» (деревьях глубины 1):

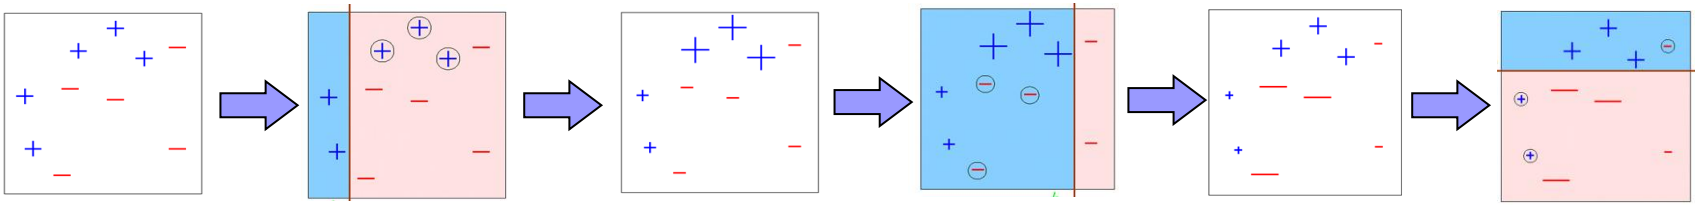

$Err_{w^{(1)}} = 0.3$
$\alpha_1 = 0.42$

$Err_{w^{(2)}} = 0.21$
$\alpha_2 = 0.65$

$Err_{w^{(3)}} = 0.14$
$\alpha_3 = 0.92$

- Финальный классификатор:

$a(x) = \text{sign}\Big(0.42 *$ 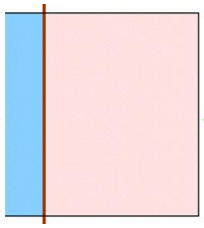 $+ 0.65 *$ 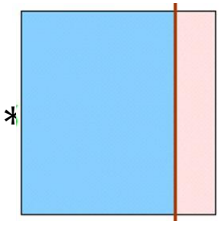 $+ 0.92 *$ 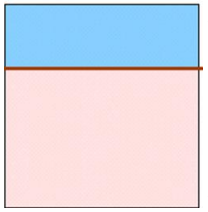 $\Big)$

Пример

```
from sklearn.ensemble import AdaBoostClassifier
from sklearn.tree import DecisionTreeClassifier

weak_learner = DecisionTreeClassifier(max_leaf_nodes=2)

for i in range(1,50,10):
    adaboost_clf = AdaBoostClassifier(estimator=weak_learner, n_estimators=i,
        algorithm="SAMME",random_state=42).fit(X, y)
    DecisionBoundaryDisplay.from_estimator(adaboost_clf, X, cmap="Pastel1")
    plt.scatter(*X.T, c=y, cmap="Set1")
```

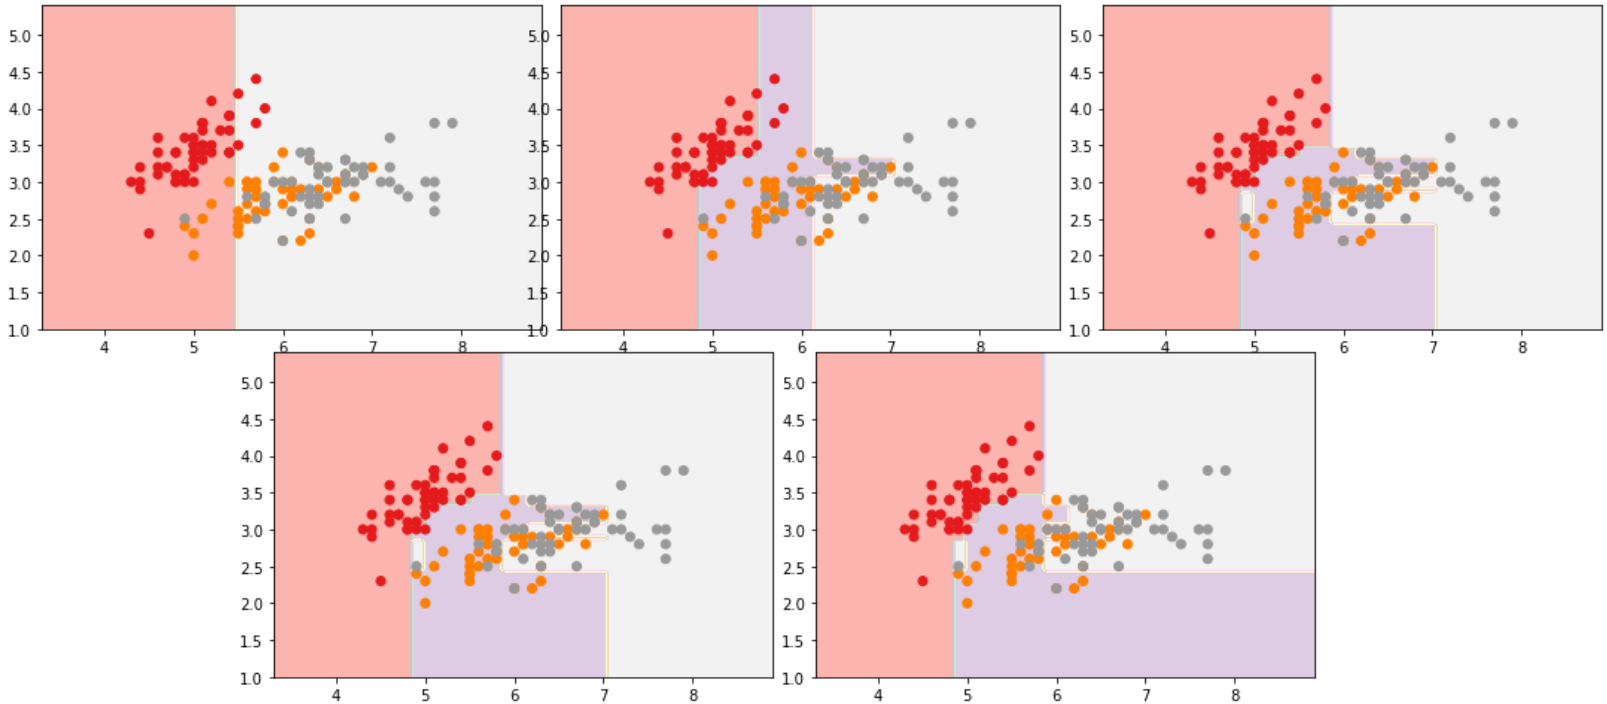

Пересчет весов классификаторов

- Рассмотри на итерации m алгоритма эмпирический риск с функцией потерь на основе ошибки классификации, он ограничен сверху риском с экспоненциальной функцией потерь:

$$Q_{perc}^{(m)} = \sum_{i=1}^{l} I[y_i \neq a_m(x_i)] \leq Q_{exp}^{(m)} = \sum_{i=1}^{l} \exp[-y_i a_m(x_i)] =$$

$$= \sum_{i=1}^{l} \exp\left[-y_i\left(\sum_{j=1}^{m} \alpha_j b_j(x_i)\right)\right] = \sum_{i=1}^{l} \underbrace{\mathbf{exp}\left[-\boldsymbol{y_i}\left(\sum_{\boldsymbol{j=1}}^{\boldsymbol{m-1}} \boldsymbol{\alpha_j b_j(x_i)}\right)\right]}_{\sim \boldsymbol{w_i^{(m)}} \text{ – не зависит от } \alpha_m, b_m} \exp[-y_i \alpha_m b_m(x_i)] \sim$$

$$\sim \sum_{i=1}^{l} w_i^{(m)} \exp[-y_i \alpha_m b_m(x_i)] = e^{-\alpha_m} \underbrace{\sum_{\boldsymbol{i}:\boldsymbol{y_i}=\boldsymbol{b_m}(\boldsymbol{x_i})} \boldsymbol{w_i^{(m)}}}_{\text{доля верных прогнозов с весами } (1 - Err_{w^{(m)}})} + e^{\alpha_m} \underbrace{\sum_{\boldsymbol{i}:\boldsymbol{y_i}\neq\boldsymbol{b_m}(\boldsymbol{x_i})} w_i^{(m)}}_{\text{доля ошибок с весами } Err_{w^{(m)}}} =$$

= …

$$\boxed{e^{-\alpha b} = e^{-\alpha} I[b = 1] + e^{\alpha} I[b = -1]}$$

Пересчет весов классификаторов

- Продолжение:

$$\ldots = \left(1 - Err_{w^{(m)}}\right)e^{-\alpha_m} + \left(Err_{w^{(m)}}\right)e^{\alpha_m} = Q_{Err_{w^{(m)}}}(\alpha_m) \to min$$

- Найдем $\min\limits_{\alpha_m}[Q_{Err_{w^{(m)}}}(\alpha_m)]$:

$$\frac{\partial Q_{Err_{w^{(m)}}}}{\partial \alpha_m} = 0 \Rightarrow \boxed{\alpha_m = \frac{1}{2}\log\left(\frac{1 - Err_{w^{(m)}}}{Err_{w^{(m)}}}\right)}$$

- Подставляем α_m в $Q_{Err_{w^{(m)}}}$ и получаем, что верхняя оценка эмпирического риска экспоненциально уменьшается с уменьшением взвешенной ошибки $Err_{w^{(m)}}$:

$$\left(1 - Err_{w^{(m)}}\right)e^{-\frac{1}{2}\log\left(\frac{1-Err_{w^{(m)}}}{Err_{w^{(m)}}}\right)} + \left(Err_{w^{(m)}}\right)e^{\frac{1}{2}\log\left(\frac{1-Err_{w^{(m)}}}{Err_{w^{(m)}}}\right)} =$$

$$= 2\sqrt{Err_{w^{(m)}}\left(1 - Err_{w^{(m)}}\right)} \le \exp\left(-2\left(0.5 - Err_{w^{(m)}}\right)^2\right)$$

Обучение слабых классификаторов и пересчет весов

- При фиксированном $\alpha_m > 0$ выразим наилучший слабый b_m :

$$e^{-\alpha_m} \sum_{i:y_i=b(x_i)} w_i^{(m)} + e^{\alpha_m} \sum_{i:y_i\neq b(x_i)} w_i^{(m)} =$$

$$= [(e^{\alpha_m} - e^{-\alpha_m}) \sum_i w_i^{(m)} I[y_i \neq b(x_i)] + e^{-\alpha_m} \sum_i w_i^{(m)}] \to \min_{b_m}$$

$$\boxed{b_m(x) = \operatorname{argmin}_b \sum_{i=1}^{l} w_i^{(m)} I[b(x_i) \neq y_i]}$$

Не зависит от b_m и >0 при $\alpha_m > 0$

- Поскольку $a_m(x) = a_{m-1}(x) + \alpha_m b_m(x)$ потери выразим рекурсивно:

$$\sum_{i=1}^{l} \exp[-y_i a_m(x_i)] = \sum_{i=1}^{l} \exp\left[-y_i\left(\sum_{j=1}^{m} \alpha_j b_j(x_i)\right)\right] =$$

$$= \sum_{i=1}^{l} w_i^{(m)} \exp[-y_i \alpha_m b_m(x_i)] = \sum_{i=1}^{l} w_i^{(m-1)} \exp[-y_i(\alpha_{m-1} b_{m-1}(x_i) + \alpha_m b_m(x_i))] =$$

$$= \sum_{i=1}^{l} w_i^{(1)} \exp[-y_i \alpha_1 b_1(x_i)] \exp[-y_i \alpha_2 b_2(x_i)] \ldots \exp[-y_i \alpha_m b_m(x_i)] \Rightarrow$$

$$\boxed{=> w_i^{(m+1)} = w_i^{(m)} \exp\left(-y_i \alpha_m b_m(x_i)\right)}$$

Теоретические результаты

- Условия применимости:
  - «достаточно богатое» семейство слабых классификаторов
  - качество слабого классификатора лучше случайного прогноза
  - «не слишком высокая» зашумленность данных
- Формально доказан ряд важных свойств алгоритма Adaboost:
  - приводит к минимизации эмпирического риска с экспоненциальной функцией потерь при использовании предложенной процедуры пошагового усложнения ансамбля и полученных формул пересчета нормированных весов примеров и весов слабых классификаторов
  - сходится за конечное число шагов
  - с увеличением числа итераций увеличивает зазор между классами и, значит, уменьшает ошибку классификации – полезно строить график зазора от шага итерации и распределение отступов на каждом шаге

Сложность ансамбля Adaboost и борьба с переобучением

- Сложность ансамбля:
  - Определяется размером ансамбля (чем больше тем сложнее)
  - Определяется сложностью базового классификатора
  - За счет экспоненциальной функции потерь может улучшаться на проверочной выборке даже когда ошибка на тренировочной ушла в 0

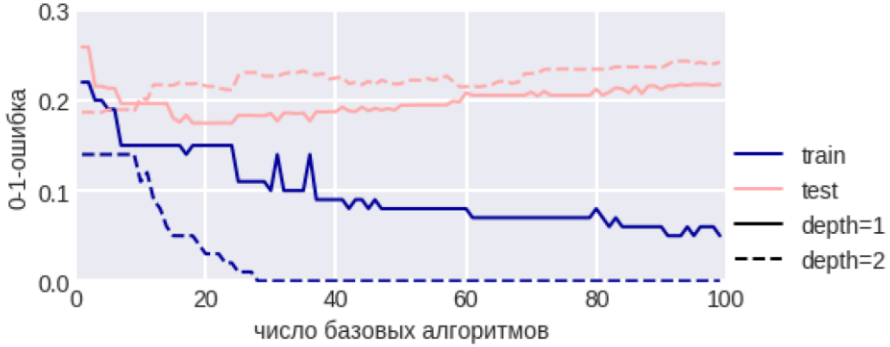

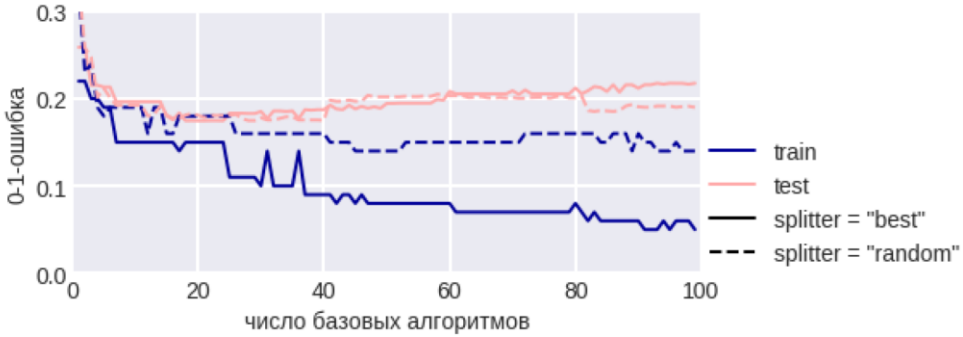

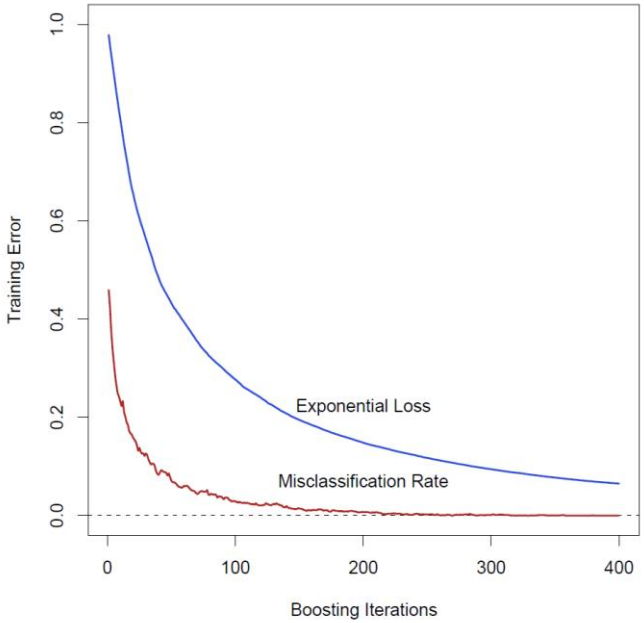

Борьба с переобучением

- Методы борьбы с переобучением:
  - Управлять размером ансамбля
  - Ограничивать сложность или упрощать (например pruning) слабые классификаторы
  - Можно пытаться контролировать (менять вес) или удалять выбросы «на лету», анализируя веса или отступы и их распределение (оно с каждой итерацией должно «смещаться вправо», «раздвигая» классы)
  - В некоторых реализациях можно контролировать learning rate или использовать регуляризацию
  - Т.к. бустинг ищет зависимости от простых к сложным, то можно использовать early stopping

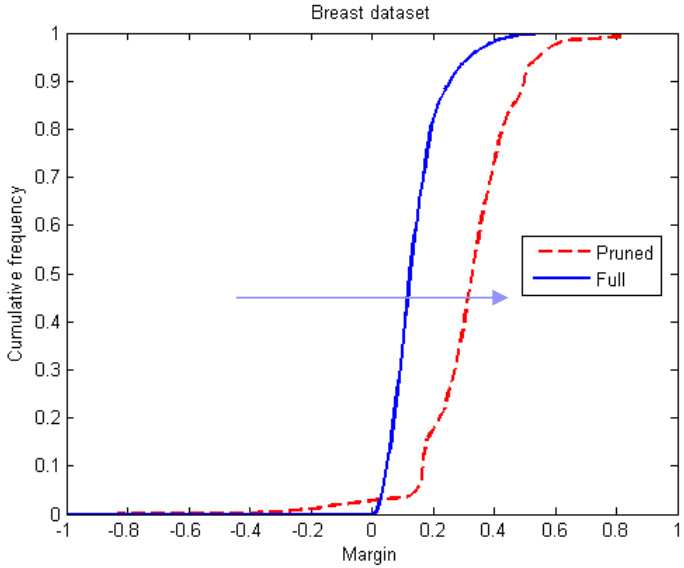

Недостатки Adaboost

- Чувствительность к выбросам:
  - из-за экспоненциальной функции потерь может быстро переобучаться при наличии шума
  - можно пытаться контролировать выбросы «на лету»
  - нужно использовать простые слабые модели, в результате не позволяет строить маленькие ансамбли сложных моделей, только большие ансамбли простых моделей
- Проблемы применения:
  - Вычислительно сложная модель (если много базовых)
  - Не интерпретируемая модель, даже если базовые модели интерпретируется
- Проблемы обучения:
  - Склонен к переобучению в зашумленных задачах
  - Требуются большие выборки
  - Плохо распараллеливается (только «внутри» обучения базовой модели)

Сравнение Adaboost

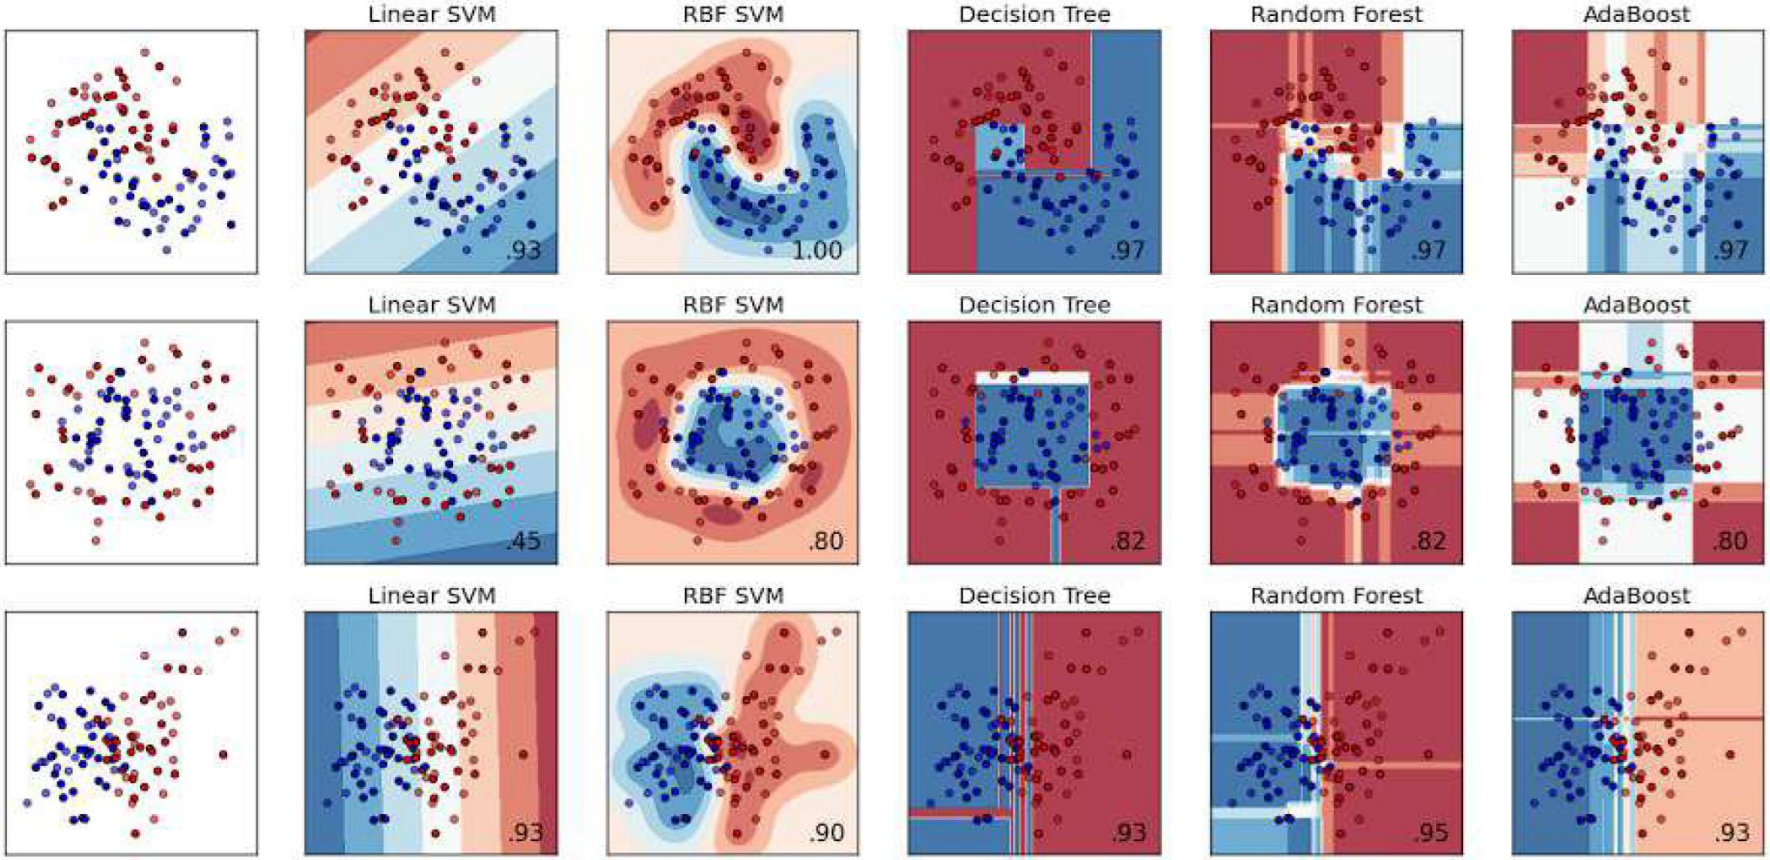

Бустинг с перевыборкой (пример)

- Arc-x4 (Breiman, 1996) как в AdaBoost последовательно строит модель $a_m(x) = a_{m-1}(x) + \alpha_m b_m(x)$, но:
  - В классической версии **нет весов классификаторов** – голосующий комитет или усреднение (хотя есть версии с эвристическим или FSAM пересчетом весов)
  - слабый классификатор **не учитывает веса примеров**, а строится на случайной выборке, где у наблюдения вероятность попасть в нее пропорциональная весу
  - Не требуется взвешенная функция ошибки или функция потерь – **может «бустить» любые базовые модели**
  - Вес имеет семантику как и в AdaBoost – **«сложность» примера**, и пересчитывается в зависимости от числа ошибок на нем слабых классификаторов ансамбля, классическая формула для классификации (эвристика):

$$w_i^{(m)} = \frac{\left(1 + \sum_{s=1}^{m} I[b_s(x_i) \neq y_i]\right)^{\mathbf{4}}}{\sum_{j=1}^{l} w_j^{(m)}}$$

Алгоритм Arc-X4

- Инициализация: $a_0(x) = 0, \forall i: w_i^{(1)} = 1/l$
- Цикл алгоритма (M итераций):
  - Формируется из набора Z **случайная выборка** $Z^{(m)}$ размера n, с вероятностью выбора примера пропорциональной распределению весов примеров ($n < l$ – параметр): $P(x_i \in Z^{(m)}) \propto w_i^{(m)}$
  - Обучается **слабая модель** $b_m(x)$ со своей функцией потерь
  - Добавляется b_m в ансамбль $a_m(x)$, где **силу классификатора** не меняют (хотя есть версии с весами и регуляризацией):

    для классификации: $a(x) = \mathrm{argmax}_i[b_i(x)]$

    для регрессии: $a(x) = \frac{1}{M}\sum b_i(x)$
  - Пересчитываются и нормируются **веса важности** примеров в зависимости от числа ошибшихся слабых классификаторов:

$$w_i^{(m)} = \frac{(1 + \sum_{s=1}^{m} L[b_s(x_i), y_i])^{\mathbf{4}}}{\sum_{j=1}^{l} w_j^{(m)}}$$

Arc-x4

- Достоинства:
  - Простота и эффективность (сопоставим с AdaBoost по качеству)
  - Не накладывает требования на тип моделей и функции потерь
  - Можно использовать свои эвристики весов
  - Легко адаптируется к разным задачам прогнозирования
- Основной недостаток – нет теоретического обоснования
- Демо-пример:

$$P(x_i \in Z^{(m)}) \propto (1 + Err_m)^{\mathbf{4}}$$

$$Err_m = \sum_{s=1}^{m} I[b_s(x_i) \neq y_i]$$

	m=1		m=2		m=3		m=4	…
x	w	Err	w	Err	w	Err	w	
1	1	1	1.5	1	.5	2	.97	
2	1	0	.75	0	.25	0	.06	
3	1	1	1.5	2	4.25	3	4.69	
4	1	0	.75	1	.5	1	.11	
5	1	0	.75	0	.25	0	.06	
6	1	0	.75	0	.25	1	.11	

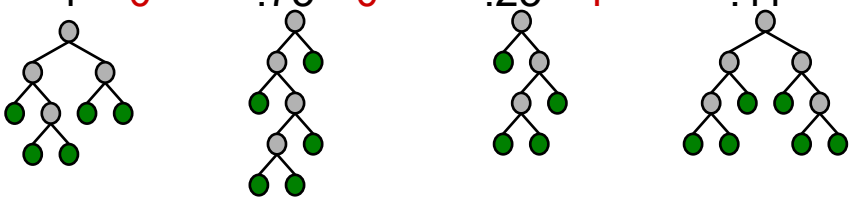

Идея градиентного бустинга

- Снова рассмотрим FSAM:
  - На каждом шаге цикл последовательного формирования ансамбля $a_m(x) = a_{m-1}(x) + \boldsymbol{\alpha_m b_m(x)}$ требует решения:

$$(b_m, \alpha_m) = \underset{b,\alpha}{\operatorname{argmin}}\, Q_m(b,\alpha)\,, Q_m(b,\alpha) = \sum_{i=1}^{l} L\big(y_i, a_{m-1}(x_i) + \alpha b(x_i)\big)$$

  - Но не для всех L есть аналитическое решение, что делать?
- Использовать приближенное решение:
  - Рассмотрим $Q_m(F_m)$ на шаге m как функцию от вектора прогнозов для всех примеров

$$F_m = [a_m(x_i)]_{i=1}^{l} = \left[\left(\sum_{j=1}^{m-1} \alpha_j b_j(x_i) + \alpha_m b_m(x_i)\right)\right]_{i=1}^{l} = [F_{m-1} + \alpha_m b_m(x_i)]_{i=1}^{l}$$

  - $F_0, F_1, \dots, F_m$ - последовательность приближений откликов
  - Нужно минимизировать по F_m $Q_m = \sum_i L(y_i, F_m(x_i))$
- **Оптимизация не в пространстве параметров модели, а в пространстве прогнозов модели (размера всей выборки)**

Градиентный бустинг

- Почему «градиентный»?
  - Раскладываем риск Q_m в ряд Тейлора 1 порядка по вектору F_{m-1} :

$$\sum_i L(y_i, F_{m-1}(x_i) + a_m b(x_i)) \approx \sum_i L\big(y_i, F_{m-1}(x_i)\big) + a_m b(x_i) \frac{\partial L(y_i, F_{m-1})}{\partial F_{m-1}}(x_i) + \cdots$$

  - Итерационно (**градиентным методом с шагом** α_m) минимизируем Q по $F_m = F_{m-1} - \alpha_m \nabla Q_m$, где $\nabla Q_m = \left[\frac{\partial Q}{\partial F_{m-1}}(x_i)\right]_{i=1}^{l} = \left[\frac{\partial L(y_i, F_{m-1})}{\partial F_{m-1}}(x_i)\right]_{i=1}^{l}$
  - В тоже время $F_m = F_{m-1} + \alpha_m b_m$ => нужно находить такое b_m, чтобы он **прогнозировал антиградиент функции потерь**
  - Значит на каждом шаге строим слабую модель (со своей функцией потерь) $b_m(x)$ на обучающем наборе $Z_m = \{(x_i, -\nabla Q_m(x_i))\}_{i=1}^{l}$, с $\boldsymbol{-\nabla Q_m}$ **в качестве отклика**
  - Находим размер шага с помощью любого метода оптимизации для одномерной задачи, например, с помощью линейного поиска (вектор прогнозов $b_m(x_i)$ зафиксирован):

$$\alpha_m = \underset{\alpha \in R}{\operatorname{argmin}} \sum_{i=1}^{N} L(y_i, F_{m-1}(x_i) + \alpha b_m(x_i))$$

Градиентный бустинг деревьев

- Финальная модель (M – число итераций):

$$F_m(x) = F_{m-1}(x) + \nu\alpha_m T_m(x) = F_0 + \nu\alpha_1 T_1(x) + \nu\alpha_2 T_2(x) + \ldots + \nu\alpha_M T_m(x)$$

- Каждая базовая модель – дерево:

$$T_m(x) = \sum_{R \in R_m} \gamma_R \, I[x \in R]$$

  - где R_m - множество регионов, соответствующих листьям дерева, а γ_R - прогноз отклика в листе
  - Каждая следующая модель $T_m(x)$ обучается на «псевдоостатках» от F_{m-1}: $y_i^{(m)} = -\frac{\partial L(y_i, F_{m-1})}{\partial F_{m-1}}(x_i)$
  - *0*<ν<1 – shrinkage регуляризация

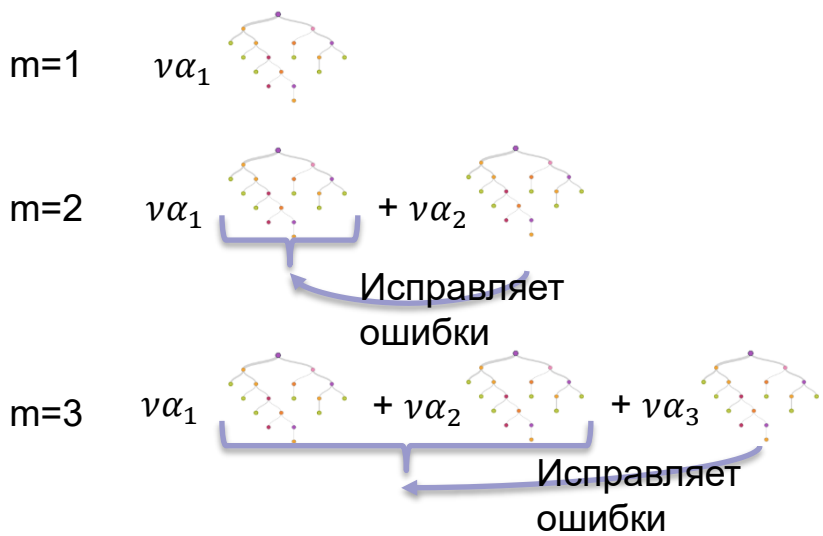

Борьба с переобучением

- Градиентный бустинг склонен к переобучению в условиях шума
- Методы борьбы с переобучением:
  - **Стохастический градиентный бустинг** - случайные подвыборки (можно использовать OOB оценки) меньшего размера для обучения базовых моделей на каждой итерации (иногда используют бутсрепинг): $Z_m = (x_i, -\nabla Q_m(x_i))_{i=1}^{n<l}$
  - **Ранняя остановка** (по порогам или по контрольной выборке)
  - Контроль **размера ансамбля** и **ограничение** (или упрощение, например, pruning) **сложности базовых моделей**, также можно использовать дообучение деревьев по уровням
  - **Shrinkage** (или learning rate) – не позволяет быстро «исчерпать» псевдоостатки, но требуется больше моделей в финальном ансамбле
  - **Регуляризация** L_0, L_1 или L_2

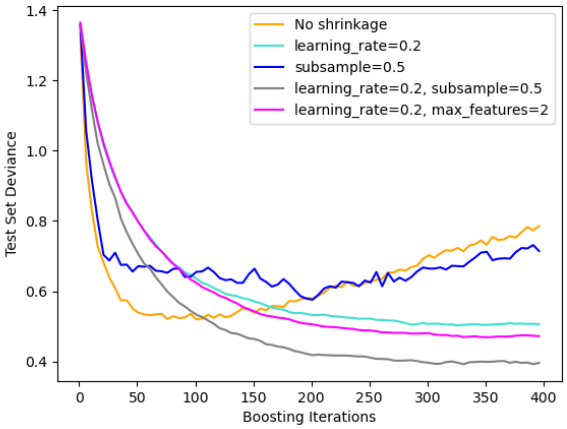

Функции потерь

- Кастомизируемые и **робастные** функции потерь:

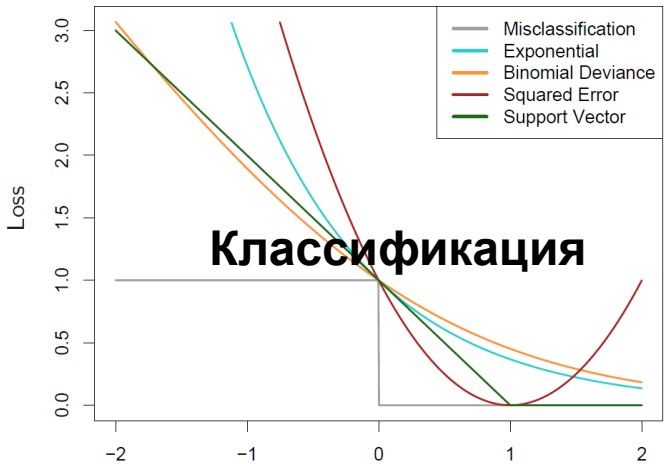

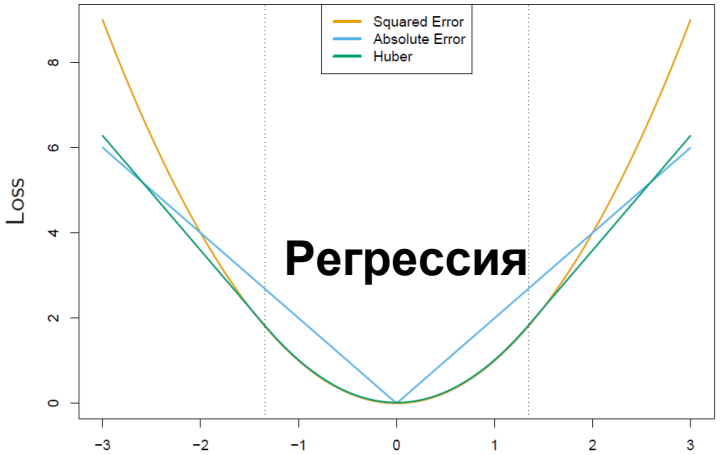

Задача	Потери	Псевдоостаток (производная функции потерь)
Регрессия	$\left(y_i - a(x_i)\right)^2$	$y_i - a(x_i)$
Регрессия	$\lvert y_i - a(x_i)\rvert$	$\mathrm{sign}(y_i - a(x_i))$
Регрессия	Huber	$y_i - a(x_i)$, при $\lvert y_i - a(x_i)\rvert \leq \sigma$, иначе $\mathrm{sign}(y_i - a(x_i))$
K классов	K классов	$I[y_i = C_k] - p_k(x_i)$ для класса k
2 класса	$\log(1 + e^{-a(x_i)y_i})$	$-y_i/(1 + e^{-a(x_i)y_i})$
…	…	…

Би- и Мульти- номинальная функция потерь

- Классификации с несколькими классами:
  - $Y = \{C_1, \dots, C_K\}$, $p_k(x) = P(Y = C_k|x)$
  - Правило Байеса $k = \mathrm{argmax}_s[p_s(x)]$
  - $g_k(x)$ - дискриминантная функция класса k
  - $p_k(x) = \mathrm{softmax}\big(g_1(x), \dots, g_K(x)\big) = \frac{e^{g_k(x)}}{\sum_{s=1}^{K} e^{g_s(x)}}$
  - Кросс энтропия: $L\big(y, p(x)\big) = -\sum_{k=1}^{K} I[y = k] \log\big(p_k(x)\big) = -\sum_{k=1}^{K} I[y = k]\, g_k(x) + \log(\sum_{s=1}^{K} e^{g_s(x)})$
  - Псевдоостаток для класса k: $\boldsymbol{-L'\big(y, p_k(x)\big) = I[y_i = C_k] - p_k(x_i)}$
- Бинарный случай:
  - $Y = \{0,1\}, p(x) = p_1(x) = P(Y = 1|x) = \frac{1}{1+e^{-g(x)}}$, $p_0(x) = 1 - p(x)$
  - $L\big(y, p(x)\big) = y\log\big(p(x)\big) + (1 - y)\log\big(1 - p(x)\big)$, и если $g(x) \equiv a(x) \Rightarrow$

$$L\big(y, a(x)\big) = \log(1 + e^{-a(x)y}) \Rightarrow$$

Псевдоостаток $\boldsymbol{L'\big(y, a(x)\big) = -y/(1 + e^{-a(x)y})}$

Градиентный бустинг (пример)

```
from sklearn.datasets import fetch_california_housing
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.metrics import mean_absolute_percentage_error
```

```
housing = fetch_california_housing()
X, y = housing.data, housing.target
X.shape, y.shape, housing.target_names
```

```
((20640, 8), (20640,), ['MedHouseVal'])
```

```
N = 15000
X_train, y_train = X[:N], y[:N]
X_test, y_test = X[N:], y[N:]
```

```
n_estimators = 100
boosting = GradientBoostingRegressor(n_estimators=n_estimators, learning_rate=0.1,
                                     max_depth=5,
                                     max_leaf_nodes=10,
                                     subsample=0.75, # stohastic if <1.0
                                     ccp_alpha=0.0, # pruning
                                     warm_start=True, # add trees to the existing forest
                                     random_state=0)
#boosting.fit(X_train, y_train)
history = sklearn_fit_history(boosting, n_estimators, X_train, y_train, (X_test, y_test))
```

Градиентный бустинг (пример)

Качество от размера ансамбля

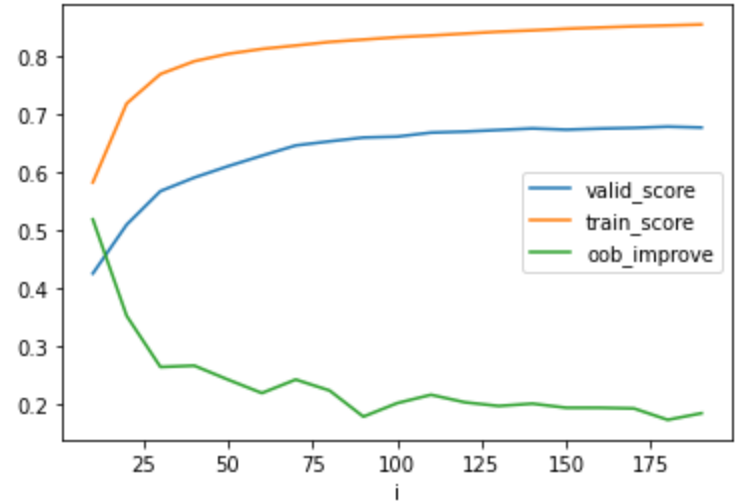

Качество от shrinkage

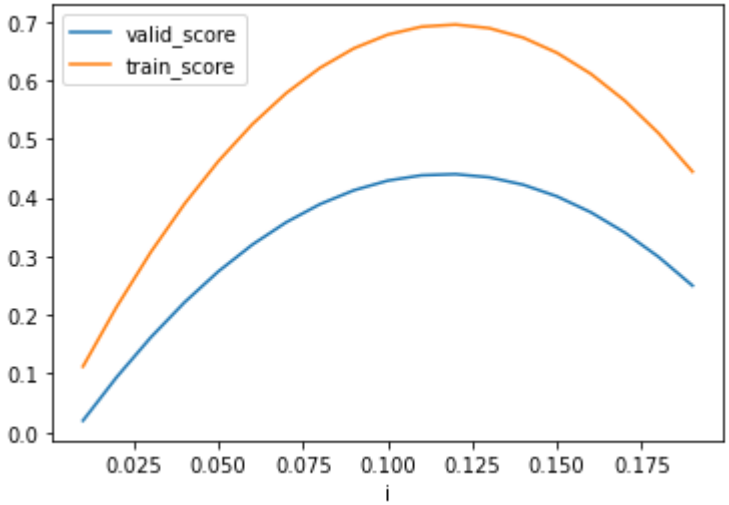

Качество от сложности дерева (max число листьев)

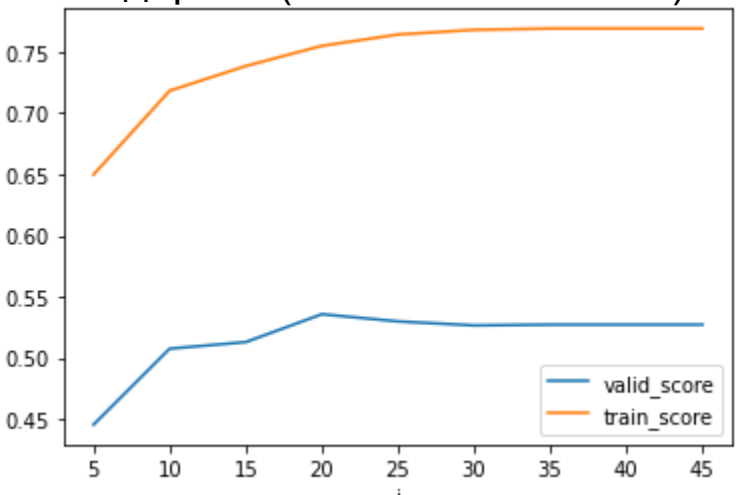

Качество от размера подвыборки

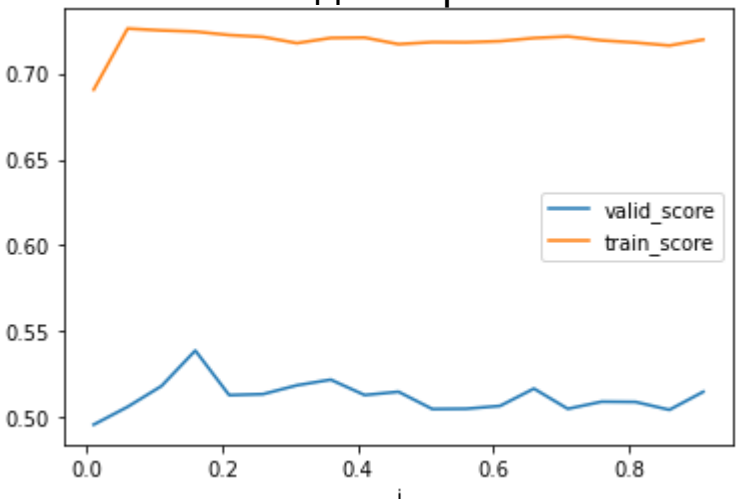

Градиентный бустинг (пример)

- Оценить важность переменных по ансамблю:

```
importance = pd.Series(index=housing.feature_names, data=boosting.feature_importances_)
importance.sort_values().plot()
plt.xticks(rotation='vertical');
```

средний прирост качества разбиения по переменной x_j всем деревьям ансамбля

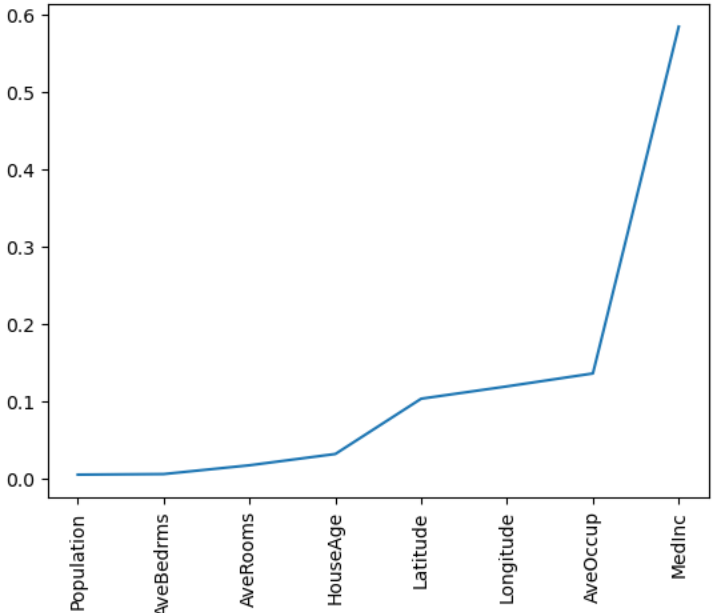

- Можно «добраться» до каждого дерева в ансамбле

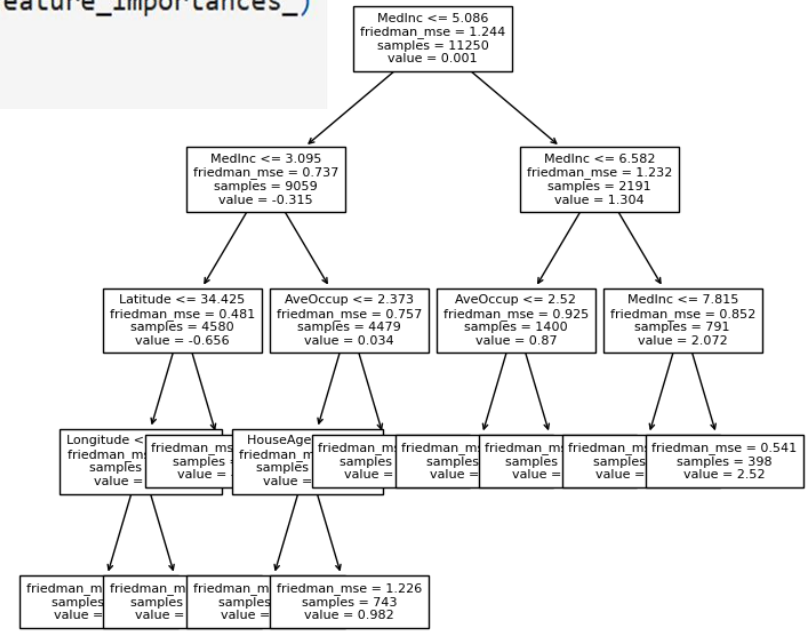


```
tree = boosting.estimators_[0][0]
plot_tree(tree, fontsize=8, feature_names=housing.feature_names)
plt.gcf().set_size_inches(8, 8)
```

Современные алгоритмы бустинга

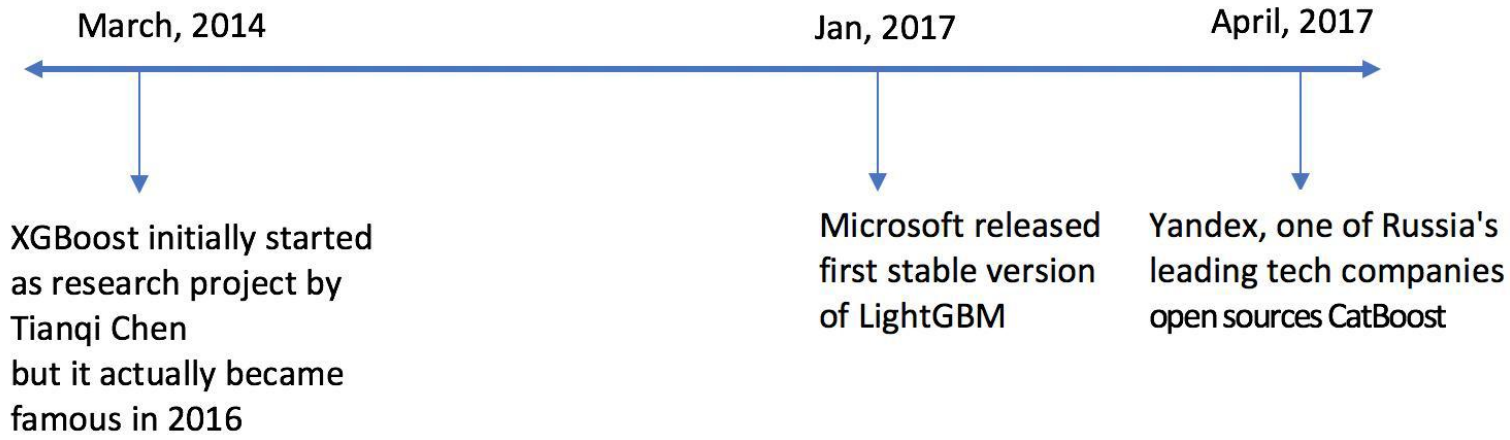

- Общие особенности:
  - Распараллеливание, поддержка GPU, TPU, возможности AutoML
  - Возможность дообучения для больших объемов данных
  - Разные стандартные и пользовательские метрики и функции потерь
  - Бэгинг, подвыборки и случайные подпространства, могут быть как RF
  - L_p регуляризации, ранняя остановка и контроль learning rate
  - Гистограммные методы поиска разбиений для числовых признаков
  - Колбэки и кастомное журналирование

Гистограммный подход для числовых признаков

- Предварительная дискретизация числовой переменной:
  - обычно на равные интервалы (buckets), получаем порядковую переменную с «весами» – число наблюдений в интервале

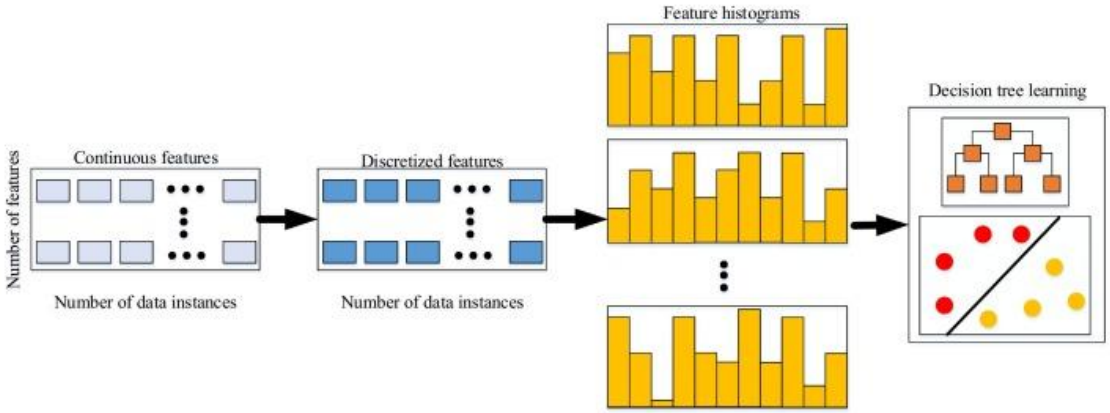

  - число перебираемых вариантов разбиения – число интервалов, а не число различных значений; ускоряется расчет критериев разбиения (за счет весов интервалов, удаления пустых или слабо заполненных); рекурсивный «досчет» на интервалах
  - эффективно сочетается с ростом дерева «в глубину» (list-wise)
  - распараллеливается расчет гистограмм

Отличия (самые важные)

- LightGBM:
  - Оптимизирован под рост «в глубину»
  - Gradient-based One-Side Sampling (GOSS) – адаптивный сэмплинг пропорционально важности примера (градиенту) при поиске разбиения
  - Exclusive Feature Bundling – жадный алгоритм «группировки» значений категориальных признаков на непересекающиеся группы
- CatBoost:
  - Оптимизирован под ODT
  - SWOE кодирование категориальных предикторов
  - Упорядоченный семплинг (для борьбы с переобучением градиентов)
- XGBoost:
  - Оптимизирован под рост «в ширину»
  - Ньютоновский бустинг - критерий поиска разбиений и/или обрубания, учитывающий качество и регуляризацию всего ансамбля

Дополнительные модификации деревьев решений и методов подвыборок бустинга

- Цель:
  - Ускорить процесс построения дерева, возможно за счет ухудшения качества и внесения дополнительной случайности («шума»)
  - Это плохо для обычных деревьев и иногда для бэгинга (может увеличивать смещение базовых моделей), но хорошо для бустинга, т.к. он уменьшает не только дисперсию, но и смещение
- «Ускорение»/ослабление обучения базовых деревьев решений:
  - Предобработка (сокращение перебора): для категориальных переменных **SWOE** (отображаем на порядковую шкалу) и жадная **группировка** значений категориальных переменных; для числовых – гистограммный подход
  - Уменьшение выборки при поиске разбиения – взвешенный **градиентный sampling, упорядоченный бустинг**
  - Упрощения структуры деревьев: рост «в глубину» - **list-wise** (сложный) и в «ширину» **level-wise** (по уровням – простой), Oblivious Decision Trees (**ODT**) - решающие таблицы

Предобработка категориальных признаков

- **SWOE** (по текущей подвыборке) для **категориальных**:
  - Пусть $\{v_1, \dots, v_k\}$ – множество значений категориальной переменной x в подвыборке Z_m
  - Для бинарного отклика $\rho_1 = P(y_i = 1 | (x_i, y_i) \in Z_m)$, ***c*** - параметр

$$x = v \Rightarrow SWOE_x(v) = \log\left(\frac{\sum_{x_i \in Z_m} I[x_i = v] I[y_i = 1] + c\rho_1}{\sum_{x_i \in Z_m} I[x_i = v] I[y_i = 0] + c(1 - \rho_1)}\right)$$

  - Для числового отклика $\rho = E(y_i | (x_i, y_i) \in Z_m)$, ***c*** – параметр

$$x = v \Rightarrow SWOE_x(v) = \frac{\sum_{x_i \in Z_m} y_i I[x_i = v] + c\rho}{\sum_{x_i \in Z_m} I[x_i = v] + c}$$

- Жадная **группировка значений категориальных** переменных:
  - Кодируем по порядку часто встречающиеся комбинации значений признаков, а не их декартово произведение
  - Эффективно при One-hot-encoding

Градиентный sampling

- Идея близка к Arc-x4:
  - учить деревья (или искать отдельные разбиения) на подмножестве «важных» примеров
  - важность примера – значение градиента на нем (псевдоостаток)
  - популярный вариант – отбираем топ % «важных» примеров, их всегда берем, а среди «не важных», часть берем случайно, но увеличиваем их градиент (меняем вес) пропорционально числу отобранных, так, чтобы не поменялось распределение «важных».

Ось y – градиенты $\nabla Q = \frac{\partial L(y_i, F_{m-1})}{\partial F_{m-1}}(x_i)$

«Усиленные» неважные примеры

Ось x –выборка $Z = \{x_1, \dots, x_l\}$

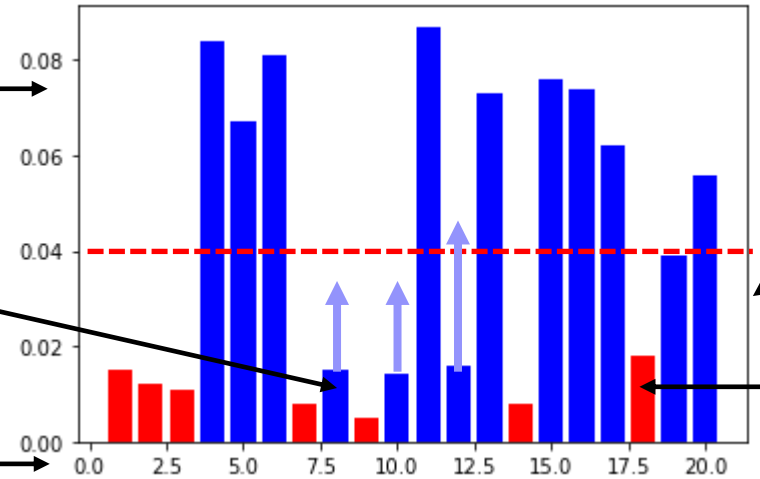

Порог «важных» примеров ($\nabla Q \geq 0.04$)

Выброшенные неважные примеры

LightGBM (пример)

```
from lightgbm import LGBMClassifier, early_stopping, record_evaluation, plot_importance
```

```
X_train, X_test, y_train, y_test = covtype_split
```

```
lgbm_classifier = LGBMClassifier(boosting_type="gbdt", # dart, rf
                                 num_leaves=10,
                                 max_depth=-1,
                                 learning_rate=0.05,
                                 min_child_samples=20, # min_samples_leaf
                                 n_estimators=2000,
                                 subsample=0.15, # subsample % for stohastic
                                 subsample_freq=1, # how many times to subsample
                                 colsample_bytree=0.15, # features by trees
                                 class_weight="balanced",
                                 reg_alpha=1.0 # l1 regularization
                                )
```

```
history = {}
lgbm_classifier.fit(X_train, y_train, feature_name=covtype.feature_names,
                    eval_set=[(X_test, y_test), (X_train, y_train)],
                    callbacks=[early_stopping(stopping_rounds=10), record_evaluation(history)])
```

```
Training until validation scores don't improve for 10 rounds
Early stopping, best iteration is:
[423]	training's multi_logloss: 0.349899	valid_0's multi_logloss: 0.728702
```

LightGBM (пример)

```
train = history["training"]["multi_logloss"]
valid = history["valid_0"]["multi_logloss"]
pd.DataFrame(dict(train=train, valid=valid)).plot()
```

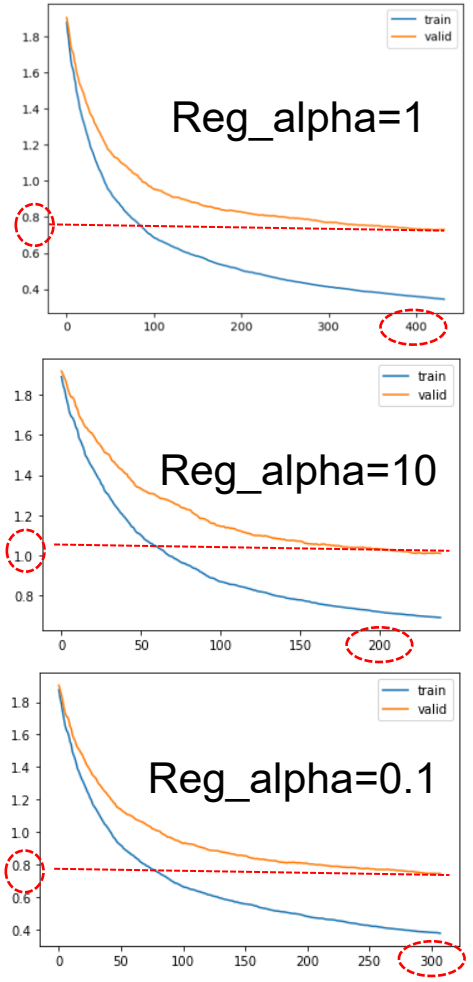

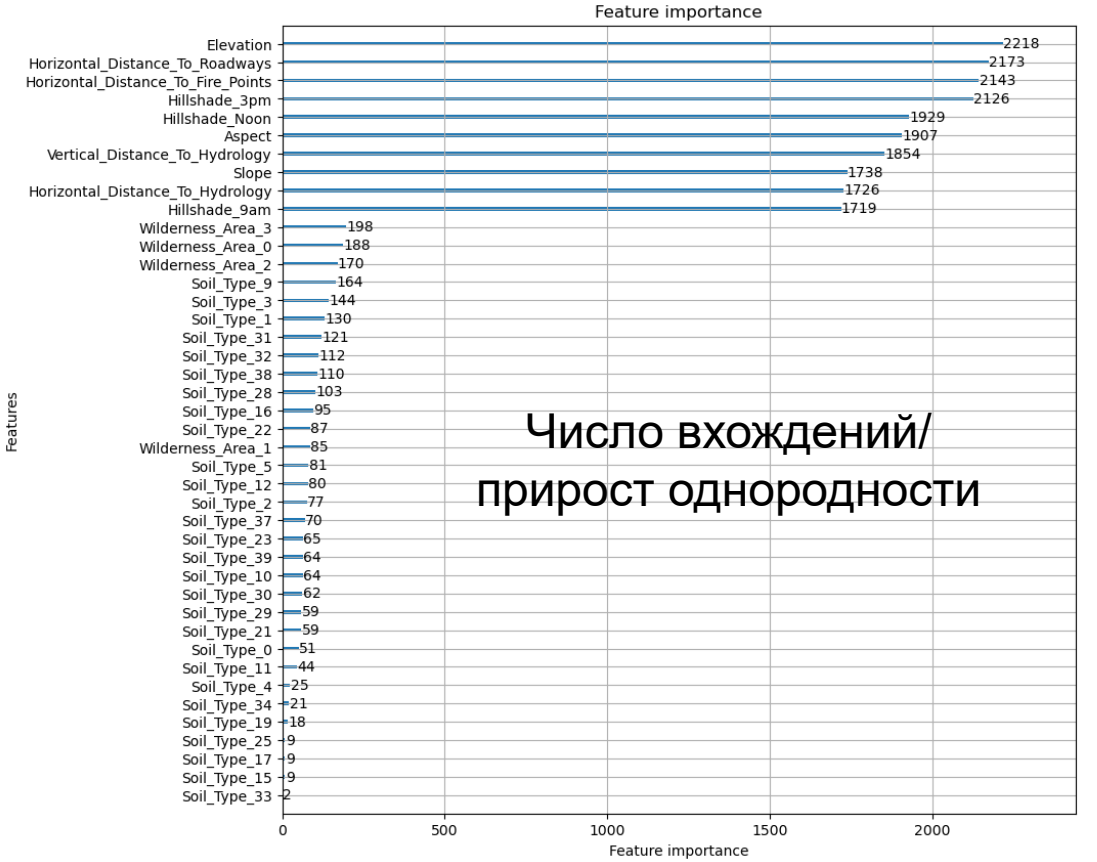


```
plot_importance(lgbm_classifier, figsize=(10, 10));
```

Упрощения роста дерева

- Стратегии роста дерева:
  - **«в глубину»** (list-wise) – классический, жадный, вычислительно долгий, сложно контролировать сложность всего дерева

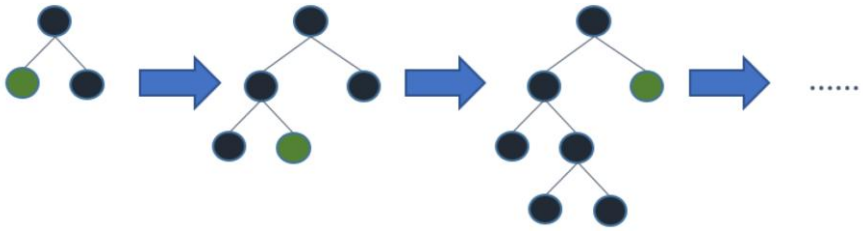

  - **«в ширину»** (level-wise) – упрощенный вариант, на каждом шаге плюс уровень для всех текущих листьев

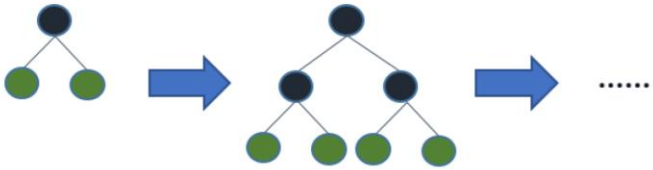

  - **«Небрежные»** деревья решений (Oblivious Decision Trees – ODT) или решающие таблицы – «в ширину», а еще правило разбиения (и переменная, и точка разбиения) одинаковые для всего уровня

Oblivious Decision Trees

- Основная идея – искать одно разбиение на весь уровень:
  - $b_d(x)$ решающее правило (сплит) для всего уровня d

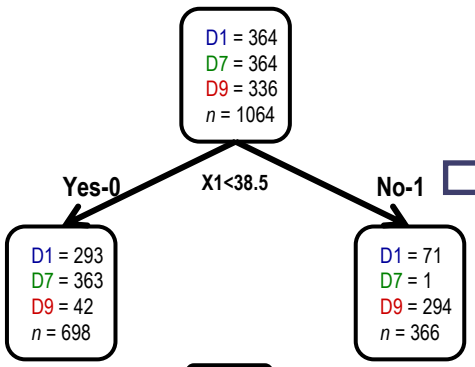

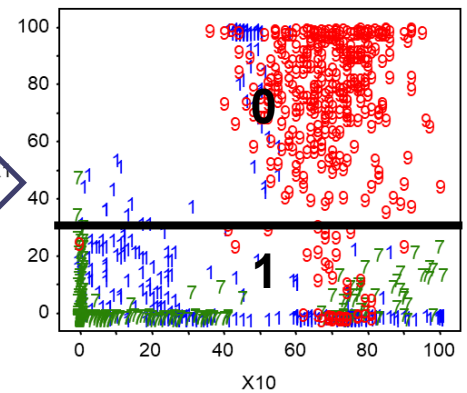

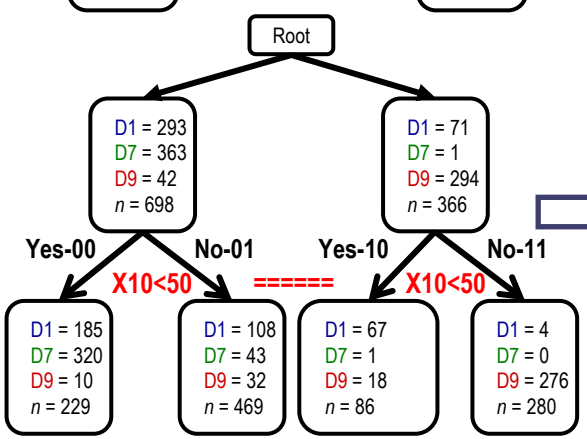

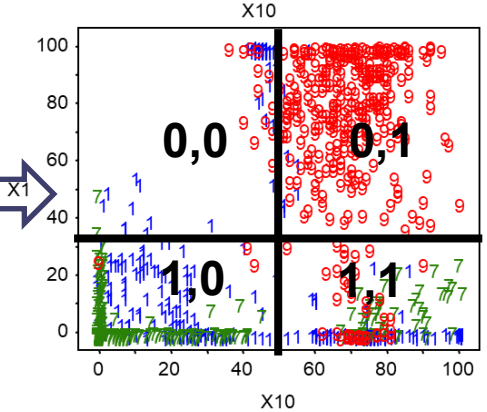

- Решающая таблица:
  - Для дерева глубины D пространство X делится на 2^D ячеек с решающим правилом:

$$B: \{0,1\}^D \to Y,$$

$$a(x) = B(b_1(x), \dots, b_D(x))$$

$b_1(x), \dots, b_D(x)$ – вектор прогнозов определяет «координаты» ячейки

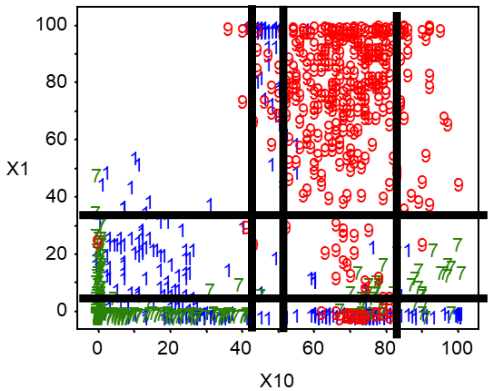

Алгоритм обучения (бинарного) ODT

- **Алгоритм разбиения** по уровням (для уровня d)
  - Сформировать множество *гипотез* $\{f_i\}$ *для разбиения* по всем признакам, $f_i: X \to \{0,1\}$ разбивает все пространство на два региона
  - Рассчитать значение *критерия разбиения* для каждой гипотезы с учетом уже существующего разбиения уровня d и выбрать лучшую по критерию (например, по увеличению однородности):

$$\Delta i = \sum_{p \in leaves_d} \left(i_p - \frac{n_{p,0} i_{p,0} + n_{p,1} i_{p,1}}{n_p} \right) \to \max$$

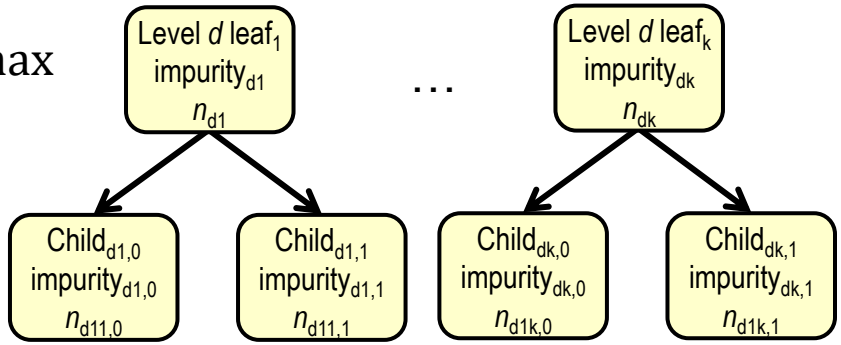

$leaves_d$ - листья на уровне d, их 2^d

i_p, n_p- однородность и число примеров одного из листьев уровня d

i_{p*}, n_{p*} - однородность и число примеров в дочерних узлах одного из листьев уровня d

  - Дорастить дерево «в ширину»: каждый лист уровня d превращается во внутренний узел с двумя новыми ветвями

Упорядоченный бустинг

- Важная проблема градиентного бустинга – target leakage:
  - «**Переобучение градиента**» за счет того, что на шаге m градиенты функции потерь (псевдоостатки) считаются с учетом отклика и на тех же точках $\{x_i\}_{i=1}^{l}$, на которых обучался ансамбль a_{m-1} на предыдущем шаге
- Как этого избежать?
  - Считать градиент функции потерь для x_i по ансамблю с шага $a_{m-1}^{(i)}$, который бы учился на $Z_m^{(i)}$, таком что $x_i \notin Z_m^{(i)}$.
  - Но считать и хранить l ансамблей одновременно - плохая идея …
- Основные идеи упорядоченного бустинга:
  - Цель - стараться вычислять градиент (псевдоостаток) для x_i по ансамблю $\boldsymbol{a_{m-1}^{(i)}}$**, который не учился на** $\boldsymbol{x_i}$
  - Строить обучающие подвыборки **последовательно** увеличивая размер (например, удваивая длину, тогда нужно не $O(l)$ моделей, а $O\big(\log(l)\big)$)
  - Нужно несколько случайно **перемешанных** подвыборок, чтобы они не перекрывались

Генерация выборок для упорядоченного бустинга

- Основная идея:
  - Заимствована из онлайн обучения (дообучаемся как накопятся данные, например, удвоилась выборка), но еще с перестановками
  - $s_0, s_1, \dots, s_k$ - случайные упорядоченные перестановки выборки $\{x_i\}_{i=1}^{l}$
  - X^{jr} - подвыборка первых j элементов из $s_r, r > 0$ - s_0 - «запасная»
  - $g_m^{jr}(x_i) = -L'(a_{m-1}^{jr}(x_i), y_i)$ – i-я координата (в точке x_i) градиента функции потерь (псевдоостаток) модели, которая не обучалась на x_i
  - если дообучаемся после удвоения, то $j = \mathrm{int}(\log_2(i-1))$ задает длину выборки, в которой еще не учился i-й объект
  - $a_m^{jr}(x)$ – ансамбль-заготовка, обученный на X^{jr}, их всего $k * \log(l)$

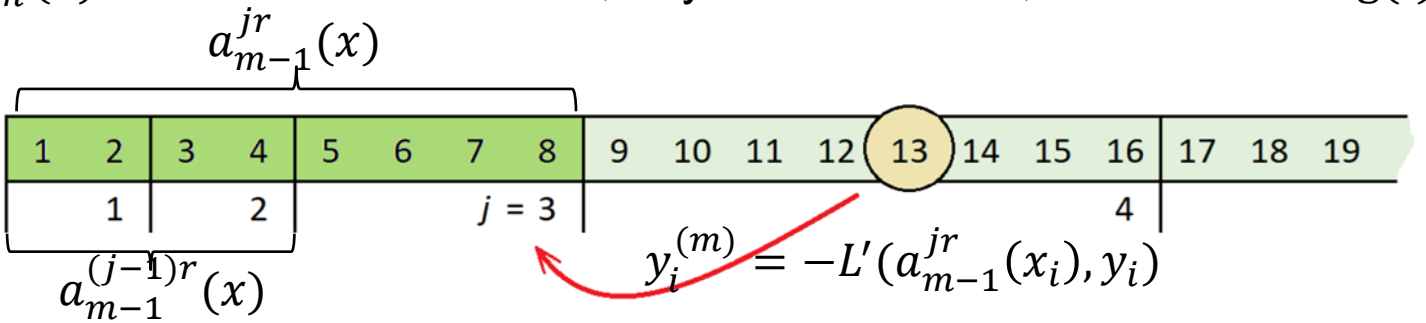

Алгоритм упорядоченного бустинга (CatBoost)

- Повторить $m = 1, \dots, M$ раз, где M – размер ансамбля:
  1. Выбрать **случайно** перестановку $s_r \in \{s_1, \dots, s_k\}$, s_0 - отложена
  2. Для всех наблюдений x_i, $i = 1, \dots, l$ вычислить **несмещенный антиградиент** (псевдоостаток), находя для каждого i такое максимальное j, чтобы a_{m-1}^{jr} не учился еще на x_i: $g_m^{jr}(x_i) = L'(a_{m-1}^{jr}(x_i), y_i)$
  3. Обучить на найденных псевдоостатках и примерах $\{(x_i, -g_m^{jr}(x_i))\}$ новое **специальное базовое** дерево $b_m^{base}(x)$, где разбиения и прогнозы в листьях для каждого наблюдения считаются с учетом порядка X^{jr}
  4. Для всех $r = 0, \dots, k$ берем **общую структуру дерева** $b_m^{base}(x)$ («жульничаем», чтобы не перестраивать дерево на всех перестановках), а прогноз отклика в листьях пересчитываем на всех s_r с учетом X^{jr}
  5. Получаем, во-первых, **базовые модели** $b_m^{jr}(x)$ для ансамблей-заготовок $a_m^{jr}(x)$, и $b_m^0(x)$, пересчитанный на s_0 для добавления в **финальный** α_m^0
  6. Для всех jr и 0 находим **градиентный шаг** $\boldsymbol{\alpha_m^*}$, где $* = jr$ или $* = 0$:

$$\alpha_m^* = \underset{\alpha}{\operatorname{argmin}} \sum_{i=1}^{N} L(y_i, a_{m-1}^*(x_i) + \alpha b_m^*(x_i))$$

Алгоритм построения специальных базовых деревьев в CatBoost

Algorithm 2: Building a tree in CatBoost

input : $M, \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \alpha, L, \{\sigma_i\}_{i=1}^s, Mode$

$grad \leftarrow CalcGradient(L, M, y)$;
$r \leftarrow random(1, s)$;
if $Mode = Plain$ **then**
  $G \leftarrow (grad_r(i)$ for $i = 1..n)$;
if $Mode = Ordered$ **then**
  $G \leftarrow (grad_{r,\sigma_r(i)-1}(i)$ for $i = 1..n)$;
$T \leftarrow$ empty tree;
foreach *step of top-down procedure* **do**
  foreach *candidate split* c **do**
    $T_c \leftarrow$ add split c to T;
    if $Mode = Plain$ **then**
      $\Delta(i) \leftarrow \text{avg}(grad_r(p)$ for $p : leaf_r(p) = leaf_r(i))$ for $i = 1..n$;
    if $Mode = Ordered$ **then**
      $\Delta(i) \leftarrow \text{avg}(grad_{r,\sigma_r(i)-1}(p)$ for $p : leaf_r(p) = leaf_r(i), \sigma_r(p) < \sigma_r(i))$ for $i = 1..n$;
    $loss(T_c) \leftarrow \cos(\Delta, G)$
  $T \leftarrow \arg\min_{T_c}(loss(T_c))$
if $Mode = Plain$ **then**
  $M_{r'}(i) \leftarrow M_{r'}(i) - \alpha\,\text{avg}(grad_{r'}(p)$ for $p : leaf_{r'}(p) = leaf_{r'}(i))$ for $r' = 1..s, i = 1..n$;
if $Mode = Ordered$ **then**
  $M_{r',j}(i) \leftarrow M_{r',j}(i) - \alpha\,\text{avg}(grad_{r',j}(p)$ for $p : leaf_{r'}(p) = leaf_{r'}(i), \sigma_{r'}(p) \le j)$ for $r' = 1..s$, $i = 1..n, j \ge \sigma_{r'}(i) - 1$;
return T, M

- Особенности:
  - «прогноз» в листьях (а значит и всего дерева) не константа для всех примеров листа, а вектор с усреднением прогноза для x_i с учетом его листа и порядка в X^{jr}
  - Потери (критерий оценки разбиения) – косинусная мера сходства с вектором несмещенных антиградиентов
  - Пересчет «векторного» прогноза в «точеный» – усреднением по всем

for $t \leftarrow 1$ **to** I **do**
  $T_t, \{M_r\}_{r=1}^s \leftarrow BuildTree(\{M_r\}_{r=1}^s, \{(\mathbf{x}_i, y_i)\}_{i=1}^n, \alpha, L, \{\sigma_i\}_{i=1}^s, Mode)$;
  $leaf_0(i) \leftarrow GetLeaf(\mathbf{x}_i, T_t, \sigma_0)$ for $i = 1..n$;
  $grad_0 \leftarrow CalcGradient(L, M_0, y)$;
  foreach *leaf* j *in* T_t **do**
    $b_j^t \leftarrow -\text{avg}(grad_0(i)$ for $i : leaf_0(i) = j)$;
  $M_0(i) \leftarrow M_0(i) + \alpha b_{leaf_0(i)}^t$ for $i = 1..n$;
return $F(\mathbf{x}) = \sum_{t=1}^I \sum_j \alpha\, b_j^t \mathbb{1}_{\{GetLeaf(\mathbf{x}, T_t, ApplyMode) = j\}}$;

Пример CatBoost с ordered boosting

```
model = CatBoostClassifier(iterations=500,  # Number of boosting iterations
                           learning_rate=0.3,  # Learning rate
                           #grow_policy='Depthwise',
                           depth=5,  # Depth of the tree
                           verbose=100,  # Print training progress every 50 iterations
                           early_stopping_rounds=10,  # stops training if no improvement in 10 consequtive rounds
                           loss_function='MultiClass')  # used for Multiclass classification tasks
```

```
0:      learn: 1.3244454        test: 1.3274746 best: 1.3274746 (0)     total: 10.8ms   remaining: 5.39s
100:    learn: 0.4770844        test: 0.5501835 best: 0.5501835 (100)   total: 1.25s    remaining: 4.95s
200:    learn: 0.3820112        test: 0.5085822 best: 0.5085822 (200)   total: 2.53s    remaining: 3.76s
300:    learn: 0.3180690        test: 0.4868846 best: 0.4868102 (299)   total: 3.6s     remaining: 2.38s
400:    learn: 0.2719426        test: 0.4756932 best: 0.4756932 (400)   total: 4.96s    remaining: 1.23s
499:    learn: 0.2394187        test: 0.4701613 best: 0.4699182 (495)   total: 6.32s    remaining: 0us

bestTest = 0.4699181794
bestIteration = 495

Shrink model to first 496 iterations.
```

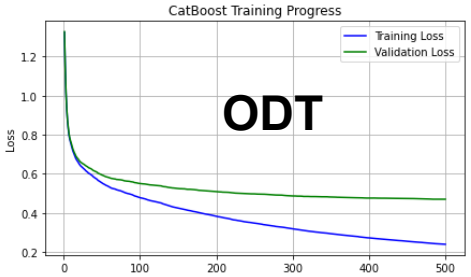


```
0:      learn: 1.2894816        test: 1.2931179 best: 1.2931179 (0)     total: 9.73ms   remaining: 4.85s
100:    learn: 0.4119708        test: 0.5314217 best: 0.5314217 (100)   total: 897ms    remaining: 3.54s
200:    learn: 0.2999559        test: 0.4992096 best: 0.4992096 (200)   total: 1.8s     remaining: 2.68s
300:    learn: 0.2308821        test: 0.4853332 best: 0.4853332 (300)   total: 2.71s    remaining: 1.79s
Stopped by overfitting detector  (10 iterations wait)

bestTest = 0.4808030753
bestIteration = 355

Shrink model to first 356 iterations.
```

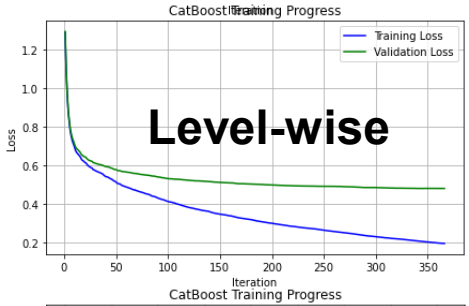


```
0:      learn: 1.3175380        test: 1.3213286 best: 1.3213286 (0)     total: 11.4ms   remaining: 5.71s
100:    learn: 0.4224715        test: 0.5395996 best: 0.5395996 (100)   total: 1.02s    remaining: 4.02s
200:    learn: 0.3073328        test: 0.5033971 best: 0.5032791 (197)   total: 2.08s    remaining: 3.1s
300:    learn: 0.2355510        test: 0.4854600 best: 0.4854600 (300)   total: 3.18s    remaining: 2.1s
400:    learn: 0.1859574        test: 0.4783043 best: 0.4780336 (398)   total: 4.29s    remaining: 1.06s
Stopped by overfitting detector  (10 iterations wait)

bestTest = 0.4780336062
bestIteration = 398

Shrink model to first 399 iterations.
```

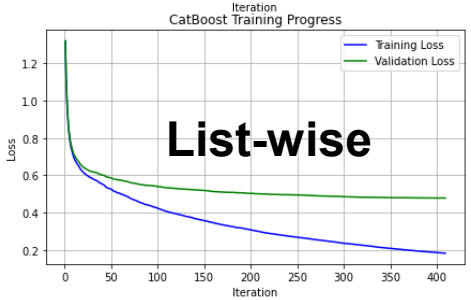

Сравнение CatBoost с упорядоченным и обычным boosting

```
model = CatBoostClassifier(iterations=500,  # Number of boosting iterations
                           learning_rate=0.3,  # Learning rate
                           depth=3,  # Depth of the tree
                           boosting_type = "Plain",
                           verbose=100,  # Print training progress every 50 iterations
                           early_stopping_rounds=10,  # stops training if no improvement in 10 consequtive rounds
                           loss_function='MultiClass')  # used for Multiclass classification tasks
```

```
0:      learn: 1.3214366        test: 1.3220541 best: 1.3220541 (0)     total: 6.69ms   remaining: 3.34s
100:    learn: 0.5648893        test: 0.5993844 best: 0.5993844 (100)   total: 793ms    remaining: 3.13s
200:    learn: 0.5041605        test: 0.5639954 best: 0.5639954 (200)   total: 1.63s    remaining: 2.42s
300:    learn: 0.4606368        test: 0.5450221 best: 0.5450221 (300)   total: 2.57s    remaining: 1.7s
400:    learn: 0.4276630        test: 0.5317555 best: 0.5317555 (400)   total: 3.51s    remaining: 867ms
499:    learn: 0.4005115        test: 0.5217715 best: 0.5215625 (496)   total: 4.45s    remaining: 0us

bestTest = 0.5215625037
bestIteration = 496

Shrink model to first 497 iterations.
```

Обычный – быстрее делает итерации, но хуже сходится

```
0:      learn: 1.3244454        test: 1.3274746 best: 1.3274746 (0)     total: 10.8ms   remaining: 5.39s
100:    learn: 0.4770844        test: 0.5501835 best: 0.5501835 (100)   total: 1.25s    remaining: 4.95s
200:    learn: 0.3820112        test: 0.5085822 best: 0.5085822 (200)   total: 2.53s    remaining: 3.76s
300:    learn: 0.3180690        test: 0.4868846 best: 0.4868102 (299)   total: 3.6s     remaining: 2.38s
400:    learn: 0.2719426        test: 0.4756932 best: 0.4756932 (400)   total: 4.96s    remaining: 1.23s
499:    learn: 0.2394187        test: 0.4701613 best: 0.4699182 (495)   total: 6.32s    remaining: 0us

bestTest = 0.4699181794
bestIteration = 495

Shrink model to first 496 iterations.
```

Упорядоченный

Особенности классического градиентного бустинга деревьев решений

- В сравнении с основным конкурентом случайным лесом:
  - уменьшает не только разброс, но и **смещение** всего ансамбля
  - с ростом числа базовых моделей не склонен к **переобучению**, когда нет шума (выбросов), но склонен когда **выбросы** есть
  - **плохо распараллеливается** (только на уровне отдельных моделей) и требует **больше вычислений** (пересчет псевдоостатков, поиск веса базовой модели на каждом шаге)
  - помимо ограничений на сложность есть и **регуляризация** (shrinkage-сокращение, штрафы L0, L1, L2, ранняя остановка)
  - может использовать идеи из случайного леса: **случайные подпространства** признаков при поиске разбиения (часто полезно) и дополнительно **бутсретпинг** в стохастическом градиентном бустинге (часто бесполезно)
  - базовые деревья (регионы и прогнозы в них) строятся **без использовании информации** о всем ансамбле – это плохо! А можно ли исправить? **ДА!**

Учет потерь ансамбля в каждом дереве

- Бустинг деревьев решений:
  - Ансамбль: $F_m(x) = F_0 + \alpha_1 T_1(x) + \alpha_2 T_2(x) + \ldots + \alpha_m T_m(x)$

$F_m(x) = F_0 + \alpha_1 *$ 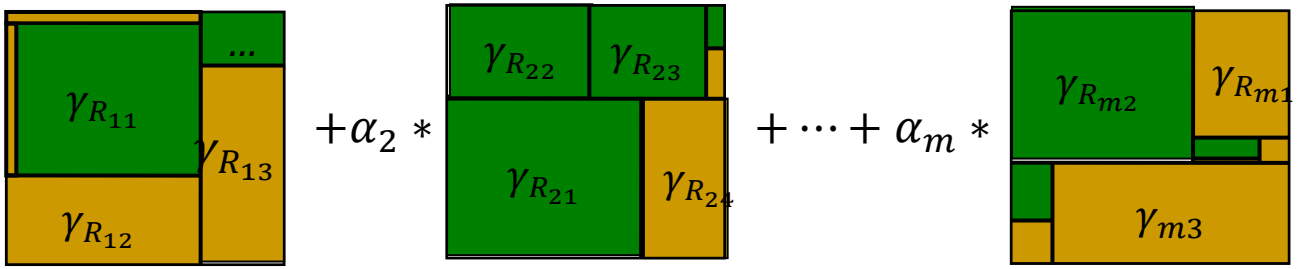

  - Базовая модель – дерево $T_m(x) = \sum_{R \in R_m} \gamma_R \, I[x \in R]$, обученное на псевдоостатках в качестве вектора отклика $-\left[\frac{\partial L(y_i, F_{m-1})}{\partial F_{m-1}}(x_i)\right]_{i=1}^{l}$
  - Ансамбль минимизирует потери: $Q_m = \sum_i L(y_i, F_m(x_i))$, а можно сразу искать $(\{\gamma_R\}_{R \in R_m}, R_m) = \mathrm{argmin}_{R_m, \gamma} Q_m$ при фиксированном Q_{m-1}?

Ньютоновский бустинг (XGBoost)

- Раскладываем потери в ряд Тейлора до 2 слагаемого:

$$\sum_i L(y_i, F_{m-1}(x_i) + \boldsymbol{b}(\boldsymbol{x_i})) \approx$$

$$\approx \sum_i L\big(y_i, F_{m-1}(x_i)\big) + b(x_i)\frac{\partial L(y_i, F_{m-1})}{\partial F_{m-1}}(x_i) + \frac{1}{2}b^2(x_i)\frac{\partial^2 L(y_i, F_{m-1})}{(\partial F_{m-1})^2}(x_i) \ldots$$

  - Обозначим:

$$b_i = b(x_i),\ g_i = \frac{\partial L(y_i, F_{m-1})}{\partial F_{m-1}}(x_i),\ h_i = \frac{\partial^2 L(y_i, F_{m-1})}{(\partial F_{m-1})^2}(x_i)$$

  - Тогда приближенно потери:

$$\sum_i L\big(y_i, F_m(x_i)\big) \sim \sum_i [g_i b_i + \frac{1}{2}h_i b_i^2] + const$$

  - Добавим регуляризацию L_2 на отклик и L_0 (число листьев) на сложность дерева, получим критерий для минимизации:

$$Q_m = \sum_i [g_i b_i + \frac{1}{2}h_i b_i^2] + \lambda_2 |T_m(x)| + \frac{1}{2}\lambda_1 \sum_{R \in R_m} \gamma_R^2 \to \min_{R_m, \gamma_R}$$

Ньютоновский бустинг (XGBoost)

- Логика вывода основных формул:
  - Если зафиксируем структуру дерева (регионы R_m), то из $\frac{\partial Q_m}{\partial \gamma_R} = 0 \Rightarrow$

$$\gamma_R = \frac{\sum_{x_i \in R} g_i}{\lambda_1 + \sum_{x_i \in R} h_i}$$

  - Подставляя γ_R в Q_m получим новый критерия поиска разбиения:

$$\Phi_m = -\frac{1}{2} \sum_{R \in R_m} \frac{\left(\sum_{x_i \in R} g_i\right)^2}{\lambda_1 + \sum_{x_i \in R} h_i} + \lambda_2 |T_m| \to \min$$

  - Прирост для поиска бинарного разбиения:

$$Gain = -\frac{1}{2}\left[\frac{\left(\sum_{x_i \in R_{left}} g_i\right)^2}{\lambda_1 + \sum_{x_i \in R_{left}} h_i} + \frac{\left(\sum_{x_i \in R_{right}} g_i\right)^2}{\lambda_1 + \sum_{x_i \in R_{right}} h_i} - \frac{\left(\sum_{x_i \in R_{parent}} g_i\right)^2}{\lambda_1 + \sum_{x_i \in R_{parent}} h_i}\right] - \lambda_2$$

XGBoost

```
import xgboost as xgb
```

```
# https://xgboost.readthedocs.io/en/stable/parameter.html
param = dict(objective="multi:softprob", num_class=10, # softmax
             booster="gbtree", learning_rate=0.1, max_depth=5, subsample=0.5,
             alpha=5, # l1 regularization
             tree_method="auto") # approx, hist, gpu_hist
```

```
N = 1000
dtrain = xgb.DMatrix(digits.data[:N], label=digits.target[:N])
dvalid = xgb.DMatrix(digits.data[N:], label=digits.target[N:])
evallist = [(dtrain, 'train'), (dvalid, 'eval')]
```

```
xgb_classifier = xgb.train(param, dtrain, 1000, evals=evallist, early_stopping_rounds=10)
# xgb_classifier.save_model('mymodel')
```

```
[0]     train-mlogloss:2.03753  eval-mlogloss:2.08882
[1]     train-mlogloss:1.82993  eval-mlogloss:1.90860
[2]     train-mlogloss:1.66188  eval-mlogloss:1.76258
[3]     train-mlogloss:1.53163  eval-mlogloss:1.65200
                        ...
[475]   train-mlogloss:0.16262  eval-mlogloss:0.45679
[476]   train-mlogloss:0.16262  eval-mlogloss:0.45679
```

XGBoost

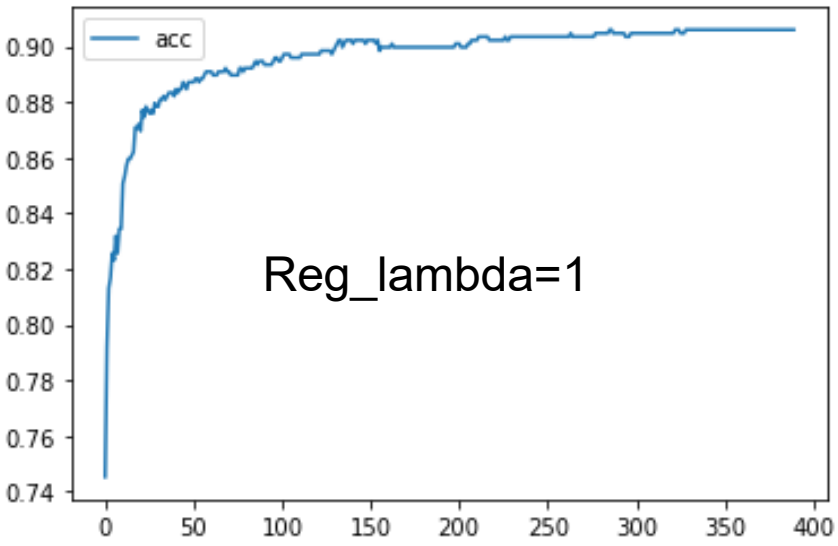

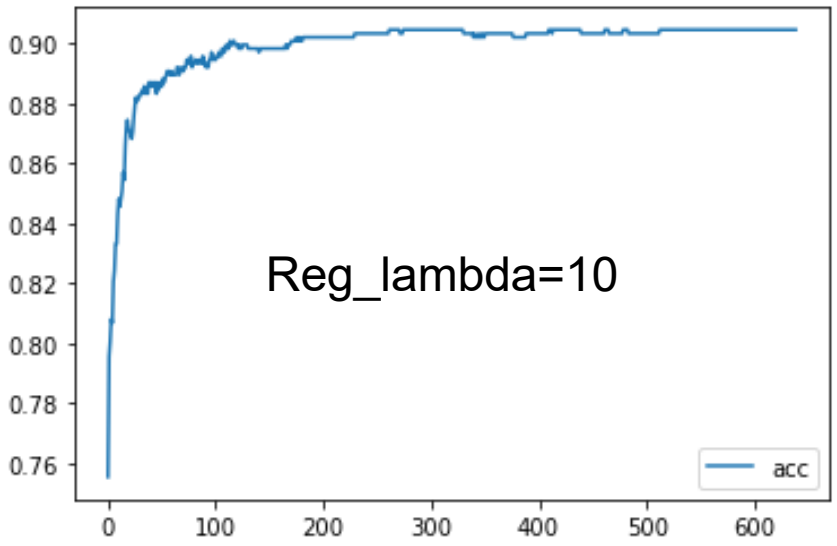


```
result = []
for i in range(xgb_classifier.best_iteration):
    true = dvalid.get_label()
    pred = xgb_classifier.predict(dvalid, iteration_range=(0, i + 1))
    result.append(dict(acc=accuracy_score(true, np.argmax(pred, axis=-1))))
pd.DataFrame(result).plot()
```

Сравнение (по logloss) XGBoost, LGBM и CatBoost

	CatBoost		LightGBM		XGBoost	
	Tuned	Default	Tuned	Default	Tuned	Default
Adult	**0.26974**	0.27298 +1.21%	0.27602 +2.33%	0.28716 +6.46%	0.27542 +2.11%	0.28009 +3.84%
Amazon	**0.13772**	0.13811 +0.29%	0.16360 +18.80%	0.16716 +21.38%	0.16327 +18.56%	0.16536 +20.07%
Click prediction	**0.39090**	0.39112 +0.06%	0.39633 +1.39%	0.39749 +1.69%	0.39624 +1.37%	0.39764 +1.73%
KDD appetency	0.07151	**0.07138** −0.19%	0.07179 +0.40%	0.07482 +4.63%	0.07176 +0.35%	0.07466 +4.41%
KDD churn	**0.23129**	0.23193 +0.28%	0.23205 +0.33%	0.23565 +1.89%	0.23312 +0.80%	0.23369 +1.04%
KDD internet	**0.20875**	0.22021 +5.49%	0.22315 +6.90%	0.23627 +13.19%	0.22532 +7.94%	0.23468 +12.43%
KDD upselling	**0.16613**	0.16674 +0.37%	0.16682 +0.42%	0.17107 +2.98%	0.16632 +0.12%	0.16873 +1.57%
KDD 98	**0.19467**	0.19479 +0.07%	0.19576 +0.56%	0.19837 +1.91%	0.19568 +0.52%	0.19795 +1.69%
Kick prediction	**0.28479**	0.28491 +0.05%	0.29566 +3.82%	0.29877 +4.91%	0.29465 +3.47%	0.29816 +4.70%

Epsilon dataset ○ Higgs dataset

	CatBoost	XGBoost	LightGBM
CPU (Xeon E5-2660v4)	**527 sec**	4339 sec	1146 sec
GTX 1080Ti (11GB)	**18 sec**	890 sec	110 sec

Dataset Epsilon (400K samples, 2000 features). Parameters: 128 bins, 64 leafs, 400 iterations.

○ Epsilon dataset **Higgs dataset**

	CatBoost	XGBoost	LightGBM
CPU (Xeon E5-2660v4)	770 sec	881 sec	**438 sec**
GTX 1080Ti (11GB)	**32 sec**	91 sec	94 sec

Dataset Higgs (4M samples, 28 features). Parameters: 128 bins, 64 leafs, 400 iterations.

Выводы по ансамблям

- Позволяют существенно повышать качество базовых моделей
- Базовые модели часто это деревья решений (универсальная, не очень точная, не стабильная модель, что хорошо)
- Ансамбли бывают разных типов для разных задач
- Модели «из коробки» - Random Forest и градиентный бустинг
- ECOC, смеси экспертов и stacking тоже важны для своих задач
- Управлять качеством ансамбля можно варьируя сложность ансамбля (размер и/или гибкость агрегационной функции), сложность базовой модели и случайность (зависит от подвыборок и настроек базовых моделей)
- Большинство ансамблей уменьшают дисперсию прогноза, но некоторые могут уменьшать и смещение
- Основной минус – долго строить и применять, как правило теряется интерпретация исходных базовых моделей